


AnchorDrive: 基于锚点引导扩散再生的大语言模型场景展开方法，用于安全关键场景生成

蒋竹林*, 李哲涛*, 王成, 王子文, 邢晨†

摘要—自动驾驶系统需要在安全关键场景中进行全面评估, 以确保安全性和鲁棒性。然而, 此类场景在真实世界驾驶数据中较为罕见且难以收集, 需要基于模拟进行合成。但现有方法在可控性和真实性方面往往存在局限性。从能力角度来看, 大语言模型擅长根据自然语言指令进行可控生成, 而扩散模型更适合生成与真实驾驶分布一致的轨迹。利用它们的互补优势, 我们提出了 AnchorDrive, 一个两阶段的安全关键场景生成框架。在第一阶段, 我们在闭环模拟中部署大语言模型作为驾驶员代理, 在自然语言约束下进行推理并迭代输出控制指令; 计划评估器会审查这些指令并提供纠正反馈, 从而实现语义可控的场景生成。在第二阶段, 大语言模型从第一阶段轨迹中提取关键锚点作为引导目标, 这些目标与其他引导项共同驱动扩散模型再生更真实的完整轨迹, 同时保留用户指定的意图。在高D数据集上的实验表明, AnchorDrive在关键性、真实性和可控性方面均取得了优异的整体性能, 验证了其在生成可控且真实的安全关键场景方面的有效性。索引词—自动驾驶, 安全关键场景生成, 大语言模型, 扩散模型, 轨迹生成

Example of Safety-Critical Scenario Generation



Challenge in Safety-Critical Scenario Generation

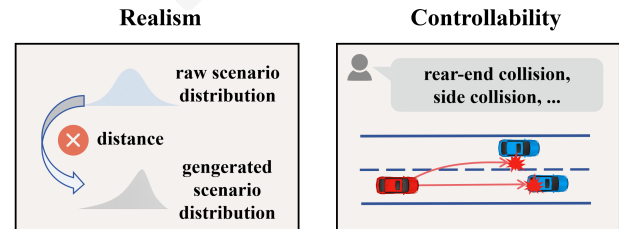


图1. 场景生成的示例和主要挑战。蓝色车辆代表本车, 红色车辆代表对抗车辆。

一、引言

随着自动驾驶技术的不断进步, 验证自动驾驶系统在不同场景下的安全性和鲁棒性, 已成为实现实际部署不可或缺的一步 [1]–[3]。在安全关键场景中的测试尤为重要, 因为这些场景是评估系统安全能力的核心基础。这些场景通常具有高风险交互特征: 自动驾驶车辆与其他道路使用者交互时, 可能会遇到突然或不寻常的行为, 显著增加碰撞的可能性 [4], [5]。然而, 现实世界的道路测试不仅资源密集, 而且难以系统地收集足够且足够危险的安全关键样本, 导致评估覆盖范围有限。相比之下, 基于仿真的安全关键场景生成和测试由于其成本较低、效率更高、易于扩展和可重复, 已成为一种普遍采用的方法。

*这些作者平等地贡献了这项工作。

†通讯作者 (邮箱: xiongch8@mail.sysu.edu.cn)。

所有作者均来自中山大学智能工程学院, 中国深圳。

作者们感谢中国国家重点研发计划 (项目编号: 2024YFB4303400)、广东省自然科学基金 (项目编号: 2025A1515010166) 以及中国深圳市基础研发计划 (项目编号: JCYJ20240813151301003) 的资助。

样本, 导致评估覆盖率有限。相比之下, 基于仿真的安全关键场景生成和测试已成为一种普遍方法, 由于其成本较低、效率更高以及可扩展性和可重复性易于实现。

如图1所示, 用于在仿真中生成安全关键场景的方法通常配置道路结构、交通参与者、其初始状态和虚拟环境中的行为策略, 合成触发高风险交互的轨迹, 以评估测试系统下的安全性。此类生成需要结果既具有真实性又具有可控性。真实性要求生成的轨迹运动学特征 (例如, 速度、加速度) 尽可能统计地近似真实驾驶数据分布, 同时避免不合理行为 (例如, 车道偏离), 从而防止极端和不合理的场景。可控性要求生成的结果遵循用户语义描述, 能够针对生成指定的风险交互场景。然而, 现有方法通常难以同时满足真实性和可控性。

早期的安全关键场景生成方法通常依赖于 CARLA [6] 和 SUMO [7], 等仿真平台, 研究人员基于本体 [8], [9] 手动或半自动地设计场景。这类方法具有强可控性, 但效率较低。

早期的安全关键场景生成方法通常依赖于CARLA [10]和SUMO [13]等仿真平台, 研究人员基于本体论 手动或半自动地设计场景。这类方法具有强可控性, 但效率低下、严重依赖专家知识, 且现实感不足。为了提高生成场景的现实感, 基于深度学习的方法应运而生。这些方法通常在大规模真实驾驶数据上训练模型, 并在测试时通过基于优化的技术或梯度引导 [10]–[13]生成安全关键场景。由于深度学习模型能够捕捉训练分布中的行为模式, 这类方法在场景现实感方面具有明显优势; 然而, 它们往往难以精细控制生成结果, 在可控性方面存在局限。

生成式 AI 的发展为应对这些挑战提供了新的可能性。大语言模型在自然语言理解和代码生成 [14]–[16], 方面展现出卓越的能力, 使其天然适合作为用户通过自然语言描述安全关键场景的交互界面。ChatScene 和 OmniTester 等工作将用户描述编译成脚本或配置文件, 以驱动模拟器进行场景生成 [17][18], 实现了从文本到场景的范式, 显著降低了场景构建的门槛; 然而, 生成的轨迹与真实轨迹分布仍存在较大差距。与此同时, 大语言模型也被用于将语义描述转换为损失项, 以指导扩散模型的去噪 [19], [20], 在一定程度上增强了基于深度学习方法的可控性。然而, 从自然语言到损失函数的映射涉及表示不匹配问题, 复杂的交互难以稳定地编码为损失函数, 导致对指令的响应仍然不够直接和精细, 仍有进一步改进的空间。

现有方法通常在单个流程中生成场景, 这往往导致现实感不足或可控性有限。为解决这一问题, 我们将这两个方面解耦: 首先解决可控生成问题, 然后处理现实感问题。我们借鉴了近期两条进展的启发: 端到端自动驾驶研究已表明, 具备“感知—推理—执行”闭环能力的基于LLM的驾驶智能体可以将高层意图稳定地转化为可执行的动作序列 [21]–[24], 使其能够作为交互过程构造器, 生成符合用户指令的高风险轨迹。同时, 扩散模型在轨迹生成中拟合真实数据分布方面展现出强大能力, 并通过锚点引导去噪过程, 确保生成的轨迹在关键时刻和位置满足指定条件 [25], [26], 从而产生既通过指定锚点又保持现实感的轨迹。基于这种互补性, 我们首先采用基于LLM的驾驶智能体生成可控场景, 然后使用锚点引导扩散进行轨迹再生, 最终实现可控性与现实感的双重效果。

因此, 我们提出了AnchorDrive, 一个两阶段LLM引导的安全关键场景生成框架。我们的框架包含两个主要模块: 一个基于LLM的场景展开模块用于可控场景生成, 以及一个轨迹再生模块用于优化。在第一个模块中, 基于LLM的驾驶员代理接收环境

因此, 我们提出了AnchorDrive, 一个两阶段的LLM引导的安全关键场景生成框架。我们的框架包含两个主要模块: 一个基于LLM的场景展开模块用于可控场景生成, 以及一个轨迹再生模块用于优化。在第一个模块中, 基于LLM的驾驶员代理接收环境状态和用户自然语言指令, 在预设的Chain-of-Thought (CoT) 提示下进行推理, 并迭代输出控制指令; 计划评估器会审查这些指令, 在失败时提供纠正反馈, 抑制不合理行为, 以在仿真闭环中稳定生成符合用户指令的安全关键场景。在第二个模块中, 我们利用LLM分析第一阶段的轨迹, 并自动提取关键锚点, 将锚点与其他约束条件作为指导目标构建损失函数, 引导扩散模型的去噪过程以再生完整的多车辆轨迹。锚点保留了第一阶段关键事件中的驾驶意图和时序结构, 而扩散先验则增强了运动学合理性和统计一致性, 从而在不改变场景语义(风险模式类型、关键参与者以及关键事件的时序顺序)的情况下提高场景真实性。

总而言之, 本文的主要贡献包括:

- 我们提出了一种基于闭环LLM驱动代理的安全关键场景生成方法: 在自然语言约束下迭代输出控制序列, 并由计划评估器提供审查和纠正反馈以抑制不合理行为, 从而稳定生成与指令语义一致的高风险交互场景, 并实现语义可控的生成。
- 我们设计了一种基于扩散模型的轨迹优化机制: LLM从生成的轨迹中提取稀疏的关键锚点集, 利用这些锚点以及其他引导目标来引导扩散去噪, 以实现多车辆轨迹再生和优化, 在保留场景语义的同时提高轨迹真实性。
- 我们提出了两阶段AnchorDrive框架, 并在highD数据集上进行了系统评估。实验表明, 在关键性、真实性和可控性指标上均表现出色, 验证了其生成可控和真实安全关键场景的有效性。

本文的其余部分组织如下: 第二节回顾了安全关键场景生成的相关工作; 第三节介绍了提出的AnchorDrive框架; 第四节提供了highD上的实验评估和组件有效性分析; 第五节总结全文并讨论未来方向。

II. 相关工作

A. 传统场景生成方法

早期的场景生成方法主要依赖专家在CARLA和SUMO等仿真平台上设计安全关键场景, 手动调整参与者的初始位置、速度和行驶路线, 或使用本体和脚本模板构建碰撞、近距离擦撞和交通违规等场景 [8], [9]。这些方法在参数层面具有强大的可控性, 但存在严重依赖领域知识、可扩展性有限、

且难以与真实轨迹分布保持一致的问题 [27]。

近期研究探索了原始场景中的特定参数化空间，以利用基于优化的方法精确定位对抗性参数 [28]–[30]。例如，AdvSim [13] 直接在轨迹空间中扰动背景车辆，以搜索导致规划器失效的轨迹。Strive [12] 引入深度学习模型，在数据驱动的潜在空间中优化，同时增强多车辆交互的合理性；其他研究通过强化学习训练对抗性车辆，在闭环交互中学习危险的机动 [31], [32]。尽管这些方法可以系统地发现具有挑战性的场景，但生成结果通常由优化目标或奖励设计决定，难以在高级语义层指定风险模式，因此通常缺乏语义级可控性。

近年来，引导式扩散模型被引入场景生成中，以提高基于深度学习的方法的可控性。例如，CTG 通过可微分的损失函数、STL 约束或安全目标引导去噪采样过程，以实现可控的轨迹生成 [10]–[12]；SafeSim [26] 进一步结合损失函数引导与闭环模拟中的部分扩散，能够在保持行为真实性的同时调整碰撞类型和风险级别。然而，此类方法仍严重依赖手动设计的损失函数或特定任务的奖励模型；不同的对抗性目标通常需要重建损失函数，限制了在语义层面的灵活指定，并降低了非专业用户的使用便利性。

B. 基于LLM的场景生成

受益于强大的自然语言理解、知识推理和代码生成能力，近年来LLM已被广泛应用于场景生成任务中，[33], [34], 展现出生成逼真且可控场景的潜力。

一类方法利用LLM将用户描述编译成脚本或配置等中间表示，定义参与者初始状态、交互规则和触发条件，以实现快速构建和批量生成。例如，LCTGen [35] 利用LLM将文本查询转换为结构化表示，然后使用Transformer生成交通场景。ChatScene [17] 通过LLM分析用户描述，将自然语言转换为Scenic脚本并在CARLA中执行以获取相应场景。这些方法显著降低了场景生成的门槛，允许用户通过简单描述直接获取目标危险场景；然而，它们仍然面临场景逼真度不足的问题。

另一类方法将大型语言模型（LLMs）与扩散模型相结合。CTG++ [19]使用LLMs将用户自然语言指令转换为可微分的引导损失函数，在扩散模型的去噪过程中应用梯度引导，以确保生成的轨迹满足指令中描述的语义约束

LD-Scene [20] 将这种方法应用于安全关键场景生成，使用思维链提示生成对抗性损失函数，引导潜在扩散模型生成指定的安全关键场景类型。然而，从自然语言到损失函数的映射仍然不够直接，复杂的交互意图难以稳定地编码为优化目标，从而限制了生成可控性。

C. 基于LLM的驾驶智能体

近年来，端到端自动驾驶研究开始将LLM直接部署为驾驶员代理，在闭环仿真环境中生成驾驶决策 [36]–[38]。[39] 指出，LLM可以作为高级决策者，在道路上稳定驾驶。

在早期工作中，Fu等人 [21] 在简化的高速公路环境中构建了一个由LLM驱动的闭环控制框架：将周围信息编码为简洁的文本输入LLM，以进行带解释的离散动作选择。LMDrive [24] 将前视摄像头图像与导航文本编码后输入LLM，LLM直接输出转向角和加速度来控制车辆，实现了导航文本引导的端到端闭环控制。DriveGPT4 [40] 将这一范式扩展到更开放的城市交通中，通过语义摘要进行逐步推理，输出连续控制信号，展示了LLM在长时序规划和复杂交互建模方面的能力。

总体而言，基于LLM的驾驶代理在闭环交互中具备遵循自然语言意图和生成可解释驾驶行为的优势。基于此，我们在第一阶段采用基于LLM的驾驶代理，以构建与用户描述一致的安全关键场景。

III. 方法论

本节介绍了所提出的AnchorDrive框架的技术细节。我们首先对安全关键场景生成任务提供正式定义，阐明输入、输出和符号；然后分别描述第一阶段和第二阶段的具体实现。

A. 问题公式化

我们的目标是根据自然语言指令生成可控且真实的安全关键交互场景。每个场景包含 N 交通参与者，其中自行车和对抗车的指定由用户指令 I 定义。我们旨在使对抗车以用户指定方式与自行车发生碰撞，同时确保所有车辆轨迹保持真实。

一个交通场景由一张地图 M 和交通参与者的状态序列 N 组成，其中地图包含车道拓扑、可行驶区域等。我们通过 $i \in \{0, 1, \dots, N-1\}$ 对交通参与者进行索引。在离散时间步长 t （时间步长长度由模拟器设置），所有参与者的联合状态表示为 $s_t = [s_t^0, s_t^1, \dots, s_t^{N-1}]$ 。

单车状态定义为 $s_t^i = (x_t^i, y_t^i, \theta_t^i, v_t^i)$, 其中 $x_t^i, y_t^i, \theta_t^i, v_t^i$ 分别表示二维位置坐标、航向角和速度。给定长度为 T_{hist} 的历史观测窗口, 我们将历史状态序列表示为

$x = \{s_{t-T_{\text{hist}}}, s_{t-T_{\text{hist}}+1}, \dots, s_t\}$, 即过去 T_{hist} 个时间步长内所有交通参与者的历史状态。我们生成所有参与者在未来预测范围 $[t+1, t+T]$ 内的联合轨迹 τ , 包括动作序列 τ^a 和状态序列 τ^s : $\tau = [\tau^a, \tau^s]$, 其中 $\tau^s = \{s_{t+1}, s_{t+2}, \dots, s_{t+T}\}$ 和 $\tau^a = \{a_{t+1}, a_{t+2}, \dots, a_{t+T}\}$ 。在时间 t , 联合动作定义为 $a_t = [a_t^0, a_t^1, \dots, a_t^{N-1}]$, 其中单车动作 $a_t^i = (\dot{v}_t^i, \dot{\theta}_t^i)$, 其中 $\dot{v}_t^i$ 和 $\dot{\theta}_t^i$ 分别表示加速度和偏航角速率。动作序列 τ^a 通过车辆运动学积分得到状态序列 τ^s , 从而确定未来轨迹 τ ; 因此, 我们的任务本质上是要预测动作序列 τ^a 。

用户指令 I 指明了期望的风险交互模式以生成 (例如, “对抗性车辆切入导致追尾碰撞”), 这可能包括目标参与者、

交互方式以及预期的风险结果。给定输入 (M, x, I) , 我们旨在生成满足两个要求的未来轨迹 τ : 1) 可控性: 生成的交互过程与用户指令描述一致, 其中对抗性车辆以用户指定的方式与主车碰撞; 2) 真实性: 生成轨迹的运动学特征尽可能统计地接近真实驾驶数据分布, 同时避免不合理行为。因此, 我们将问题表述为

学习条件生成模型

$$\tau \sim P_\theta(\tau | M, x, I) \quad (1)$$

用于直接生成基于地图 M 、历史观测 x 和自然语言指令 I 的多车辆未来联合轨迹 τ , 从而生成具有可控性和真实性的安全关键交互场景。

B. 第一阶段: 基于LLM的场景部署

本节描述了第一阶段 (基于LLM的场景展开) 的闭环生成过程。如图2所示, 生成过程以固定长度的帧窗口作为规划步骤进行迭代。在每个规划步骤中, 基于LLM的驾驶代理读取全局状态, 并在推理当前情况后, 输出该步骤的计划, 包括驾驶意图以及 ego 车辆和对抗性车辆对应的每帧控制命令。为了方便直接车辆控制, 我们将每帧的控制命令统一表示为 (a_x, a_y) , 分别代表横向加速度和纵向加速度。随后, 命令被发送到基于LLM的计划评估器进行快速审查, 重点关注“是否推进目标”和“是否违反规则约束”。如果通过, 命令被执行以更新场景, 并将规划决策写入计划内存; 如果未通过, 则返回基于LLM的驾驶代理进行计划修订。该闭环通过时间步长迭代, 直到目标达成或达到最大模拟步数。具体而言, 该模块包含三个子模块:

1) 全局状态构造器: 全局状态构造器为基于LLM的驱动代理提供决策所需的全局信息, 包含三个部分: 用户指令、场景状态和规划记忆。用户指令是用户对期望的

场景, 例如“对抗性车辆变道切入 ego 车辆前方导致追尾”。场景状态描绘了当前的交通状况, 包括 ego 车辆、对抗性车辆和一定范围内背景车辆的位置、航向角、速度、尺寸和类型, 以及道路几何信息 (如车道中心线、道路边界和相邻车道拓扑); 还提供了场景截图以增强LLM对空间关系的理解。计划内存记录闭环迭代期间已执行的规划步骤的摘要, 包括每个步骤的驾驶意图、每帧控制命令和执行轨迹, 作为后续推理的参考。

2) 基于LLM的驾驶代理: 基于LLM的驾驶代理在提示约束下读取全局状态并生成驾驶决策。LLM推理效果显著受提示设计 [41], [42]影响; 为提高推理稳定性, 我们设计了分层CoT提示, 通过“情境分析—意图规划—行动输出”工作流引导每一步规划。情境分析层评估自我车辆与对抗车辆之间的相对位置和速度关系, 以及与背景车辆和车道边界的空间约束, 从而限制可行行动空间并避免边界越界和非目标碰撞。意图规划层根据用户指令和当前状态为自我车辆和对抗车辆生成高级驾驶意图。例如, 对于指令“对抗车辆变道插入自我车辆前方导致追尾”, 如果对抗车辆已进入变道过程, 该层要求其继续完成切入并在切入后适当减速以促进追尾, 而自我车辆保持原速。行动输出层

输出遵循模板, 为自身和对抗车辆生成驾驶意图和逐帧控制序列, 每个帧作为 (a_x, a_y) , 约束值范围以避免极端行为。

3) 基于LLM的规划评估器: 用于审查基于LLM的驾驶代理的输出。它通过车辆运动学将逐帧控制集成到短期轨迹中, 背景车辆遵循原始数据集轨迹, 并从两个方面进行评估: 目标推进 (交互是否符合指令) 和约束满足 (是否发生边界违规、是否与背景车辆发生碰撞、控制幅度是否可行)。如果评估通过, 则控制将在模拟环境中执行以更新场景状态, 并将该规划步骤的驾驶意图和逐帧控制写入规划内存; 如果未通过, 则返回结构化的失败原因, 驱动基于LLM的驾驶代理重新生成, 直到通过或达到最大重试次数。

(是否发生边界违规、是否与背景车辆发生碰撞、控制幅度是否可行)。如果评估通过, 则控制将在模拟环境中执行以更新场景状态, 并将该规划步骤的驾驶意图和逐帧控制写入规划内存; 如果未通过, 则返回结构化的失败原因, 驱动基于LLM的驾驶代理重新生成, 直到通过或达到最大重试次数。

通过多次闭环迭代, 第一阶段可以

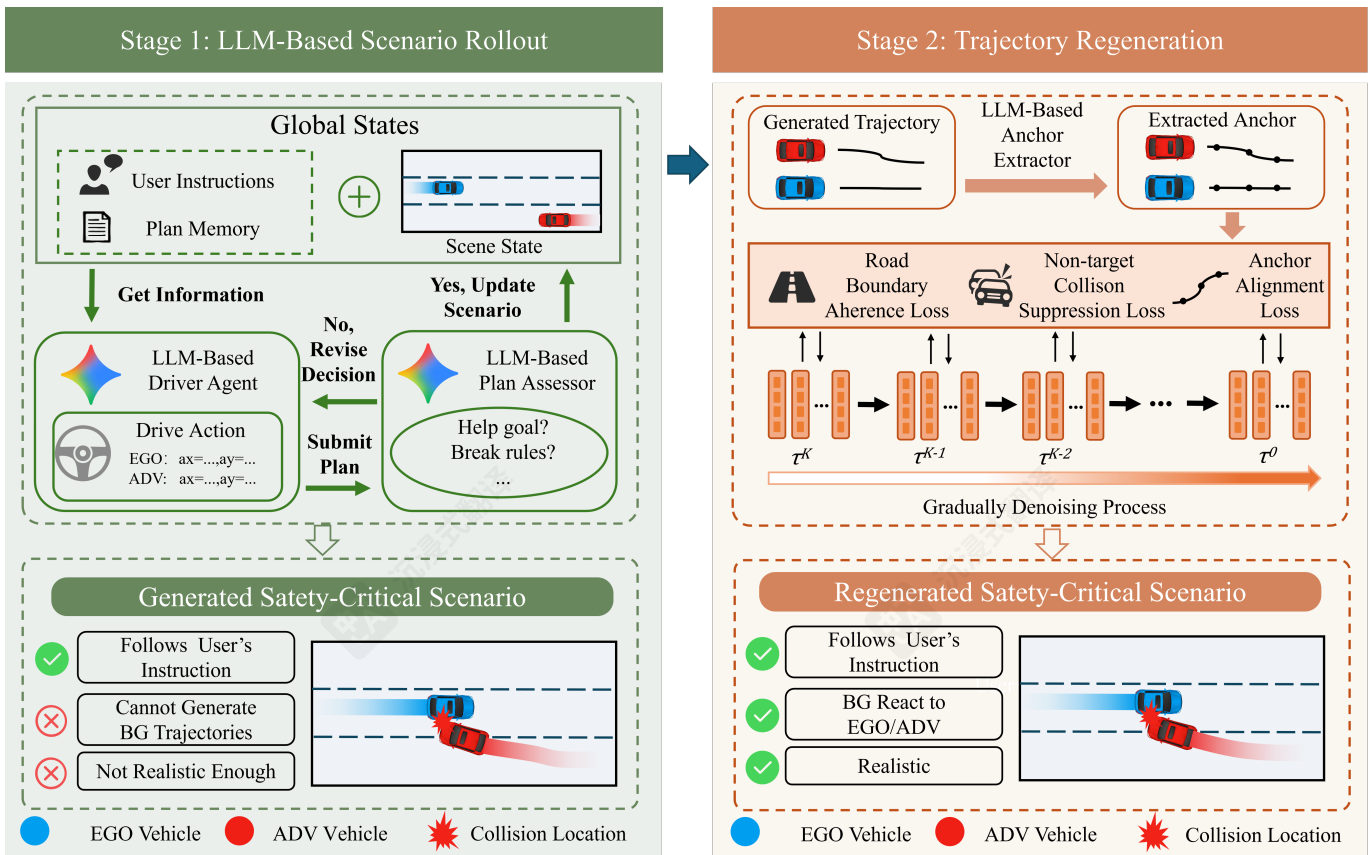


图 2. AnchorDrive 框架的整体架构。该框架采用两阶段生成：第一阶段在自然语言指令约束下以闭环方式生成满足用户指令的安全关键场景；第二阶段从第一阶段轨迹中提取稀疏的关键锚点集，并结合其他约束共同指导扩散模型的去噪过程，以重新生成完整轨迹，在保留场景语义的同时提高多车轨迹的真实性。

生成符合用户指令的安全关键场景；然而，其输出仍存在两个限制：首先，背景车辆缺乏交互响应——这一阶段仅规划主车和对抗车辆，其他背景车辆遵循原始数据集轨迹且无法响应主车行为；其次，轨迹真实性不足——LLM按帧加速度输出控制指令，易引入速度和加速度不连续等非自然运动，且关键运动学指标的概率分布也与原始数据集差异显著。

C. 第二阶段：为生成场景优化而进行的扩散模型轨迹再生

为优化第一阶段生成的场景，我们设计了一种基于扩散模型的场景优化机制，该机制利用扩散模型重新生成第一阶段的轨迹，以提高场景的真实性。如图2所示，第二阶段包含两个子模块：基于LLM的锚点提取器和锚点引导的扩散轨迹再生模块。基于LLM的锚点提取器对第一阶段的轨迹进行语义和运动学分析，提取关键锚点作为保留场景语义的约束。锚点引导的扩散轨迹再生模块将锚点对齐、道路边界遵循和非目标碰撞抑制作为三个指导目标整合到损失函数中，在去噪过程中对扩散模型应用梯度引导，使再生轨迹更加真实，同时保持关键交互结构。

在去噪过程中对扩散模型应用梯度引导，使再生轨迹更加真实，同时保持关键交互结构。

1) 基于LLM的锚点提取器：锚点作为连接两个阶段的关键桥梁。第一阶段轨迹包含逐帧状态信息；如果所有帧都作为扩散模型的指导目标，则会显著压缩可调自由度，阻止模型利用其在细节精炼和分布拟合方面的优势；同时也会限制不合理行为的修正——例如，一旦轨迹出现边界违规，逐帧指导将迫使再生结果遵循原始偏差，使有效修正变得困难。因此，我们设计了一个基于LLM的锚点提取器，从完整轨迹（如意图启动、交互发生、碰撞发生等）中识别并提取适当数量的关键锚点，仅在关键时刻进行指导，而将其他时刻留给扩散模型完成和精炼，从而在保留交互语义的同时提高轨迹真实性。

锚点提取器接收第一阶段的完整记录输出，包括驾驶意图描述和每个规划步骤的逐帧控制命令

以及相应的轨迹。通过提示引导, LLM 分析轨迹, 识别自我车辆和对抗车辆行为的关键阶段, 并选择代表性时空位置 (x, y, t) 作为每个阶段锚点。锚点无需完全复制原始轨迹的精确坐标; 为获得更好的生成结果, 允许进行适当调整。

由于安全关键场景涉及对抗车辆攻击自车, 因此对于对抗车辆, 我们进一步在锚点处附加简短说明, 描述该锚点处的行为阶段或意图节点。同时, 为了保持两车交互的时间一致性, 我们在自车轨迹中同步设置相同帧编号的对应锚点, 而无需语义解释。

2) 锚点与规则一致性联合引导扩散轨迹再生: 为了在保留第一阶段场景语义的同时使轨迹更真实, 我们提出了一种用于优化已生成场景的多目标引导扩散模型轨迹再生策略。该策略使用 LLM 提取的关键锚点作为主要引导目标, 并将道路边界遵循和非目标碰撞抑制统一为可组合的引导损失函数, 在每次去噪步骤对清洁轨迹估计应用梯度校正, 以稳定实现语义保留和真实性提升。

碰撞抑制集成到可组合引导损失函数中, 在干净轨迹估计上应用梯度校正

每个去噪步骤对清洁轨迹估计应用梯度校正, 以稳定实现语义保留和真实性提升。

具体来说, 遵循 [43], 我们的扩散模型直接预测动作序列 τ^a , 而状态序列 τ^s 可以从初始状态 s_t 和动力学模型 f 推导出。扩散模型通过逆转一个逐渐去噪的过程生成轨迹。给定从数据分布 $q(\tau_0)$ 采样的真实轨迹 τ_0 , 正向去噪过程会产生一系列越来越嘈杂的轨迹 $(\tau_1, \tau_2, \dots, \tau_K)$ 。第 k 步轨迹 τ_k 是通过向 τ_{k-1} 添加高斯噪声获得的, 其参数由预定义的方差调度 β_k 指定:

$$Kq(\tau_{1:K}|\tau_0) := \prod_{k=1} q(\tau_k|\tau_{k-1}) \quad (2)$$

$$q(\tau_k|\tau_{k-1}) := \mathcal{N}(\tau_k; \sqrt{1 - \beta_k}\tau_{k-1}, \beta_k I) \quad (3)$$

噪声过程逐渐破坏数据, 使得最终 $q(\tau_K)$ 趋近于 $\mathcal{N}(\tau_K; 0, I)$ 。轨迹生成是通过学习噪声过程的逆过程实现的: 给定噪声轨迹 τ_K , 模型通过一系列逆向步骤将其去噪回 τ_0 。每个逆向步骤被建模为:

$$p_\theta(\tau_{k-1}|\tau_k, c) := \mathcal{N}(\tau_{k-1}; \mu_\theta(\tau_k, k, c), \Sigma_k) \quad (4)$$

其中 c 是条件信息, 包括地图道路结构 M 和所有车辆历史轨迹 x , 而 Σ_k 使用预设的方差调度。具体来说, 我们采用噪声预测参数化方法, 结合网络输出 $\hat{\epsilon}_\theta = \epsilon_\theta(\tau_k, k, c)$, 并使用正向过程中的闭式关系从 τ_k 恢复干净轨迹, 得到当前步的 $\hat{\tau}_0$ 估计:

$$\hat{\tau}_0 = \frac{\tau_k - \sqrt{1 - \bar{\alpha}_k}\hat{\epsilon}_\theta}{\sqrt{\bar{\alpha}_k}} \quad (5)$$

其中 $\bar{\alpha}_k$ 是 DDPM 预定义参数。随后, 我们根据 DDPM 后验均值公式将 $\hat{\tau}_0$ 与 τ_k 融合, 计算反向步长均值:

$$\mu_\theta(\tau_k, k, c) = \frac{\sqrt{\bar{\alpha}_{k-1}}\beta_k}{1 - \bar{\alpha}_k} \hat{\tau}_0 + \frac{\sqrt{\alpha_k}(1 - \bar{\alpha}_{k-1})}{1 - \bar{\alpha}_k} \tau_k \quad (6)$$

并在高斯分布中采样 τ_{k-1} ; 重复此迭代即可得到最终的生成轨迹 τ_0 。

虽然扩散先验单独可以生成逼真的行为, 但它们无法满足用户指令。因此, 我们采用在 [44], [45] 中提出的重建指导方法来指导扩散模型的每个去噪步骤: 在 k -步逆向去噪时, 扩散模型首先从当前噪声样本中重建对应的干净轨迹估计 $\hat{\tau}_0$ 。随后, 我们在干净轨迹估计 $\hat{\tau}_0$ 上计算损失函数 J 的梯度, 并沿梯度方向对 $\hat{\tau}_0$ 进行微小修正:

$$\tilde{\tau}_0 = \hat{\tau}_0 - \alpha \Sigma_k \nabla_{\tau_k} J(\hat{\tau}_0) \quad (7)$$

α 在哪里是指导力量, 控制施加的指导幅度。这种策略稳定地将指导目标信息注入每个去噪步骤中, 使校正的 $\tilde{\tau}_0$ 更倾向于满足指导目标, 从而使生成的轨迹 τ_0 能更好地满足各种指导目标。

具体来说, 我们将指导目标写成可组合的加权损失函数:

$$J(\tau) = \lambda_{\text{anchor}} J_{\text{anchor}} + \lambda_{\text{avoid}} J_{\text{avoid}} + \lambda_{\text{boundary}} J_{\text{boundary}} \quad (8)$$

其中 λ_{anchor} 、 λ_{avoid} 、 $\lambda_{\text{boundary}}$ 控制每个指导目标的相对强度。这三个损失项对应于: 关键语义锚点对齐、非目标碰撞抑制和道路边界遵循损失。

a) 锚点对齐损失 J_{anchor} : 为保留在第一阶段确定的临界交互结构, 形式上, 锚点提取器将第一阶段记录 R 映射到锚点集 A , 记为 $A = E_{\text{LLM}}(R)$, 其中 A 可以表示为 $A = \{(p_i, t_i)\}_{i=1}^{N_a}$, 其中 $p_i = (x_i, y_i)$ 。扩散模型清洁轨迹估计 $\hat{\tau}_0$ 在时间 t_i 的位置为 $p(t_i) = (x(t_i), y(t_i))$, 然后

$$J_{\text{anchor}} = \sum_{i=1}^{N_a} \|p(t_i) - p_i\|_2^2 \quad (9)$$

where N_a 是总锚点数量。该术语鼓励车辆在时间 t_i 时到达相应的锚点位置, 从而保持关键交互语义一致性。

b) 非目标碰撞抑制

损失 J_{avoid}

在安全关键场景中, 我们希望仅保留预期的目标碰撞对, 即自车与对抗性车辆发生碰撞, 而非目标车辆对则应保持安全距离。让车辆 i 和 j 在时间 t 的边界框间隙为

t 为 $d_{ij}(t)$, 安全距离阈值设为 d_{safe} , 并记为需要引导的一组车辆对 B , 包含多对

Algorithm 1 Stage-2 Anchor-conditioned Multi-objective Guided Denoising

Input: $K, B, \alpha, R, M, \epsilon_\theta, E_{LLM}, \{\beta_k, \Sigma_k\}, (\lambda_{\text{anchor}}, \lambda_{\text{avoid}}, \lambda_{\text{boundary}})$

Output: τ_0

```

1:  $A \leftarrow E_{LLM}(R)$ 
2:  $\tau_K \sim \mathcal{N}(0, I)$ 
3: for  $k = K$  down to 1 do
4:    $\hat{\epsilon}_\theta \leftarrow \epsilon_\theta(\tau_k, k, c)$ 
5:    $\hat{\tau}_0 \leftarrow \frac{1}{\sqrt{\alpha_k}}(\tau_k - \sqrt{1 - \alpha_k}\hat{\epsilon}_\theta)$ 
6:    $J_{\text{anchor}} \leftarrow J_{\text{anchor}}(\hat{\tau}_0; A)$ 
7:    $J_{\text{avoid}} \leftarrow J_{\text{avoid}}(\hat{\tau}_0; B)$ 
8:    $J_{\text{boundary}} \leftarrow J_{\text{boundary}}(\hat{\tau}_0; M)$ 
9:    $J \leftarrow \lambda_{\text{anchor}}J_{\text{anchor}} + \lambda_{\text{avoid}}J_{\text{avoid}} + \lambda_{\text{boundary}}J_{\text{boundary}}$ 
10:   $\tau_{k-1} \leftarrow \hat{\tau}_0 - \alpha\Sigma_k\nabla_{\tau_k}J(\hat{\tau}_0)$ 
11: end for
12: return  $\tau_0$ 

```

自车-背景、对抗性车辆-背景以及背景-背景车辆。损失函数为:

$$J_{\text{avoid}} = \sum_{t=1}^T \sum_{(i,j) \in B} \max(0, d_{\text{safe}} - d_{ij}(t)) \cdot \exp\left(\frac{d_{\text{safe}} - d_{ij}(t)}{\sigma}\right) \quad (10)$$

其中 σ 是惩罚强度参数。当车辆间距离低于安全阈值时, 该项随穿透深度迅速增加, 有效抑制非目标碰撞。

c) 道路边界遵循损失 J_{boundary} : 用于防止车辆进入非可行行驶区域。由于 highD 是一个高速公路数据集, 主要的非可行行驶区域体现在横向边界约束中, 因此我们仅对车辆的横向位置应用边界惩罚。设车辆 i 在时间 t 的横向坐标为 $y_i(t)$ 。我们定义每个车辆 i 对应的横向可行行驶区间 $[y_{\text{lower}}^{(i)}, y_{\text{upper}}^{(i)}]$ 并引入安全裕度 δ_{boundary} 。当车辆接近或超出其可行行驶边界时, 损失会增加, 定义为:

$$J_{\text{boundary}} = \sum_i \sum_{t=1}^T \left[\max(0, y_i(t) - y_{\text{upper}}^{(i)} - \delta_{\text{boundary}}) + \max(0, y_{\text{lower}}^{(i)} + \delta_{\text{boundary}} - y_i(t)) \right] \quad (11)$$

当车辆位于安全区域 $[y_{\text{lower}}^{(i)} + \delta_{\text{boundary}}, y_{\text{upper}}^{(i)} - \delta_{\text{boundary}}]$; 内时, 此项为零。一旦车辆超出该范围, 惩罚随偏差线性增长, 促使车辆保持在可行行驶区域内。

根据上述锚点与规则一致性联合指导, 我们总结 Stage-2 去噪再生过程于算法1:

通过上述多目标引导, 第二阶段生成结果在三个方面优于第一阶段: 首先, 场景语义得到保留——用户指令中描述的碰撞类型和交互逻辑得以保留; 其次, 背景车辆获得了交互响应

通过上述多目标引导, 第二阶段生成结果在三个方面优于第一阶段: 首先, 场景语义得到保留——用户指令中描述的碰撞类型和交互逻辑得以保留; 其次, 背景车辆获得交互响应能力——扩散模型从真实驾驶数据中学习多车辆交互模式, 使背景车辆能够根据自身车辆和对抗车辆的行为自适应地做出合理反应(如减速和让行), 而不仅仅是遵循原始轨迹; 第三, 轨迹平滑度得到提升——速度和加速度变化更加连续, 更接近真实驾驶行为, 运动学特征更好地匹配原始数据集分布。因此, 两个子任务最终得以完成: 首先解决可控场景生成问题, 然后解决逼真度问题。

IV. 实验

本节展示所提出的 AnchorDrive 模型的实验评估。

我们首先描述数据集、评估指标和实验设置。然后, 我们将 AnchorDrive 的性能与基线方法进行比较, 并提供结果的定量分析。此外, 我们进行消融研究以评估我们方法中关键组件的贡献。

A. 数据集

我们在 highD 数据集上进行实验。highD 是一个通过无人机航拍收集的高速自然驾驶数据集, 涵盖6个记录地点, 每段道路长度约410米; 总数据时长约16.5小时, 包含约11万个车辆轨迹, 采样频率为25 Hz。我们使用固定时间窗口提取轨迹片段用于模型训练和评估: 使用1.28秒(32帧)的过去运动数据来预测5.12秒(128帧)的未来轨迹。

B. 评估指标

为了全面评估生成场景的质量, 我们从三个方面设计了指标: 关键性、真实性和语义可控性。

关键性: 这一方面衡量生成场景的有效性。自我-对抗碰撞率量化了对于抗车辆与自我车辆发生碰撞的场景比例; 更高的值表示更强的对抗效果。

真实性: 为确保生成场景符合真实世界交通行为, 我们评估越野率、非目标碰撞率和轨迹分布一致性。自我越野率、对抗越野率和背景越野率分别衡量自我车辆、对抗车辆和背景车辆驶离道路的频率; 更低的值表示更合理的行为。非目标碰撞率包括自我-背景碰撞率、对抗-背景碰撞率和背景-背景碰撞率, 量化不同车辆组之间的碰撞频率; 更低的值表示交互更符合现实。

此外, 我们还计算了在速度和加速度统计分布上生成的和真实轨迹之间的第一阶 Wasserstein 距离 [46](WD) 来衡量




图3. AnchorDrive生成的对抗性安全关键场景。示例包括刹车追尾碰撞、超车变道碰撞、危险切入碰撞和多车协同冲突，展示了该模型生成多样化安全关键场景的能力。

生成结果与真实驾驶数据之间的一致性。具体来说，对于任何一维统计数据（速度或加速度），令真实样本集为 $\{x_i\}_{i=1}^n$ ，生成样本集为 $\{y_i\}_{i=1}^n$ ，则：

$$\hat{W}_1(P, Q) = \frac{1}{n} \sum_{i=1}^n |x_{(i)} - y_{(i)}| \quad (12)$$

其中 $x_{(i)}$ 和 $y_{(i)}$ 分别是排序后的样本值。我们将主车和对抗性车辆的速率样本合并计算速率WD，将两车的加速度样本合并计算加速度WD，并将速率WD和加速度WD的平均值作为最终指标。较小的值表示生成的轨迹在统计分布上更接近真实交通行为。

语义可控性：我们使用任务成功率来衡量场景是否满足自然语言指令中的描述目标；更高的值表示更大的语义可控性。

C. 实验设置

基线。我们将我们提出的方法与现有的基于LLM的安全关键场景生成基线方法进行了比较。具体来说，我们重新实现了并与以下两种方法进行了比较：LLMscenario [34]，它将原始完整场景和提示发送给LLM，指示LLM修改原始场景中的轨迹以获得目标危险场景；以及LD-scene [34]，它让LLM根据其场景和用户指令的理解生成损失函数，使用这些损失函数来指导训练好的扩散模型的去噪过程以获得用户指定的危险场景。这两种方法都是由我们重新实现的。

目标危险场景；以及LD-scene [20]，该场景让LLM根据其场景和用户指令的理解生成损失函数，并使用这些损失函数来指导训练好的扩散模型的去噪过程，以获得用户指定的危险场景。这两种方法均由我们重新实现。

实现细节。我们的方法在PyTorch中实现，并在NVIDIA GeForce RTX 4090 GPU上训练约8小时。轨迹扩散模型使用Adam优化器 [47]，学习率 = 0.003，并进行50步去噪训练，共训练20个epoch。第一阶段驾驶员代理使用Gemini-2.5-Pro [48]作为决策模型，每个规划步长设置为10帧；第二阶段锚提取也由Gemini-2.5-Pro执行。

D. 整体性能

如图3所示，我们的方法可以生成多样化的交通场景。该图展示了四种安全关键场景，涵盖了单车冲突和多车协同冲突模式。这四种场景的对应提示为：a) AD突然刹车导致ego追尾；b) AD试图超车ego但过早返回原车道，造成碰撞；c) AD变道进入ego车道，与ego发生碰撞；d) AD1（较低）试图从AD2（较高）前方插入，AD2未能及时减速导致快速减小间隙，

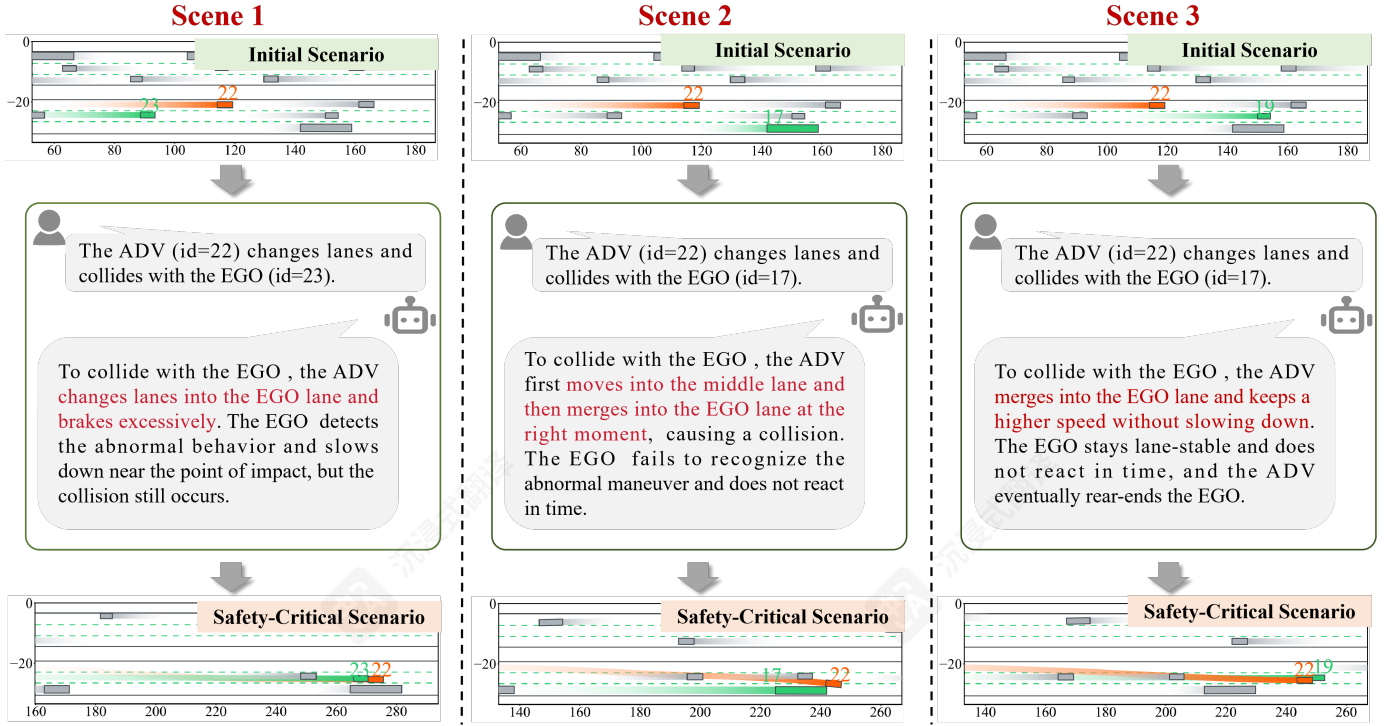


图4. 可控性研究。在相同的初始场景条件下，ADV车辆被指令攻击不同的车辆，ADV可以根据不同的目标做出不同的决策。

迫使AD1紧急变回原车道以避免被AD2追尾，最终与ego发生碰撞。

表I展示了我们的方法与基线方法的定量比较结果。总体而言，所提出的AnchorDrive在关键性、真实性和语义可控性指标上表现出更强的综合优势。具体而言，AnchorDrive的EGO-ADV Coll为0.86，高于LLM场景（0.83）和LD场景（0.69），表明我们的方法更容易触发目标对抗性碰撞；同时，AnchorDrive的任务成功率达到0.81，优于LLM场景（0.78）和LD场景（0.55），显示出更稳定的指令一致性。

关于真实性相关指标，AnchorDrive的EGO/ADV 越野是 0.02，低于 LLM场景 (0.14)和 LD-scene (0.06)；此外，AnchorDrive的EGO/ADV-BG Coll和BG-BG Coll都是0，显示整体性能更鲁棒。为了分布一致性，LD-scene 拥有最低的 Wasserstein 距离 (0.72)，而 AnchorDrive 为 1.15，优于 LLMscenario (7.64)，表明我们的方法保持了良好的轨迹分布

在保持高度一致性的同时，实现了高关键性和任务成功率。总而言之，AnchorDrive在关键性、真实性和语义可控性之间取得了更好的平衡。

E. 可控性研究

本节进一步评估了AnchorDrive对自然语言指令的响应能力。我们通过以下方法验证其语义可控性：在相同初始场景下更改提示，并观察生成的场景交互模式是否随语义变化而改变。图4展示了相应的可视化结果。

生成的场景交互模式是否随语义变化而改变。图4展示了相应的可视化结果。

如图4所示，我们通过修改提示来指定不同的目标车辆ID，从而指挥ADV车辆攻击不同的车辆。结果表明，该模型能够稳定地将“目标车辆ID”语义约束映射到生成的行为上：当目标变化时，ADV的关键决策会相应调整。

F. 消融实验

本节评估了AnchorDrive中关键组件对生成质量的影响。我们重点关注第一阶段的计划评估器决策审查机制和第二阶段的轨迹再生模块，构建了三种配置进行比较。表II总结了三种配置的定量结果。

首先，计划评估器决策审查机制显著提高了第一阶段闭环生成的稳定性和指令达成率。与没有计划评估器的配置相比，引入计划评估器将EGO-ADV碰撞率从0.85提高到0.91，任务成功率从0.72提高到0.85，同时将EGO/ADV-BG碰撞率从0.15降低到0.06，证明审查和失败反馈可以有效地抑制非目标冲突和边界违规。

另一方面，二级轨迹再生主要提升了轨迹的真实性并抑制了不合理动作。在计划评估器启用设置下移除该模块时，EGO-ADV 从 0.86 上升到 0.91，任务成功率从 0.81 上升到 0.85，生成策略倾向于更激进的方法来完成

表 I

在HIGHD数据集上与基线方法的总体性能比较。我们将我们提出的方法与LLMSCENARIO和LD-SCENE进行比较，以评估在安全关键场景生成中的关键性、真实性和语义可控性方面的总体性能。

方法	关键性	真实性					可控性
	EGO-ADV Coll ↑	EGO/ADV-BG Coll ↓	BG-BG Coll ↓	EGO/ADV Offroad ↓	BG Offroad ↓	WD ↓	任务 成功 ↑
LLM场景	0.83	0.23	/	0.14	/	7.64	0.78
LD场景	0.69	0.02	0	0.06	0.04	0.72	0.55
AnchorDrive (我们的)	0.86	0	0	0.02	0.04	1.15	0.81

表 II

关键组件的消融研究。不同模块配置的比较（计划评估决策审查和阶段-2轨迹再生）对HighD数据集安全关键场景生成性能的影响。

配置		关键性	真实性					可控性
规划评估器	轨迹再生	EGO-ADV 协作 ↑	EGO/ADV-BG Coll ↓	BG-BG Coll ↓	EGO/ADV 越野 ↓	BG 越野 ↓	WD ↓	任务 成功 ↑
×	×	0.85	0.15	/	0.07	/	2.18	0.72
✓	×	0.91	0.06	/	0.05	/	2.43	0.85
✓	✓	0.86	0	0	0.02	0.04	1.15	0.81




图5. 轨迹再生前后ADV速度分布对比。对比原始场景与不同生成配置中的对抗车辆（ADV）速度直方图，添加第二阶段轨迹再生后，速度分布更接近原始场景。

指令；然而，Wasserstein 距离从 1.15 显著增加到 2.43，EGO/ADV Offroad 从 0.02 上升到 0.05，非目标碰撞 EGO/ADV-BG 从 0.00 上升到 0.06，表明轨迹真实性降低。引入二级轨迹再生后，轨迹真实性显著提升；尽管 EGO-ADV 和任务成功率有所下降，但这为确保真实性是一个必要的权衡。图 5 比较了扩散优化前后的 ADV 车辆速度分布；优化后的分布与原始场景更一致，相应的 Wasserstein 距离更小。

上述实验验证了 Anchor-Drive 的两个关键设计：第一阶段计划评估器提高了指令执行稳定性和交互合理性，而第二阶段扩散优化显著增强了轨迹真实性。

G. 锚点引导研究

图6展示了引入基于LLM的锚点提取器在第二阶段精炼中的必要性和有效性。图的上部显示了第一阶段基于LLM的驾驶员代理直接生成的安全关键场景。可以看出，虽然该方法可以实现指令要求的交互目标，但在闭环生成过程中仍可能发生错误；例如，在图中，ADV在变道过程中纵向速度过高，未能及时应用反向加速度，导致轻微边界违规。

可以观察到，LLM提取的锚点能够总结ADV在每个阶段的关键意图，并在检测到

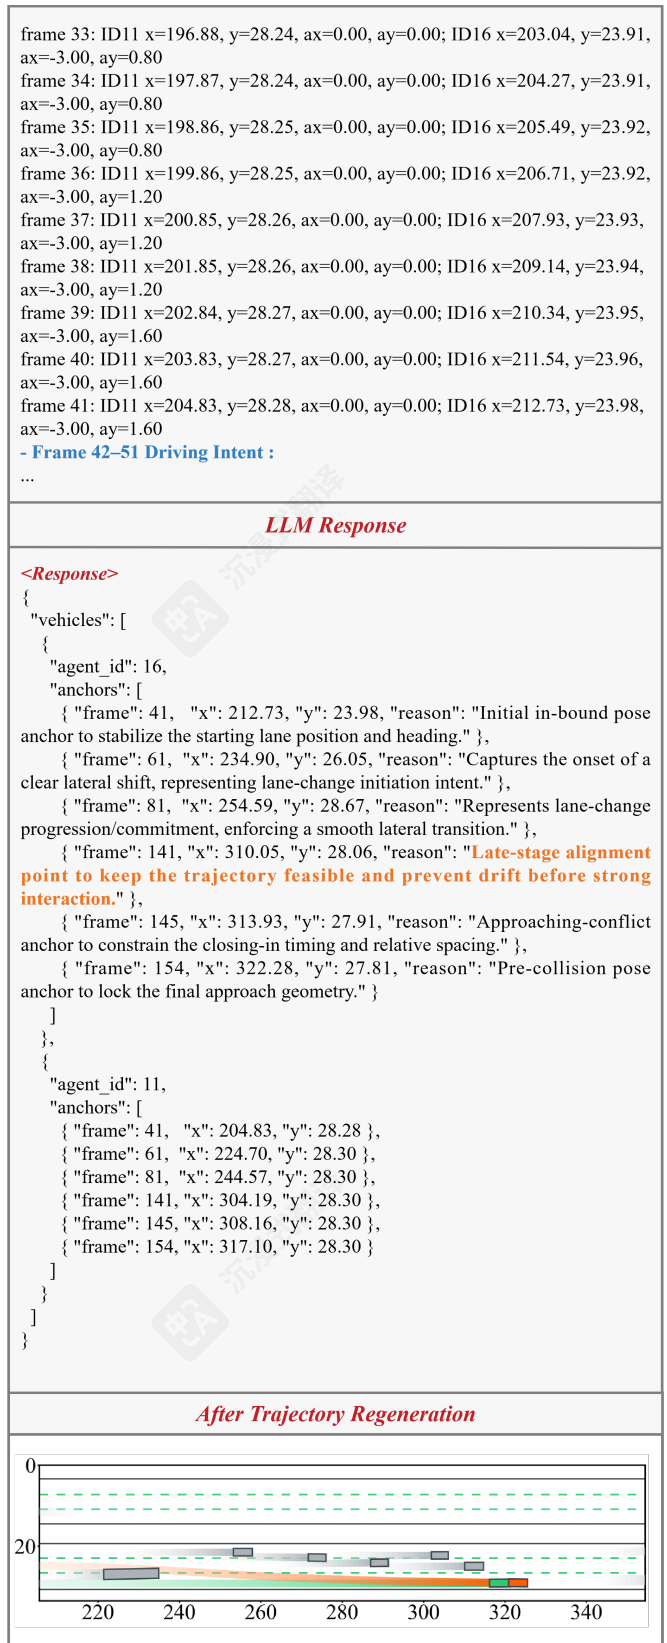
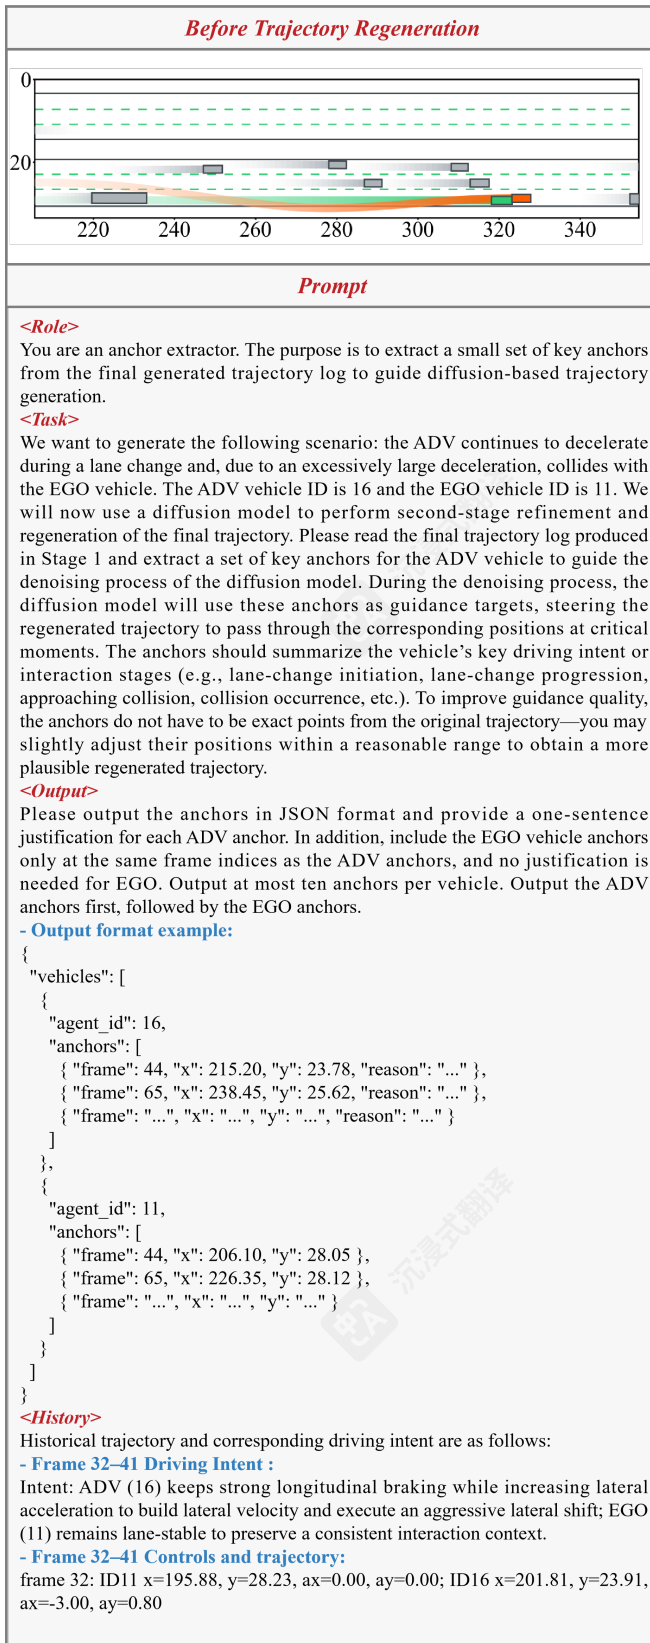


图 6. 锚点引导研究。该图展示了基于 LLM 的锚点提取器在第二阶段轨迹再生中的作用。通过基于 LLM 的锚点提取器提取锚点，扩散模型能够在保留场景语义的同时抑制边界违规和其他不合理行为。

车道变化边界违规片段时，主动跳过异常片段，在之前设置最终对齐锚点

强交互作用使车辆回到车道内合理位置。最终,在锚点引导下,扩散模型生成的轨迹既保持原始驾驶意图和交互结构,又有效抑制边界违规和其他不合理行为,提升轨迹真实性。

V. 结论

我们提出了 AnchorDrive, 一个两阶段安全关键场景生成框架, 同时实现语义可控性和轨迹真实性。第一阶段, 我们部署 LLM 作为驾驶代理, 在模拟闭环中根据用户自然语言指令约束推理场景状态, 逐步输出控制指令生成符合指令的高风险交互过程。第二阶段, 我们利用 LLM 从第一阶段轨迹中提取关键锚点, 将锚点作为主要引导目标, 联合其他引导项指导扩散模型的去噪过程进行轨迹再生, 在保留指令语义目标的同时提升生成轨迹真实性。高D数据集上的实验结果表明, AnchorDrive 框架一方面能稳定生成符合用户指令语义的安全关键场景, 另一方面使生成轨迹在统计上更接近真实数据分布, 在可控性和真实性之间取得平衡。

我们的方法仍有进一步改进的空间。未来, 我们计划开展以下工作以进一步提升框架的能力: 1) 当前实验主要在高D上进行验证; 后续工作将扩展到更复杂的城市场景数据集(如nuScenes), 以覆盖更丰富的道路拓扑结构、交通参与者类型和交互模式, 进一步检验方法的泛化能力; 2) 当前框架的场景生成速度相对较慢, 主要因为第一阶段需要多轮闭环推理和规划评估器审查迭代, 第二阶段还需额外进行扩散模型轨迹再生, 导致整体计算开销较高; 后续研究可探索提升生成效率的方法。

参考文献

- [1] Z. Jiang, J. Liu, P. Sun, M. Sang, H. Li, and Y. Pan, "Generation of risky scenarios for testing automated driving visual perception based on causal analysis," *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 11, pp. 15991–16004, 2024.
- [2] I. Argui, M. Gueriau, and S. Ainouz, "Advancements in mixed reality for autonomous vehicle testing and advanced driver assistance systems: A survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 12, pp. 19276–19294, 2024.
- [3] Y. Kang, H. Yin, and C. Berger, "Test your self-driving algorithm: An overview of publicly available driving datasets and virtual testing environments," *IEEE Transactions on Intelligent Vehicles*, vol. 4, no. 2, pp. 171–185, 2019.
- [4] W. Ding, C. Xu, M. Arief, H. Lin, B. Li, and D. Zhao, "A survey on safety-critical driving scenario generation—a methodological perspective," *IEEE Transactions on Intelligent Transportation Systems*, vol. 24, no. 7, pp. 6971–6988, 2023.
- [5] Q. Wang, D. Xu, G. Kuang, C. Lv, S. E. Li, and B. Nie, "Risk-aware vehicle trajectory prediction under safety-critical scenarios," *IEEE Transactions on Intelligent Transportation Systems*, 2025.

- [6] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, "Carla: An open urban driving simulator," in *Conference on robot learning*. PMLR, 2017, pp. 1–16.
- [7] P. A. Lopez, M. Behrisch, L. Bieker-Walz, J. Erdmann, Y.-P. Flötteröd, R. Hilbrich, L. Lücken, J. Rummel, P. Wagner, and E. Wießner, "Microscopic traffic simulation using sumo," in *2018 21st international conference on intelligent transportation systems (ITSC)*. Ieee, 2018, pp. 2575–2582.
- [8] A. A. B. da Costa, P. Irvine, X. Zhang, S. Khastgir, and P. Jennings, "Ontology-based scenario generation for automated driving systems verification and validation using rules of the road," *IEEE Transactions on Intelligent Vehicles*, 2024.
- [9] J. M. Scanlon, K. D. Kusano, T. Daniel, C. Alderson, A. Ogle, and T. Victor, "Waymo simulated driving behavior in reconstructed fatal crashes within an autonomous vehicle operating domain," *Accident Analysis & Prevention*, vol. 163, p. 106454, 2021.
- [10] C. Jiang, A. Cornman, C. Park, B. Sapp, Y. Zhou, D. Anguelov et al., "Motiondiffuser: Controllable multi-agent motion prediction using diffusion," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 9644–9653.
- [11] C. Xu, A. Petiushko, D. Zhao, and B. Li, "Diffscene: Diffusion-based safety-critical scenario generation for autonomous vehicles," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 8, 2025, pp. 8797–8805.
- [12] D. Rempe, J. Philion, L. J. Guibas, S. Fidler, and O. Litany, "Generating useful accident-prone driving scenarios via a learned traffic prior," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 17305–17315.
- [13] J. Wang, A. Pun, J. Tu, S. Manivasagam, A. Sadat, S. Casas, M. Ren, and R. Urtasun, "Advsim: Generating safety-critical scenarios for self-driving vehicles," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 9909–9918.
- [14] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat et al., "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023.
- [15] S. Bubeck, V. Chandrasekaran, R. Eldan, J. Gehrke, E. Horvitz, E. Kamar, P. Lee, Y. T. Lee, Y. Li, S. Lundberg et al., "Sparks of artificial general intelligence: Early experiments with gpt-4," *arXiv preprint arXiv:2303.12712*, 2023.
- [16] M. Chen, "Evaluating large language models trained on code," *arXiv preprint arXiv:2107.03374*, 2021.
- [17] J. Zhang, C. Xu, and B. Li, "Chatscene: Knowledge-enabled safety-critical scenario generation for autonomous vehicles," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 15459–15469.
- [18] Q. Lu, X. Wang, Y. Jiang, G. Zhao, M. Ma, and S. Feng, "Omnitester: Multimodal large language model driven scenario testing for autonomous vehicles," *Automotive Innovation*, pp. 1–15, 2025.
- [19] Z. Zhong, D. Rempe, Y. Chen, B. Ivanovic, Y. Cao, D. Xu, M. Pavone, and B. Ray, "Language-guided traffic simulation via scene-level diffusion," in *Conference on robot learning*. PMLR, 2023, pp. 144–177.
- [20] M. Peng, Y. Xie, X. Guo, R. Yao, H. Yang, and J. Ma, "Ld-scene: Llm-guided diffusion for controllable generation of adversarial safety-critical driving scenarios," *arXiv preprint arXiv:2505.11247*, 2025.
- [21] D. Fu, X. Li, L. Wen, M. Dou, P. Cai, B. Shi, and Y. Qiao, "Drive like a human: Rethinking autonomous driving with large language models," in *2024 IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*. IEEE, 2024, pp. 910–919.
- [22] X. Zhou, X. Han, F. Yang, Y. Ma, V. Tresp, and A. Knoll, "Opendrivevla: Towards end-to-end autonomous driving with large vision language action model," *arXiv preprint arXiv:2503.23463*, 2025.
- [23] Z. Zhou, T. Cai, S. Z. Zhao, Y. Zhang, Z. Huang, B. Zhou, and J. Ma, "Autovla: A vision-language-action model for end-to-end autonomous driving with adaptive reasoning and reinforcement fine-tuning," *arXiv preprint arXiv:2506.13757*, 2025.
- [24] H. Shao, Y. Hu, L. Wang, G. Song, S. L. Waslander, Y. Liu, and H. Li, "Lmdrive: Closed-loop end-to-end driving with large language models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 15120–15130.
- [25] Z. Huang, Z. Zhang, A. Vaidya, Y. Chen, C. Lv, and J. F. Fisac, "Versatile behavior diffusion for generalized traffic agent simulation," *arXiv preprint arXiv:2404.02524*, 2024.
- [26] W.-J. Chang, F. Pittaluga, M. Tomizuka, W. Zhan, and M. Chandraker, "Safe-sim: Safety-critical closed-loop traffic simulation with diffusion-controllable adversaries," in *European Conference on Computer Vision*. Springer, 2024, pp. 242–258.

- [27] C. Zhang, R. Guo, W. Zeng, Y. Xiong, B. Dai, R. Hu, M. Ren, and R. Urtasun, "Rethinking closed-loop training for autonomous driving," in *European Conference on Computer Vision*. Springer, 2022, pp. 264–282.
- [28] Y. Abeysirigoonawardena, F. Shkurti, and G. Dudek, "Generating adversarial driving scenarios in high-fidelity simulators," in *2019 International Conference on Robotics and Automation (ICRA)*. IEEE, 2019, pp. 8271–8277.
- [29] W. Ding, M. Xu, and D. Zhao, "Cmts: A conditional multiple trajectory synthesizer for generating safety-critical driving scenarios," in *2020 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2020, pp. 4314–4321.
- [30] N. Hanselmann, K. Renz, K. Chitta, A. Bhattacharyya, and A. Geiger, "King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients," in *European Conference on Computer Vision*. Springer, 2022, pp. 335–352.
- [31] W. Ding, B. Chen, M. Xu, and D. Zhao, "Learning to collide: An adaptive safety-critical scenarios generating method," in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2020, pp. 2243–2250.
- [32] M. Koren and M. J. Kochenderfer, "Efficient autonomy validation in simulation with adaptive stress testing," in *2019 IEEE Intelligent Transportation Systems Conference (ITSC)*. IEEE, 2019, pp. 4178–4183.
- [33] Y. Gao, M. Piccinini, Y. Zhang, D. Wang, K. Moller, R. Brusnicki, B. Zarrouki, A. Gambi, J. F. Totz, K. Storms *et al.*, "Foundation models in autonomous driving: A survey on scenario generation and scenario analysis," *arXiv preprint arXiv:2506.11526*, 2025.
- [34] C. Chang, S. Wang, J. Zhang, J. Ge, and L. Li, "Llmscenario: Large language model driven scenario generation," *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 54, no. 11, pp. 6581–6594, 2024.
- [35] S. Tan, B. Ivanovic, X. Weng, M. Pavone, and P. Kraehenbuehl, "Language conditioned traffic generation," *arXiv preprint arXiv:2307.07947*, 2023.
- [36] J. Mao, J. Ye, Y. Qian, M. Pavone, and Y. Wang, "A language agent for autonomous driving," *arXiv preprint arXiv:2311.10813*, 2023.
- [37] L. Wen, D. Fu, X. Li, X. Cai, T. Ma, P. Cai, M. Dou, B. Shi, L. He, and Y. Qiao, "Dilu: A knowledge-driven approach to autonomous driving with large language models," *arXiv preprint arXiv:2309.16292*, 2023.
- [38] S. Hu, Z. Fang, Z. Fang, Y. Deng, X. Chen, and Y. Fang, "Agentsco-driver: Large language model empowered collaborative driving with lifelong learning," *arXiv preprint arXiv:2404.06345*, 2024.
- [39] Y. Li, K. Katsumata, E. Javanmardi, and M. Tsukada, "Large language models for human-like autonomous driving: A survey," in *2024 IEEE 27th International Conference on Intelligent Transportation Systems (ITSC)*. IEEE, 2024, pp. 439–446.
- [40] Z. Xu, Y. Zhang, E. Xie, Z. Zhao, Y. Guo, K.-Y. K. Wong, Z. Li, and H. Zhao, "Drivegpt4: Interpretable end-to-end autonomous driving via large language model," *IEEE Robotics and Automation Letters*, 2024.
- [41] P. Liu, W. Yuan, J. Fu, Z. Jiang, H. Hayashi, and G. Neubig, "Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing," *ACM computing surveys*, vol. 55, no. 9, pp. 1–35, 2023.
- [42] P. Sahoo, A. K. Singh, S. Saha, V. Jain, S. Mondal, and A. Chadha, "A systematic survey of prompt engineering in large language models: Techniques and applications," *arXiv preprint arXiv:2402.07927*, 2024.
- [43] Z. Zhong, D. Rempe, D. Xu, Y. Chen, S. Veer, T. Che, B. Ray, and M. Pavone, "Guided conditional diffusion for controllable traffic simulation," *arXiv preprint arXiv:2210.17366*, 2022.
- [44] J. Ho, T. Salimans, A. Gritsenko, W. Chan, M. Norouzi, and D. J. Fleet, "Video diffusion models," *Advances in neural information processing systems*, vol. 35, pp. 8633–8646, 2022.
- [45] D. Rempe, Z. Luo, X. Bin Peng, Y. Yuan, K. Kitani, K. Kreis, S. Fidler, and O. Litany, "Trace and pace: Controllable pedestrian animation via guided trajectory diffusion," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 13 756–13 766.
- [46] L. Kantorovitch, "On the translocation of masses," *Management science*, vol. 5, no. 1, pp. 1–4, 1958.
- [47] D. P. Kingma, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [48] G. Comanici, E. Bieber, M. Schaeckermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen *et al.*, "Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities," *arXiv preprint arXiv:2507.06261*, 2025.