

基于碰撞模式预测的可控碰撞场景生成

陈品伦¹, 孔启熙², 张哲瀚³, 邱伟辰¹, 陈怡婷^{1,†}

摘要—评估自动驾驶汽车 (AV) 的安全性需要多样化的、安全关键场景, 其中碰撞尤为重要, 但在现实世界中收集此类场景既困难又不安全。因此, 学术界一直致力于在模拟环境中生成安全关键场景。然而, 控制碰撞类型和碰撞时间 (TTA) 等属性仍然具有挑战性。我们提出了一项新任务——可控碰撞场景生成, 目标是生成满足用户指定碰撞类型和TTA的轨迹, 以探究自动生成所需碰撞场景的可行性。为此, 我们提出了 COLLIDE, 这是一个大规模碰撞场景数据集, 通过将真实驾驶日志转换为多样化的碰撞构建而成, 并在五种代表性碰撞类型和不同TTA区间内保持平衡。我们提出了一种框架, 该框架在生成完整对抗性轨迹之前预测碰撞模式, 这是一种紧凑且可解释的表示, 能够捕获碰撞时本车和对抗车辆的空间配置。实验表明, 我们的方法在碰撞率和可控性方面均优于强基线。此外, 生成的场景始终导致更高的规划器失败率, 揭示了现有规划器的局限性。我们证明, 这些场景能够微调规划器以提升鲁棒性, 从而在不同碰撞场景中促进更安全的AV部署。更多生成的场景可在该项目网页上获取。

一、引言

评估自动驾驶汽车 (AV) 的可靠性需要在具有不同属性的各种安全关键场景中进行测试, 包括场景类别 (例如, 变道、交叉路口)、交通参与者类型和状态 (例如, 事故时间) 以及道路拓扑结构 [1]–[5]。在这些场景中, 碰撞场景尤为关键, 因为它们直接测试自动驾驶汽车在高风险条件下预测、反应和确保安全的能力。然而, 碰撞场景在统计上很少见, 并且在现实世界中测试具有固有的不安全性。因此, 社区一直专注于在模拟 [1], [6] 中生成安全关键场景, 以及控制属性以生成多样化的场景 [1]。

在这项工作中, 我们提出了一项新任务: 可控碰撞场景生成。给定目标碰撞类型和期望的事故发生时间 (TTA), 目标是生成能够实现指定碰撞的轨迹。以往的研究主要关注迫使测试车辆发生碰撞的对抗性轨迹。然而, 它们在场景的关键方面缺乏明确的可控性, 例如调整碰撞类型的粒度或改变事故发生时间。例如, 最近的进展 [v1] 可以生成易发生事故的场景, 但这些场景通常仅限于特定的事故类型, 如追尾或正面碰撞 (参见 [v2] 中的图6)。最近, 扩散模型的条件生成 [v3] 为可控碰撞场景生成开辟了新的可能性, 但现有的公式尚未解决细粒度可控性问题。这些差距促使我们研究实现可控碰撞场景生成所需的条件。

[†] 通讯作者。¹ 计算机科学系, 国立阳明交通大学, 台湾新竹市。yp201141413.en11, ychen@nycu.edu.tw² 信息、计算与工程学院, 印第安纳大学, 印第安纳州布卢明顿, 美国。kung@iu.edu³ MediaTek Inc.




图1: 给定初始场景, 用户指定条件输入, 包括碰撞类型和碰撞前时间 (TTA)。该框架预测碰撞模式, 定义为碰撞时刻 ego 车辆 (绿色汽车) 与攻击者 (红色边界框) 之间的相对配置。此预测模式随后指导轨迹规划器生成可行的攻击者运动 (红色箭头), 从而产生可控的生成场景, 如变道或左转避免碰撞 (LTAP)。

对场景的关键方面具有可控性, 例如改变碰撞类型的粒度或调整事故发生时间。例如, 最近的进展 [7], [8] 可以生成易发生事故的场景, 但这些通常仅限于特定的事故类型, 例如追尾或正面碰撞 (参见 [7] 中的图 6)。最近, 使用扩散模型的条件生成 [9], [10] 为可控碰撞场景生成开辟了新的可能性, 但现有的公式尚未解决细粒度可控性问题。这些差距促使我们研究实现可控碰撞场景生成需要什么。

为此, 我们引入了 COLLIDE, 这是一个大规模的碰撞场景数据集, 专门为可控碰撞场景生成而设计。现有的碰撞场景数据集 [11]–[17] 缺乏碰撞类型标注, 并且不提供具有不同事故发生时间 (TTA) 的场景。为了解决这个问题, 我们提出了一种自动流程, 将真实世界驾驶日志中的非碰撞轨迹转换为多样化的碰撞场景。具体来说, 我们根据美国国家公路交通安全管理局 (NHTSA) [11] 定义的事故类别, 选择目标碰撞类型。对于给定的自行车轨迹, 我们选择一个时间戳并提取相应的自行车边界框作为参考。然后, 将对抗车辆放置在所有可行的空间位置。选择满足所需碰撞类型定义 (见图1底部) 的配置。最后, 根据自行车和对抗车辆的空间配置以及指定的TTA, 我们使用五次多项式规划器生成一个合理的轨迹。该流程支持可扩展和可控的碰撞场景生成, 为相应算法的系统评估提供支持。这引发了一个问题: 如何根据碰撞类型和TTA自动生成碰撞场景?

为此,我们引入了COLLIDE,这是一个大规模的碰撞场景数据集,专门为可控碰撞场景生成而设计。现有的碰撞场景数据集 [18] 缺乏碰撞类型标注,并且不提供具有不同事故发生时间(TTA)的场景。为了解决这个问题,我们提出了一种自动流程,将真实世界驾驶日志中的非碰撞轨迹转换为多样化的碰撞场景。具体来说,我们根据美国国家公路交通安全管理局(NHTSA) [18] 定义的事故类别,选择目标碰撞类型。对于给定的自行车轨迹,我们选择一个时间戳并提取相应的自行车边界框作为参考。然后,将对抗车辆放置在所有可行的空间位置。选择满足所需碰撞类型定义(见图1底部)的配置。最后,根据自行车和对抗车辆的空间配置以及指定的TTA,我们使用五次多项式规划器生成一个合理的轨迹。该流程支持可扩展和可控的碰撞场景生成,为相应算法的系统评估提供支持。这引发了一个问题:如何根据碰撞类型和TTA自动生成碰撞场景?

我们认为,生成碰撞场景的关键在于对碰撞类型进行情境化分析。例如,车道变换碰撞会呈现出大致模式,如图1底部所示。而左转横穿路径(LTAP)碰撞则属于不同模式。一旦我们有了大致模式,就可以生成相应的合理轨迹。我们将这些模式称为碰撞模式,它编码了碰撞时刻本车和对抗车辆之间的相对位置、朝向以及角色。碰撞模式并非建模完整轨迹,而是聚焦于关键终点,为碰撞场景生成提供紧凑且可解释的表示。

我们的框架借鉴了目标检测中的区域提议网络 [19], 该网络首先估计大致位置然后进行细化。类似地,我们首先预测一个粗略的碰撞模式作为锚点,再对其进行细化以确定精确的空间配置。基于此配置,我们生成完整的对抗轨迹。这种结果驱动、由粗到精的策略能够有效生成,避免逐步预测中的误差累积,同时提升可控性和灵活性。

我们在COLLIDE数据集上开展实验,并评估条件轨迹预测基准方法,包括SGAN [20], MID [10] 和 STRIVE [7]。我们的方法始终能生成符合用户指定的事故发生时间(TTA)和碰撞类型的碰撞,实现更高的碰撞率,从而生成更合理的场景。我们还进一步在三种基于规则的运动规划器——IDM [21], (基于规则的规划器 [7],) 和PDM [22]——上评估生成的场景,发现我们的方法比C-STRIVE导致更多规划器失效,揭示了现有规划策略中的关键盲点。为了进一步评估生成的场景的影响,我们使用它们来更新AV规划器,发现我们的方法能在多种危险场景中提高碰撞率。

我们的贡献总结如下:

- 我们提出了可控碰撞场景生成,一项为全面和系统评估自动驾驶汽车安全而设计的新任务。
- 我们引入了一个自动数据收集流程,该流程考虑了碰撞类型和TTA,能够评估可控碰撞场景生成算法。

- 我们介绍了一种紧凑且可解释的表示方法 Collision Pattern, 它编码了碰撞时刻 ego 车辆和对抗车辆之间的相对位置、朝向和角色。

- 我们证明了我们的框架能够有效地生成用户指定的场景,并优于强大的基线模型。此外,生成的场景揭示了基于规则的运动规划器的局限性,并且可以用于提高其鲁棒性。

II. 相关工作

场景生成。根据 [1], 现有方法可以分为数据驱动、对抗和基于知识三类。数据驱动方法 [23]–[25] 从大规模真实世界数据集中提取稀有的碰撞事件 [26], 但这些事件在碰撞类型和紧迫性(TTA)方面都非常稀疏且高度不平衡,限制了它们在训练或评估中的价值。对抗方法 [7], [8], [27] 在学习的交通动力学模型 [28] 中扰动智能体轨迹以诱导故障,但它们通常偏向于特定的故障模式,并且缺乏对碰撞语义的显式可控性。基于知识的方法 [17], [29]–[31] 结合了基于规则的先验知识或预定义模板,以确保某些碰撞类型的覆盖范围,但它们不可扩展,因为增加类内变化需要大量的手动工作,并且无法有效地泛化。

我们的方法不属于现有的三类方法。相反,它通过从COLLIDE学习分布来连接数据驱动的现实主义,并通过碰撞模式监督来学习基于知识结构。这种方法直接解决了先前工作的局限性:通过在从真实世界日志中合成的碰撞轨迹上进行训练,我们缓解了仅使用真实世界方法面临的数据稀缺问题;通过基于结构化碰撞模式和TTA进行条件化,我们实现了知识型方法(这些方法依赖于基于规则或启发式的方法)通常无法提供的类内多样性;并通过将每个生成的结果与碰撞类型对齐,我们的设计确保了对碰撞类型的可控性,而像STRIVE [7] 和 KING [8] 这样的对抗优化方法无法保证这一点。

轨迹预测与交通仿真。由于我们的任务涉及在碰撞约束下生成未来智能体轨迹,因此它与轨迹预测最为相关,所以我们简要回顾了用于交通仿真的生成模型。早期的生成模型如Social-GAN [20] 通过学习每个智能体的过去轨迹来预测多样但合理的未来运动。TrafficSim [28] 和BITS [32] 利用地图信息作为附加输入来生成交通流。然而,这些自回归预测器通常按步生成轨迹,这往往导致在较长的时间范围内误差累积,并难以保证精确的长期结果,例如特定的碰撞类型或TTA。STRIVE [7] 基于TrafficSim通过优化潜在空间中的扰动来生成安全关键场景,

表 I: 现有碰撞相关数据集的比较。该表列出了具有代表性碰撞数据集及其主要任务、碰撞案例数量和可用属性。

数据集	Task	#碰撞	属性
YouTubeCrash [14]	碰撞预测	122	x
街道事故 [11]	碰撞预测	678	x
碰撞 [34]	碰撞检测	803	x
VIENA [35]	行为预测	1200	单一行为
CTA [15]	碰撞推理	1935	碰撞原因
NIDB [12], [13]	碰撞预测	4595	拓扑结构
GTAcrash [14]	碰撞预测	7720	x
RiskBench [17]	风险识别	1873	单一行为
HazardVLM [16]	风险描述	3860	单个行为
COLLIDE	场景生成	8586	碰撞类型 TTA

更近期, 基于扩散的预测器 [9], [10]已经展现出更强的能力来捕捉多智能体行为的多样化分布, 缓解了先前轨迹预测器中常见的模式坍塌问题。CTG++ [33] 通过大型语言模型 (LLMs) 引入了语言引导的条件生成, 用户通过提供提示来影响未来行为。然而, 这种自然语言条件仅以粗粒度的语义级别 (例如, 意图或风格) 指导智能体行为, 而不是强制执行精确的空间关系或碰撞时机。

我们的方法采用了一种自后向前、由粗到细的生成过程: 而不是逐步预测每一步, 这有累积错误和错过预期结果的风险, 我们首先预测最终碰撞模式, 该模式编码了碰撞类型和TTA。然后生成攻击者的完整轨迹, 以实现这一结果, 同时保持物理上的合理性。

碰撞数据集。现有的真实世界数据集, 如 YouTubeCrash [14], StreetAccidents [11], 和 VIENA [35], 已被广泛用于训练或评估模型在事故预警或分类任务上的性能。然而, 这些数据集从交通摄像头画面或行车记录仪中被动收集碰撞事件, 存在覆盖偏差且缺乏详细的语义标注, 例如碰撞类型和时间至事故 (TTA)。一些基于仿真的数据集, 如 RiskBench [17], SafeBench [31], 和 Target [36], 提供合成碰撞场景以覆盖更广泛的罕见事件, 但它们缺乏碰撞类型的语义标签, 仅限于单车行为而非结构化的碰撞模式。为弥补这一差距, 我们提出了 COLLIDE, 一个通过自动生成流程从真实世界日志中衍生的结构化数据集。它确保在五种 NHTSA 定义碰撞类型和 TTA 间隔上实现均衡覆盖, 并提供对场景属性的细粒度控制。如表 I 所示, COLLIDE 包含 8,586 个任务特定的碰撞案例, 与先前数据集相比, 支持可扩展的训练和评估。此外, 在现有工作中, COLLIDE 是唯一一个支持具有显式碰撞类型控制的场景生成的数据集。

III. 数据收集

本节介绍了碰撞类型的定义、数据收集方法以及场景增强。我们构建了一个名为 COLLIDE 的专用数据集, 提供大规模、均衡且具有语义基础碰撞场景, 非常适合可控场景生成。

A. 碰撞类型

我们基于NHTSA [18] 统计数据, 采用了五种具有代表性的碰撞类别, 这些类别反映了社会影响, 包括碰撞频率、受伤严重程度和经济负担。这些类别包括: (1) 十字路口穿越 (JC), (2) 车道变换, (3) 相向行驶, (4) 追尾, 以及 (5) 左转横穿路径 (LTAP)。我们使用碰撞点的相对航向角来分配类别: 追尾 ($\sim 0^\circ$), 车道变换 ($\sim 20^\circ$), 相向行驶 ($\sim 180^\circ$), 十字路口穿越 ($\sim 90^\circ$), 以及 LTAP ($\sim 90^\circ$)。应用一个 10° 容差来解释噪声。由于 JC 和 LTAP 都涉及一个 90° 碰撞角度, 我们通过进入交叉口时的相对航向来区分它们: JC 在整个过程中保持正交路径, 而 LTAP 涉及一个左转, 车辆以 180° 差异接近。

B. 数据收集

由于现有真实世界数据集中标记的碰撞场景稀缺, 我们开发了一个自动数据收集流程, 将nuScenes数据集中收集的非碰撞场景转换为合成碰撞场景。每个修改后的场景都包含我们自定义的碰撞模式, 并保持物理可行性。

原始nuScenes场景持续20秒, 频率为2Hz。我们将这些场景分割为4.5秒至9秒的片段, 并在每个0.5秒的间隔内定义一个目标碰撞点。乘用车的边界框作为参考, 用于计算攻击者的碰撞目标。例如, 在追尾场景中, 攻击者必须在碰撞时刻到达乘用车后方预定义的位置。

使用五次多项式规划器生成平滑的攻击者轨迹, 使其朝向目标位置。候选攻击者从场景中其他表现出连续运动的车辆中选取。如果生成的轨迹导致不可行性, 例如与其他智能体碰撞或离开道路, 该场景将被丢弃。这确保了生成的数据集对碰撞类型和TTA (Time-To-Act) 具有高度控制。

C. 场景覆盖范围

为确保全面覆盖安全关键案例, 我们的数据集整合了多种变化来源。碰撞几何增强。为丰富碰撞多样性, 我们在定义的对碰撞角度进行均匀采样, 以生成既多样化又语义一致的场景。

TTA增强。时间至事故 (TTA) 被定义为当前时间与自我到达碰撞点时刻之间的时间差。通过均匀采样此类碰撞点, 我们获得了分布的TTA




图2: 可控碰撞场景生成的提出架构。给定结构化场景上下文和用户指定的条件（碰撞类型和TTA），我们的模型预测“碰撞模式”，表示碰撞时刻本车和攻击车（ATT）的相对配置。预测的模式随后指导运动规划器生成可行的攻击者轨迹。

地图多样性。我们的数据集涵盖了nuScenes中的所有四个城市，这提供了多样的道路结构和驾驶规范（例如，左侧驾驶与右侧驾驶）。这种地理多样性自然地丰富了碰撞场景，包含不同地图拓扑结构，确保了交叉口布局、车道几何形状和驾驶惯例的更广泛覆盖。

车辆， $\Delta\theta$ 表示碰撞时的相对航向，而 $\hat{a}$ 指示选定的攻击者。然后使用预测的模式作为五次多项式规划器实现轨迹的目标。三个可训练模块，自我位置预测、攻击者偏移预测和攻击者选择，对编码的场景和条件特征进行操作以预测碰撞模式。

IV. 方法

A. 问题公式化

我们的目标是基于用户指定的属性（期望的碰撞类型和时间至事故发生，TTA）生成可控的碰撞场景。该任务的输入包括所有交通参与者的历史轨迹和地图拓扑。每个智能体轨迹表示为位置和航向的序列：

$s_{1:T_{\text{hist}}}^i = \{(x_i^t, y_i^t, \theta_i^t)\}_{t=1}^{T_{\text{hist}}}$ ，其中 (x_i^t, y_i^t) 表示智能体 i 在时间 t 的二维位置， θ_i^t 是其航向角。令 $\mathcal{M}$ 表示地图拓扑。给定 N 智能体 $\{s_{1:T_{\text{hist}}}^i\}_{i=1}^N$ 的历史轨迹和地图 $\mathcal{M}$ ，目标是生成攻击者轨迹 $s_{T_{\text{hist}}:t_{\text{TTA}}}^a$ ，使其与本车在 $t = t_{\text{TTA}}$ 时刻精确碰撞。生成的轨迹与用户指定的碰撞类型 $\mathbf{C}_{\text{type}}$ 和TTA确定的紧急程度一致。这种公式化强调了两个关键挑战：(1) 定位碰撞发生的位置和方式，以及(2) 实现满足指定条件的运动学可行的攻击者轨迹。

B. 框架概述

如图2所示，我们并非直接预测攻击者的完整轨迹，而是首先预测碰撞模式，这是一种紧凑且可解释的表示，描述了碰撞时刻 ego 车辆和攻击者车辆在空间中的最终配置。具体来说，我们将碰撞模式定义为一个4D向量

$\mathbf{p} = (\Delta x, \Delta y, \Delta\theta, \hat{a})$ ，其中 $(\Delta x, \Delta y)$ 表示攻击者相对于 ego 车辆的相对位置， $\mathbf{p} = (\Delta x, \Delta y, \Delta\theta, \hat{a})$ 表示它们在碰撞时的相对航向， Δx 表示选定的攻击者。预测的模式随后被用作五次多项式规划器实现轨迹的目标。三个可训练模块——ego位置预测、攻击者偏移预测和攻击者选择——在编码的场景和条件特征上运行，以预测碰撞模式。

C. 输入表示

我们采用基于VectorNet的编码器 [37]从地图拓扑和智能体轨迹中提取向量化特征，形成场景特征 $\mathbf{F}_{\text{scene}}$ 。用户指定的条件，包括碰撞类型（one-hot向量 $\mathbf{C}_{\text{type}}$ ）和归一化的TTA值，与 $\mathbf{F}_{\text{scene}}$ 连接，生成最终特征：

$\mathbf{F}_{\text{final}} = [\mathbf{F}_{\text{scene}}, \mathbf{C}_{\text{type}}, \text{TTA}]$ 。该最终特征作为所有后续模块的输入。

D. 碰撞模式预测

a) 自车位置预测：我们将预期碰撞点定位为区域提议任务。候选锚点 $\{T_i\}$ 沿车道中心线采样，并根据其与真实碰撞点 $x_{\text{ego}, \text{GT}}$ 的距离（半径为 r ）分类为正或负：

$$\text{label}(T_i) = \begin{cases} \text{positive}, & \|T_i - x_{\text{ego}, \text{GT}}\| \leq r, \\ \text{negative}, & \text{otherwise.} \end{cases}$$

每个候选锚点 T_i 都由一个特征向量表示，该向量包含其自身的空间属性 (x, y, θ) 以及拼接的局部地图 T_i 。对于排名最高的候选，航向和偏移回归生成最终的 ego 边界框 $\mathbf{B}_{\text{ego}}(t_{\text{TTA}})$ 。局部特征设计使模型能够利用更丰富的局部几何信息，以实现更可靠的排序。

表 II: 在 COLLIDE 上可控碰撞场景生成的结果。我们的方法在五种碰撞类型中实现了最高的碰撞率和相似度, 优于条件基线模型。

方法	指标	变道	对向	追尾	交叉路口	LTAP	平均
C-SGAN [20]	碰撞率	20%	20%	18%	9%	0%	14%
C-STRIVE [7]		32%	21%	39%	16%	15%	25%
C-MID [10]		25%	10%	9%	5%	10%	11%
Ours		73%	77%	84%	81%	90%	81%
C-SGAN	相似度	34%	33%	68%	0%	0%	39%
C-STRIVE		52%	75%	93%	52%	18%	68%
C-MID		42%	68%	74%	33%	22%	49%
Ours		62%	90%	87%	84%	76%	81%

b) 攻击者偏移预测: 给定 B_{ego} 和 F_{final} , 模型预测一个相对偏移量来确定广告边界框:

$$\mathbf{B}_{attacker} = \mathbf{B}_{ego} + (\Delta x, \Delta y, \Delta \theta).$$

这确保了可控的几何关系, 与目标碰撞类型一致。

c) 攻击者选择: 对于每个候选代理 i , 其当前状态 P_i 与 F_{final} 连接, 并通过一个 MLP 使用 softmax 进行评分。MLP 使用 softmax 进行评分。选中的攻击者是

$$\hat{a} = \arg \max_i \text{MLP}([P_i, F_{final}]).$$

E. 轨迹实现

给定预测的碰撞模式, 该模式指定了在 $t = T_{TTA}$ 时刻 ego 和攻击者之间的相对空间配置, 我们采用五次多项式规划器来实现平滑且运动学可行的攻击者轨迹。碰撞模式作为轨迹生成的边界条件: 攻击者必须从其观测到的历史 $s_{1:T_{hist}}^a$ 开始, 并在指定的 TTA 时刻精确到达配置 $\mathbf{B}_{attacker}$ 。形式上, 轨迹表示为

$$s_{T_{hist}:T_{TTA}}^a = \mathcal{P}(s_{T_{hist}}^a, \mathbf{B}_{attacker}, T_{TTA}),$$

其中 $\mathcal{P}$ 表示多项式规划器。这种构造保证了物理可行性, 同时确保轨迹忠实地实现了用户指定的碰撞类型和时间。

V. 实验结果

A. 基线和评估设置

我们将我们的方法与三种条件场景生成基线进行了比较, 分别是C-SGAN、C-MID和C-STRIVE, 它们分别使用 Social-GAN [20], MID [10], 和 STRIVE 的交通动态模型实现。对于所有基线, 碰撞类型的 one-hot 向量和标准化的事故时间 (TTA) 被连接作为解码器的条件输入。为了确保公平的比较, 基线通过应用开环自回归扩展到相同的预测范围: 每次迭代预测4帧, 并将它们附加到下一步的输入序列中。我们的方法使用相同的历史输入直接预测紧凑的碰撞模式, 即自我和攻击者的终端空间配置

。然后, 五次多项式规划器生成完整的攻击者轨迹, 以在所需的TTA时满足预测的模式。这种生成策略上的差异 (模式预测 + 规划器与自回归滚动) 在评估中明确考虑, 通过为所有方法强制执行相同的输入范围和最终预测范围来实现。

我们不与基于脚本或基于对抗的情景生成方法进行比较, 因为它们依赖于预定义的攻击者脚本或在模拟环境中进行的代理级对抗优化。这些方法旨在探索可能的崩溃, 但它们不直接适用于如 COLLIDE 之类的离线驾驶日志, 并且它们无法提供对碰撞类型或 TTA 的明确可控性。相反, 我们采用条件轨迹预测模型作为基线, 因为它们自然地在已记录数据上运行, 并且可以扩展以支持基于碰撞属性的生成条件。

B. 评估指标

为了评估可控情景生成, 我们定义了两个关键指标:

- 碰撞率: 修改后的攻击者轨迹与自身车辆发生碰撞的百分比。
- 场景相似度: 在发生碰撞的情况下, 自我车辆与攻击者之间的相对角度与期望的碰撞类型匹配的百分比, 允许在10度公差范围内。

C. 实施与训练细节

三个模块, 自我位置预测、攻击者偏移预测和攻击者选择, 使用从 COLLIDE 中提取的真实碰撞模式监督, 以端到端的方式联合训练。完整的训练损失定义为自我位置预测损失、攻击者偏移回归损失和攻击者选择分类损失的加权总和。我们使用 Adam 优化器, 学习率为 5×10^{-5} , 批量大小为128, 训练网络1000个epoch。在单个GPU上, 整体推理延迟约为每场景0.37 ms, 包括碰撞模式预测和多项式轨迹实现。




图3: 不同碰撞类型下生成场景的定性比较。我们将我们的数据集和模型与C-STRIVE [7], (当前最强的基线) 进行比较。我们的模型在生成用户指定碰撞类型方面表现出强大的可控性。

表III: 自我位置预测模块的消融研究。我们评估了不同方法在碰撞时刻预测自我车辆位置的效果, 比较了基于回归的预测、目标点排序和区域提议。

设置	位移误差 (米)	角度距离 (°)	碰撞率	相似度
基于回归	3.95	16	69%	67%
目标点排序	2.15	11.4	80%	74%
区域提议	3.1	10.18	77%	78%

D. 条件碰撞场景生成的结果

表II显示, 与条件基线相比, 我们的方法在五种碰撞类型中始终实现更高的碰撞率和场景相似度。生成的场景不仅导致更多碰撞, 而且更好地匹配了由碰撞前时间 (TTA) 和碰撞类型指定的预期碰撞模式。图3突出了基线的常见失败案例。例如, 在相反方向示例中, C-STRIVE [7] 预测了U型转弯行为, 而不是侵入自我车道, 导致与真实轨迹的高偏差。同样, 在追尾场景中, C-STRIVE [7] 未能捕捉到在自我车前方急减速的超车攻击者, 而是默认为良性前进驾驶行为。相比之下, C-STRIVE [7] 在两种车辆都在车道中行驶的常见场景中表现良好。

相同方向。这个限制是因为 C-STRIVE 缺乏细粒度的碰撞类型指导, 因此倾向于过拟合数据集中占主导地位且更安全的行為。通过将碰撞模式作为显式的中间目标引入, 我们的方法克服了这种偏差, 并可靠地生成与指定碰撞类型和 TTA 一致的危险但未充分表示的事件。

E. 自我边界框预测的消融研究

我们研究了三种定位自我碰撞终点的策略, 这是形成碰撞模式的关键步骤。基于回归的方法直接预测 (x, y, θ) 中的偏移量, 但通常会产生不精确的目标。目标点排序 [38] 通过在中心线上选择候选锚点来提高位置精度, 但可能仍与车道拓扑不一致。我们的区域提议设计进一步将局部子图特征附加到锚点上, 强调符合车道方向。

表III显示, 回归产生最大的误差, 排序减少位移但缺乏角度精度, 而区域提议与真实模式具有最佳相似性。由于我们的任务优先考虑碰撞模式的语义一致性而非原始碰撞频率, 我们在最终框架中采用了区域提议变体。

虽然目标排序策略能更好地预测碰撞是否会发生, 但区域提议方法更忠实地捕捉了碰撞是如何发生的。由于我们的目标是生成符合特定类型的可控场景,

表IV：对自动驾驶车辆规划器的生成场景评估。我们报告了C-STRIVE和我们的方法在五种碰撞类型上的碰撞率，并在不同的规划器上进行了测试。更高的碰撞率表明在暴露规划器失效案例方面效果更强。

规划器	算法	变道	对向	追尾	交叉口	LTAP	平均
IDM [21]	C-STRIVE Ours	17% 16%	11% 30%	58% 65%	9% 20%	4% 6%	21% 29%
基于规则的 [7]	C-STRIVE Ours	23% 31%	24% 52%	40% 18%	13% 28%	23% 22%	25% 30%
PDM [22]	C-STRIVE Ours	12% 19%	12% 37%	67% 76%	11% 18%	11% 39%	24% 39%

因此我们优先考虑语义一致性和模式保真度，而非仅仅是碰撞频率。为此，我们在最终模型中采用了区域提议变体。

F. 安全关键场景下的规划器评估

为了评估我们生成的场景的实际影响，我们评估了三个规划器：IDM [21], 基于规则的STRIVE [7] 规划器和来自nuPlan 2023规划挑战的PDM [22] 规划器，这些场景由我们的方法和C-STRIVE生成。如表IV所示，我们的场景在所有场景类型和规划器中始终导致更高的碰撞率。

IDM和STRIVE基于规则的规划器都依赖于原始自我轨迹作为参考路径。IDM规划器将攻击者视为领先车辆，并遵循保守的跟车策略，通常导致早期制动，从而降低碰撞率。相比之下，STRIVE基于规则的规划器应用简单的制动-加速规则来微调重播速度，产生的行为与原始碰撞场景更相似。PDM规划器使用车道中心线作为参考路径，在横向和纵向方向上生成候选动作，并使用内部评分函数评估它们。为了评估潜在的碰撞，它模拟了周围车辆的未来运动，假设每个车辆继续以当前速度行驶，而不是依赖于学习到的轨迹预测器。这种对前方代理推理的不确定性导致更高的碰撞率。

实验结果证实，我们的方法能产生更多对抗性场景，即使在运动规划设置下也能持续触发规划器失败。

G. 使用生成的场景改进规划器

规划器优化过程。为展示我们生成的碰撞场景的实用性，我们在C-STRIVE生成的场景和我们的方法（表V）生成的场景下，通过网格搜索对PDM规划器 [22] 进行参数优化。规划器通过横向移动主车的中心线参考路径来构建候选轨迹，模拟避让动作，并将每个移动后的路径与不同的速度尺度组合，模拟不同程度的减速。每个候选轨迹使用IDM策略进行评估，并选择得分最高的轨迹。

表V：规划器的参数调优结果。我们通过不同方法生成的场景来调整PDM的策略参数，以评估碰撞率。

参数	LC	OD	RE	JC	LTAP
默认值	8.1%	43.4%	72.6%	14.9%	27.8%
C-STRIVE的	8.7%	39.4%	70.3%	12.9%	20.9%
Ours	8.7%	40.0%	70.4%	12.5%	20.8%

根据评分函数。我们调整IDM参数（例如，最小期望距离，最大加速度）和评分权重（例如，进度和时序权重）。

结果。C-STRIVE倾向于产生过于激进的攻击行为，通常导致在指定TTA之前就发生碰撞。这促使PDM规划器更频繁地改变车道，这在相反方向（OD）和追尾（RE）等场景中是有利的，因为这些场景中避碰只能通过横向机动来实现。这些结果表明，不同的场景生成方法暴露了不同的规划器失效模式，强调了需要更广泛和可控的测试场景集来全面评估规划器的鲁棒性和泛化能力。项目网页上提供了使用生成的场景对规划器行为进行定性可视化的结果。

第六节 结论与未来工作

我们提出可控碰撞场景生成作为系统化自动驾驶安全评估的新任务。为此，我们构建了COLLIDE，这是首个平衡覆盖碰撞类型和事故发生时间（TTA）的数据集。我们进一步引入了碰撞模式的概念，并设计了一个基于区域提议的框架，能够对碰撞结果进行细粒度控制。实验表明，我们的方法在可控性和合理性方面优于强基线，同时揭示了规划器的局限性并提高了其鲁棒性。

致谢

这项工作由国家科学技术委员会部分资助，资助项目编号为113-2628-E-A49-022-和114-2628-E-A49-007-，由MobileDrive、国立阳明交通大学高等教育萌芽计划，以及教育部和玉山奖学金项目行政支持基金提供资助。

由国立阳明交通大学、教育部以及玉山奖学金项目行政支持基金提供资助。

参考文献

- [1] W. Ding, C. Xu, M. Arief, H. Lin, B. Li, and D. Zhao, "A survey on safety-critical driving scenario generation - a methodological perspective," *IEEE Transactions on Intelligent Transportation Systems*, vol. 24, no. 7, pp. 6971–6988, 2023.
- [2] B. Schütt, J. Ransiek, T. Braun, and E. Sax, "1001 ways of scenario generation for testing of self-driving cars: A survey," in *2023 IEEE Intelligent Vehicles Symposium (IV)*. IEEE, 2023, pp. 1–8.
- [3] Y. Gao, M. Piccinini, Y. Zhang, D. Wang, K. Moller, R. Brusnicki, B. Zarrouki, A. Gambi, J. F. Totz, K. Storms *et al.*, "Foundation models in autonomous driving: A survey on scenario generation and scenario analysis," *arXiv preprint arXiv:2506.11526*, 2025.
- [4] Z. Wang, J. Ma, and E. M. Lai, "A survey of scenario generation for automated vehicle testing and validation," *Future Internet*, vol. 16, no. 12, p. 480, 2024.
- [5] C.-H. Kung, S.-W. Lu, Y.-H. Tsai, and Y.-T. Chen, "Action-slot: Visual action-centric representations for multi-label atomic activity recognition in traffic scenes," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2024, pp. 18 451–18 461.
- [6] H. X. Liu and S. Feng, "Curse of rarity for autonomous vehicles," *nature communications*, vol. 15, no. 1, p. 4808, 2024.
- [7] D. Rempe, J. Phillon, L. J. Guibas, S. Fidler, and O. Litany, "Generating useful accident-prone driving scenarios via a learned traffic prior," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 17 305–17 315.
- [8] N. Hanselmann, K. Renz, K. Chitta, A. Bhattacharyya, and A. Geiger, "King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients," in *European Conference on Computer Vision*. Springer, 2022, pp. 335–352.
- [9] D. Rempe, Z. Luo, X. Bin Peng, Y. Yuan, K. Kitani, K. Kreis, S. Fidler, and O. Litany, "Trace and pace: Controllable pedestrian animation via guided trajectory diffusion," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 13 756–13 766.
- [10] T. Gu, G. Chen, J. Li, C. Lin, Y. Rao, J. Zhou, and J. Lu, "Stochastic trajectory prediction via motion indeterminacy diffusion," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 17 113–17 122.
- [11] F.-H. Chan, Y.-T. Chen, Y. Xiang, and M. Sun, "Anticipating accidents in dashcam videos," in *Computer Vision-ACCV 2016: 13th Asian Conference on Computer Vision, Taipei, Taiwan, November 20-24, 2016, Revised Selected Papers, Part IV 13*. Springer, 2017, pp. 136–153.
- [12] H. Kataoka, T. Suzuki, S. Oikawa, Y. Matsui, and Y. Satoh, "Drive video analysis for the detection of traffic near-miss incidents," in *2018 IEEE International Conference on robotics and automation (ICRA)*. IEEE, 2018, pp. 3421–3428.
- [13] T. Suzuki, H. Kataoka, Y. Aoki, and Y. Satoh, "Anticipating traffic accidents with adaptive loss and large-scale incident db," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 3521–3529.
- [14] H. Kim, K. Lee, G. Hwang, and C. Suh, "Crash to not crash: Learn to identify dangerous vehicles using a simulator," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no. 01, 2019, pp. 978–985.
- [15] T. You and B. Han, "Traffic accident benchmark for causality recognition," in *Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part VII 16*. Springer, 2020, pp. 540–556.
- [16] D. Xiao, M. Dianati, P. Jennings, and R. Woodman, "Hazardvlm: A video language model for real-time hazard description in automated driving systems," *IEEE Transactions on Intelligent Vehicles*, 2024.
- [17] C.-H. Kung, C.-C. Yang, P.-Y. Pao, S.-W. Lu, P.-L. Chen, H.-C. Lu, and Y.-T. Chen, "Riskbench: A scenario-based benchmark for risk identification," in *2024 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2024, pp. 14 800–14 807.
- [18] W. G. Najm, R. Ranganathan, G. Srinivasan, J. D. Smith, S. Toma, E. D. Swanson, A. Burgett *et al.*, "Description of light-vehicle pre-crash scenarios for safety applications based on vehicle-to-vehicle communications," United States. Department of Transportation. National Highway Traffic Safety..., Tech. Rep., 2013.
- [19] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," *IEEE transactions on pattern analysis and machine intelligence*, vol. 39, no. 6, pp. 1137–1149, 2016.
- [20] A. Gupta, J. Johnson, L. Fei-Fei, S. Savarese, and A. Alahi, "Social gan: Socially acceptable trajectories with generative adversarial networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 2255–2264.
- [21] M. Treiber, A. Hennecke, and D. Helbing, "Congested traffic states in empirical observations and microscopic simulations," *Physical review E*, vol. 62, no. 2, p. 1805, 2000.
- [22] D. Dauner, M. Hallgarten, A. Geiger, and K. Chitta, "Parting with misconceptions about learning-based vehicle motion planning," in *Conference on Robot Learning*. PMLR, 2023, pp. 1268–1281.
- [23] C. Knies and F. Diermeyer, "Data-driven test scenario generation for cooperative maneuver planning on highways," *Applied Sciences*, vol. 10, no. 22, p. 8154, 2020.
- [24] J. M. Scanlon, K. D. Kusano, T. Daniel, C. Alderson, A. Ogle, and T. Victor, "Waymo simulated driving behavior in reconstructed fatal crashes within an autonomous vehicle operating domain," *Accident Analysis & Prevention*, vol. 163, p. 106454, 2021.
- [25] W. Ding, W. Wang, and D. Zhao, "A new multi-vehicle trajectory generator to simulate vehicle-to-vehicle encounters," *arXiv preprint arXiv:1809.05680*, 2018.
- [26] R. Krajewski, J. Bock, L. Kloecker, and L. Eckstein, "The hight dataset: A drone dataset of naturalistic vehicle trajectories on german highways for validation of highly automated driving systems," in *2018 21st international conference on intelligent transportation systems (ITSC)*. IEEE, 2018, pp. 2118–2125.
- [27] J. Wang, A. Pun, J. Tu, S. Manivasagam, A. Sadat, S. Casas, M. Ren, and R. Urtasun, "Advsim: Generating safety-critical scenarios for self-driving vehicles," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 9909–9918.
- [28] S. Suo, S. Regalado, S. Casas, and R. Urtasun, "TrafficSim: Learning to simulate realistic multi-agent behaviors," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 10 400–10 409.
- [29] W. Ding, H. Lin, B. Li, and D. Zhao, "Causalaf: Causal autoregressive flow for safety-critical driving scenario generation," in *Conference on robot learning*. PMLR, 2023, pp. 812–823.
- [30] P. Huang, W. Ding, B. Stoler, J. Francis, B. Chen, and D. Zhao, "Cadre: Controllable and diverse generation of safety-critical driving scenarios using real-world trajectories," *arXiv preprint arXiv:2403.13208*, 2024.
- [31] C. Xu, W. Ding, W. Lyu, Z. Liu, S. Wang, Y. He, H. Hu, D. Zhao, and B. Li, "Safebench: A benchmarking platform for safety evaluation of autonomous vehicles," *Advances in Neural Information Processing Systems*, vol. 35, pp. 25 667–25 682, 2022.
- [32] D. Xu, Y. Chen, B. Ivanovic, and M. Pavone, "Bits: Bi-level imitation for traffic simulation," in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 2929–2936.
- [33] Z. Zhong, D. Rempe, Y. Chen, B. Ivanovic, Y. Cao, D. Xu, M. Pavone, and B. Ray, "Language-guided traffic simulation via scene-level diffusion," in *Conference on Robot Learning*. PMLR, 2023, pp. 144–177.
- [34] R. Herzig, E. Levi, H. Xu, H. Gao, E. Brosh, X. Wang, A. Globerson, and T. Darrell, "Spatio-temporal action graph networks," in *Proceedings of the IEEE/CVF international conference on computer vision workshops*, 2019, pp. 0–0.
- [35] M. S. Aliakbarian, F. S. Saleh, M. Salzmann, B. Fernando, L. Petersson, and L. Andersson, "Viena: A driving anticipation dataset," in *Asian Conference on Computer Vision*. Springer, 2018, pp. 449–466.
- [36] Y. Deng, J. Yao, Z. Tu, X. Zheng, M. Zhang, and T. Zhang, "Target: Automated scenario generation from traffic rules for testing autonomous vehicles," *arXiv preprint arXiv:2305.06018*, 2023. [Online]. Available: <https://arxiv.org/abs/2305.06018>
- [37] J. Gao, C. Sun, H. Zhao, Y. Shen, D. Angelov, C. Li, and C. Schmid, "Vectornet: Encoding hd maps and agent dynamics from vectorized representation," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 11 525–11 533.
- [38] H. Zhao, J. Gao, T. Lan, C. Sun, B. Sapp, B. Varadarajan, Y. Shen, Y. Shen, Y. Chai, C. Schmid *et al.*, "Tnt: Target-driven trajectory prediction," in *Conference on Robot Learning*. PMLR, 2021, pp. 895–904.