

KING: 基于运动学梯度生成安全关键驾驶场景以实现鲁棒模仿

Niklas Hanselmann^{1,2}

Katrin Renz^{2,3}

Kashyap Chitta^{2,3}

Apratim Bhattacharyya^{2,3}

Andreas Geiger^{2,3}

¹梅赛德斯-奔驰 AG 研发中心, 斯图加特

²蒂宾根大学

³马克斯·普朗克智能系统研究所, 蒂宾根

摘要: 模拟器为自动驾驶系统的安全、低成本开发提供了可能。然而, 当前的驾驶模拟器在背景交通行为模型方面表现出天真 (naïve) 的行为。通常在模拟过程中添加手工调优的场景来诱导安全关键情况。另一种方法是恶意干扰背景交通轨迹。在本文中, 我们使用 CARLA 模拟器研究这种安全关键驾驶场景生成方法。我们使用运动学自行车模型作为模拟器真实动力学的代理, 并观察到通过该代理模型的梯度足以优化背景交通轨迹。基于这一发现, 我们提出了 KING, 其生成的安全关键驾驶场景成功率比黑盒优化高 20%。通过使用特权规则式专家算法解决 KING 生成的场景, 我们获得了用于模仿学习策略的训练数据。在新的数据上微调后, 我们表明该策略在避免碰撞方面表现更好。重要的是, 我们生成的数据不仅减少了通过 KING 生成的保留场景中的碰撞, 也减少了传统手工制作场景中的碰撞, 证明了鲁棒性的提升。

1 引言

经过多年的稳步发展, 自动驾驶系统正逐渐接近成熟 [1]。由于失败的高后果性, 它们必须在面对未知和安全关键场景时满足极高的鲁棒性标准。然而, 针对这些情况的真实世界数据收集和验证既危险又缺乏必要的可扩展性 [2, 3]。这些问题可以通过逼真的模拟来解决。不幸的是, 当前的模拟器如 CARLA [4] 不仅在视觉保真度方面不足, 而且缺乏必要的驾驶场景多样性: 与现实世界存在外观和内容上的差距 [5]。内容差距是采用在模拟环境中使用模仿学习 (IL) 或强化学习 (RL) 训练的驾驶代理时面临的主要挑战, 这些代理在训练期间通常对未受代表性的 o.o.d. 输入非常脆弱 [6]。在本工作中, 我们旨在通过改进模拟背景交通代理的行为来弥合内容差距。

当前模拟器中的背景智能体遵循朴素的行为模型, 导致涌现交通的多样性有限, [4, 7]。关键场景通常由人工手工制作 [8, 9]。这种策略不太可能成功全面覆盖真实世界中可能遇到的关键情况的长尾分布。此外, 这些场景通常对被测试的驾驶智能体缺乏适应性。更精准的方法是主动寻找可能的失效模式。为此, 现有工作以物理上合理的方式扰动背景智能体的轨迹, 以在驾驶智能体中诱导失效 [10, 11]。这种范式可以被视为对驾驶智能体的运动学约束对抗攻击, 其中在给定计算预算内生成的安全关键数据量取决于攻击的成功率。这项任务的主流方法是黑盒优化 (BBO), 因为模拟器通常不可微分 [12, 13]。




图1: 为稳健驾驶生成安全关键场景。左: 我们提出了KING, 一种新的优化方法, 用于生成安全关键驾驶场景, 该方法通过可微分的运动学模型迭代更新初始场景, 并成功诱导与自身代理的碰撞。右: 在安全关键扰动中的专家行为上进行微调, 可得到更稳健的代理。

然而, 正如我们在广泛使用的CARLA模拟器 [4], 上观察到的, 基于BBO (例如 [12, 14, 13]) 的现有攻击难以可靠地诱导基于IL的驾驶智能体发生碰撞 (见表2)。

如图像空间对抗攻击中观察到的, 基于梯度的优化比BBO [15, 16]具有更快、更成功的潜力。此外, 在模拟 [17, 18, 19, 20] 和驾驶代理 [21, 22, 23, 24, 25, 26]中, 已出现端到端可微分的趋势。使用可微分组件可实现基于梯度的对抗交通场景生成。在本文中, 我们回答了一个重要问题: 整个模拟管道是否需要可微分才能为交通场景优化提供有用的梯度? 我们提出了KING, 一种简单有效的安全关键场景生成方法。我们的核心思想是使用运动学自行车模型作为驾驶模拟器真实动力学的代理, 并通过反向传播求解非关键初始场景的安全关键扰动。使用KING优化非关键场景的过程如图1 (左) 所示。此外, 我们展示了KING为使用 (1) 作用于鸟瞰图 (BEV) 网格输入的规划器以及 (2) 基于相机和LiDAR的驾驶代理 [27] 的驾驶系统生成具有挑战性但可解决的测试用例。最后, 我们证明了KING生成的场景可以增强具有有限多样性的原始训练分布。这导致了碰撞避免的改进, 如图1 (右) 所示。

贡献: (1) 我们提出了 KING, 一种通过反向传播生成安全关键场景的简单方法, 它比 BBO 更可靠且优化时间更少。(2) 我们展示了 KING 为两种具有不同输入模式的驾驶代理生成了具有挑战性、多样性和可解的场景。(3) 我们使用生成的场景来增强 CARLA 模拟器的非多样性交通, 提高了端到端基于 IL 的驾驶代理在生成的测试用例和包含 CARLA 手工制作场景的基准测试中的鲁棒性。项目页面: <https://lasnik.github.io/king/>。

2 相关工作

端到端驾驶: 我们对压力测试和改进基于端到端学习的自动驾驶系统很感兴趣。虽然这项任务有一些强化学习 (RL) 方法 [28, 29], 但大多数工作利用了独立学习 (IL)。有些方法紧密遵循端到端学习范式 [30, 21, 24, 31, 32, 27], 直接从原始传感器观测中推断驾驶动作。然而, 另一些方法使用可解释的中间表示 [33, 34, 35]。特别是, BEV语义占用栅格表示在现代驾驶方法中 [36, 22, 23, 37, 26] 被广泛使用。这种表示可以从图像中推断 [28, 29]。在我们的研究中, 我们考虑了两个基于IL的驾驶代理, 它们反映了两种不同的思想流派: (1) 一个名为AIM-BEV的规划器, 它作用于表示为BEV语义占用栅格的真实感知, 以及 (2) 一个端到端代理, 它作用于相机和激光雷达观测, 称为TransFuser [30, 21, 24, 31, 32, 27]。

在研究中，我们考虑了两个基于独立学习（IL）的驾驶代理，它们反映了两种不同的思想流派：(1) 一个名为AIM-BEV的规划器，它作用于表示为BEV语义占用栅格的真实感知，以及 (2) 一个端到端代理，它作用于相机和激光雷达观测，称为TransFuser [27]。

生成安全关键场景：以往关于生成安全关键场景的研究依赖于BBO技术，并探索了多种搜索空间参数化方法，例如单个对抗智能体的初始速度和位置 [45, 46]，高层路线图 [10]或从集成模型最终层采样的权重 [2]。在AdvSim [11]，中，搜索空间参数化为每个对抗智能体的运动学自行车模型状态序列，转向和加速度作为自由参数。我们也为KING采用了这种简单且表达能力强的参数化方法。与这一研究方向不同，我们提出了一种基于梯度的方法来优化这些参数，而不是依赖BBO技术。同时工作的STRIVE [47]，是一个通过基于梯度的优化生成关键场景的框架。在这里，对抗智能体被参数化为学习到的运动预测模型的潜在向量。虽然他们只攻击一个简单、特权的基于规则的规划器，但我们关注端到端的IL智能体。此外，我们通过实验将KING与黑盒场景生成进行了比较，而STRIVE并未考虑这一点。最后，STRIVE使用驾驶智能体的代理来启用基于梯度的优化，而KING直接针对实际驾驶智能体优化碰撞。

3 安全关键场景生成以增强鲁棒性

在本节中，我们概述了用于压力测试和改进基于强化学习的驾驶代理鲁棒性的整体方法，该方法如图2所示。给定一个在常规交通中训练的驾驶代理，我们提出了KING，这是一种基于梯度的优化程序，用于自动生成针对所考虑代理的非关键场景的安全关键扰动。这些场景用于增强原始训练分布的有限多样性。在下文中，我们将正式介绍我们的任务设置，详细说明用于场景生成的参数化和目标函数，并描述我们针对强化学习的鲁棒性训练方法。

驾驶代理和常规训练：我们对在专家驾驶常规交通数据集 $\mathcal{D}_{reg}$ 上训练的基于强化学习的驾驶代理进行压力测试和改进鲁棒性感兴趣。我们假设代理的驾驶策略是一个神经网络 π_ω ，其参数为 ω ，该网络接收一个观察 $\mathbf{o}_t \in \mathbb{R}^{H_o \times W_o \times C_o}$ 和目标位置 $\mathbf{x}_{goal} \in \mathbb{R}^2$ ，指示地图上的预期高级路线，并规划一个由四个未来2D航路点 $\mathbf{w} \in \mathbb{R}^{4 \times 2}$ 表示的轨迹：

$$\pi_\omega(\mathbf{o}_t, \mathbf{x}_{goal}) : \mathbb{R}^{H_o \times W_o \times C_o} \times \mathbb{R}^2 \rightarrow \mathbb{R}^{4 \times 2}. \quad (1)$$

根据预测的航点，横向和纵向控制器生成最终动作 $\mathbf{a}_t^0 \in [-1, 1]^2$ ，其形式为油门和转向指令。目前，几种最先进的 IL 代理属于这种范式 [48, 27, 26]。在此通用方案中，我们研究了一种具有中间表示的 IL 策略以及一个严格端到端的模型。第一个是一个作用于真实视觉抽象的规划器，我们将它称为 AIM-BEV。这受到 [35] 和 [26]，中的 AIM-VA 模型的启发，但使用 BEV 中间表示而不是 2D 语义，因为 BEV 是物理 3D 空间的正交投影，与车辆运动学比 2D 图像域有更好的相关性。在这里，观测 $\mathbf{o}_t \in \mathbb{R}^{192 \times 192 \times 3}$ 是一个编码 HD 地图信息的 BEV 网格，具有用于 (1) 道路和 (2) 车道的通道，以及一个用于动态障碍物（如背景代理）的单独通道 (3)。该网格以每米 5 个像素的分辨率表示代理前方和两侧的环境。除了 AIM-BEV，我们还对 TransFuser [27] 作者公开发布的检查点¹进行了压力测试。这是一个最近的最先进的基于 IL 的自动驾驶模型，它作用于从前置摄像头和离散化的

¹<https://github.com/autonomousvision/transfuser/tree/main/transfuser>




图2: 鲁棒的训练流程。给定任何使用常规交通数据训练的驾驶策略 π_ω 的智能体, 我们提出通过生成目标增强来提高其在安全关键场景下的鲁棒性。我们提出KING, 一种基于梯度的优化程序, 用于获得初始常规交通场景的安全关键扰动。这些扰动随后作为 π_ω 的附加训练数据。

BEV 激光雷达直方图, 具有两个高度分箱 $\mathbf{o}_t^{lid} \in \mathbb{R}^{256 \times 256 \times 2}$ 。AIM-BEV 和 TransFuser 都在观测航点对 (o, w) 上进行训练, 这些对来自 $\mathcal{D}_{reg}$ 。观测被映射到潜在表示, 该表示输入到一个门控循环单元 (GRU), 以自回归的方式规划轨迹 w 。有关更多详细信息, 请参阅补充材料和原始 TransFuser 论文。

基于梯度的场景生成: 为了优化初始非关键场景 (常规交通) 的安全关键扰动, 我们迭代地在闭环模拟中用受攻击的驾驶智能体 (自我智能体) 模拟场景。特别是, 我们旨在在自我智能体和其中一个背景演员 (对抗智能体) 之间创建碰撞。在每次迭代中, 我们调整场景的参数 (即对抗智能体的轨迹), 以诱导这种碰撞。重要的是, 自我智能体能够对对抗智能体的扰动做出反应, 因为攻击发生在闭环中。因此, 生成的场景能够适应被攻击的具体自我智能体。在下文中, 我们将正式描述模拟过程和场景生成程序。

设 $\mathbf{x}_t^i \in \mathbb{R}^2$, $\psi_t^i \in [0, 2\pi]$ 和 $v_t^i \in \mathbb{R}$ 分别为第 i 个智能体在时间 t 时的地面位置、朝向和速度, 其中索引 0 表示自身智能体。我们将交通状态表示为 $\mathbf{s}_t = \{\mathbf{x}_t^i, \psi_t^i, v_t^i\}_{i=0}^N$, 其中 N 为智能体数量。在略微违反符号约定的情况下, 我们将使用 s_t^i 来指代特定智能体的状态。我们将特定场景实例化为这些状态 $\mathcal{S} = \{\mathbf{s}_t\}_{t=0}^T$ 的序列, 其中 T 为固定的仿真时间范围。 $\mathcal{S}$ 使用第 4.2 节中描述的常规、非关键交通行为进行初始化。为了在时间上展开仿真, 我们根据当前状态 s_t 以及所有智能体的行为 $\mathbf{a}_t = \{\mathbf{a}_t^i\}_{i=0}^N$, 使用运动学模型 κ (即 $\mathbf{s}_{t+1} = \kappa(\mathbf{s}_t, \mathbf{a}_t)$) 计算下一个时间步的状态 $\mathbf{s}_{t+1}$ 。我们选择了自行车模型, 该模型为非完整车辆 [49, 28] 的物理上合理的运动提供了强先验知识, 并且是可微分的, 能够对展开的状态序列 $\mathcal{S}$ 进行反向传播。自身智能体对仿真做出反应, 并根据通过渲染函数 $\mathcal{R}$ (即 $\mathbf{o}_t = \mathcal{R}(\mathbf{s}_t, \mathcal{M})$) 获得的关于真实底层状态的观测 $\mathbf{o}_t$ 选择其行为 $\mathbf{a}_t^0$ 。为了渲染 AIM-BEV 的 BEV 语义占用栅格, 我们查询给定当前状态 s_t 和 HD 地图 $\mathcal{M}$ 的可微分光栅化器 [50], 用边界多边形表示其他智能体。为了渲染 TransFuser 的相机图像和 LiDAR 点云等传感器数据, 我们查询 CARLA 模拟器的图形引擎。请注意, 仿真所有组件 (π , κ 和 $\mathcal{R}$) 对于 AIM-BEV 是可微分的, 但 $\mathcal{R}$ 对于 TransFuser 不可微分。

安全关键扰动: 我们扰动状态序列 $\{\mathbf{s}_t^{i>0}\}_{t=0}^T$ 以使 N 对抗智能体产生碰撞。如果自我智能体在 T 步内发生碰撞, 我们将终止模拟。同时, 我们希望对抗智能体的行为保持合理。如果任何对抗智能体偏离地图的可驾驶区域或与其他对抗智能体碰撞, 模拟将不成功终止。为了检测碰撞, 我们在智能体的边界框之间执行交集检查。对于越界违规, 我们检查对抗智能体的边界框是否进入地图的非铺装区域。

模拟成功。同时，我们希望对抗智能体的行为保持合理。如果任何对抗智能体偏离地图的可驾驶区域或与其他对抗智能体碰撞，模拟将不成功终止。为了检测碰撞，我们在智能体的边界框之间执行交集检查。对于越界违规，我们检查对抗智能体的边界框是否进入地图的非铺装区域。

与 [11], 类似，我们将对抗智能体的轨迹参数化为一组通过展开运动学模型 κ 获得的状态。具体来说，通过优化每个对抗智能体的动作序列 $\{\mathbf{a}_t^{i>0}\}_{t=1}^T$ 来找到一个安全关键扰动。整个搜索空间可以表示为 $\theta = \{\theta^i\}_{i=1}^N$ ，其中 $\theta^i = \{\mathbf{a}_{t=0}^i, \dots, \mathbf{a}_{t=T}^i\}$ 等具有维度 $N \times T \times 2$ 。我们优化一个目标 $\mathcal{C}$ ，该目标受先前关于安全关键场景生成的 [10, 45, 11] 工作启发：

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \mathcal{C}(\mathcal{S}) \quad \text{with} \quad \mathcal{C}(\mathcal{S}) = \phi_{col}^{ego}(\mathcal{S}) + \lambda \phi_{col}^{adv}(\mathcal{S}) + \gamma \phi_{dev}^{adv}(\mathcal{S}). \quad (2)$$

我们鼓励涉及自我智能体的碰撞，其成本为 ϕ_{col}^{ego} ，并通过成本 ϕ_{col}^{adv} 和 ϕ_{dev}^{adv} 抑制模拟的不成功终止，这些成本使用超参数 λ 和 γ 进行加权。这些成本类似于规划中常用的成本函数 [51, 22, 23]。我们现在详细解释目标 $\mathcal{C}$ 的成本。

令 $d(\mathbf{s}_t^i, \mathbf{s}_t^j)$ 表示在时间 t 时， i^{th} 和 j^{th} 代理在边界多边形上最近点之间的欧几里得距离。为了通过与对抗代理的碰撞来诱导驾驶策略 π_ω 失效，我们选择 ϕ_{col}^{ego} 为一个鼓励近距离接触的吸引势。我们最小化自我代理与最近对抗代理之间的欧几里得距离。我们只选择最近的对抗代理，目的是阻止多个对抗代理偏离其轨迹以与自我代理发生碰撞的情况：

$$\phi_{col}^{ego}(\mathcal{S}) = \min_{i \in \{1, \dots, N\}} \frac{1}{T} \sum_{t=0}^T d(\mathbf{s}_t^0, \mathbf{s}_t^i). \quad (3)$$

为了提高场景的物理合理性，我们通过一个阈值化的排斥势 ϕ_{col}^{adv} 来阻止对抗代理之间的碰撞。阈值 τ 确保势仅在代理对距离小于安全距离时才起作用。此外，我们发现仅将排斥势 ϕ_{col}^{adv} 应用于最近的对抗代理对就足够了。因此，它被定义为：

$$\phi_{col}^{adv}(\mathcal{S}) = -\min \left(\min_{i, j \in \{1, \dots, N\}, t \in \{0, \dots, T\}} d(\mathbf{s}_t^i, \mathbf{s}_t^j), \tau \right). \quad (4)$$

最后，我们使用排斥势 ϕ_{dev}^{adv} 对抗代理进行正则化，以防止它们偏离可驾驶区域。这应用于对抗代理和地图 $\mathcal{M}$ 定义的越野区域之间。我们使用对应于 i^{th} 对抗代理的高斯势 $g(\mathbf{s}_t^i, \mathcal{M})$ ，该势应用于所有时间步和代理：

$$\phi_{dev}^{adv}(\mathcal{S}) = \sum_{i=0}^N \sum_{t=0}^T g(\mathbf{s}_t^i, \mathcal{M}). \quad (5)$$

关于成本函数的补充细节（例如具体的参数值）在补充材料中提供。请注意，生成的场景的真实性取决于正则化项在 $\mathcal{C}$ 中的选择。虽然增加额外的正则化可能有益，但我们发现公式(2)中的三个项足以找到有意义的场景。我们指出，我们的目标是发现位于交通分布长尾中的具有挑战性的场景。因此，我们目标发现的场景并非都可能在日常交通中频繁出现。然而重要的是，发现的场景是多样化的、可解的，并且能够通过第4.2节和第4.4节所示，使驾驶行为更加鲁棒。

运动学梯度：鉴于状态序列 $\mathcal{S}$ 基于可微分的运动学模型展开，我们可以将成本反向传播到任意时间步 t ，以作用于动作集




图3: 渐变路径。为了模拟一个场景, 我们使用渲染函数 $\mathcal{R}$ 对受到攻击的驾驶策略 π_ω 渲染观测值 $\mathbf{o}_t$ 。然后驾驶策略和对抗智能体都采取行动。自我智能体的行动 $\mathbf{a}_t^0$ 取决于观测值和目标位置 $\mathbf{x}_{goal}$ 。对抗智能体的行动 $\mathbf{a}_t^{i>0}$ 是要优化的安全关键扰动参数。给定所有智能体的行动和当前交通状态 $\mathbf{s}_t$, 使用可微运动学模型 κ 计算下一个状态 $\mathbf{s}_{t+1}$ 。然后可以从时间 t 的成本反向传播梯度到先前的步骤状态。如图所示, 导数沿两条路径的分量: 一条高效的直接路径和一条计算密集的间接路径。

$\{\mathbf{a}_{t-1}, \mathbf{a}_{t-2}, \dots, \mathbf{a}_0\}$ 在先前时间步上。在模拟的完整展开计算图中, 可以通过递归应用链式法则沿两条路径计算任意时间步的成本真实梯度, 这两条路径分别为: 一条通过运动学模型的直接路径, 以及一条间接路径, 后者额外涉及驱动策略 π_ω 和渲染器 $\mathcal{R}$ 。这如图 3 所示。

使用KING, 我们提出了一种近似真实梯度的方法, 该方法仅考虑直接路径并阻止通过间接路径的梯度。虽然这给梯度估计引入了误差, 但我们通过经验发现它效果良好, 并带来 several 优势。首先, 正如我们在第 4.2 节所示, 它能够在渲染函数或驱动策略不可微分的常见情况下实现基于梯度的生成, 防止梯度相对于间接路径被计算。其次, 即使所有组件都是可微分的, 相对于间接路径计算梯度需要通过驱动策略和渲染函数进行反向传播 (图 3 中的虚线红色箭头), 这会带来巨大的计算开销。我们在第 4.2 节研究了 AIM-BEV 的这种设置, 其中驱动策略和渲染函数都是可微分的, 并表明在固定的计算预算下, 这种计算开销导致的结果比 KING 更差。我们假设, 随着驱动策略对攻击的鲁棒性增强, 利用两条路径的梯度变得更加重要。

IL的鲁棒训练: 在压力测试基于IL的驾驶代理后, 我们进一步感兴趣通过用生成的安全关键场景增强原始训练数据来提高鲁棒性。为此, 我们追求一种简单而有效的策略: (1)我们生成大量安全关键场景, (2)我们筛选这些场景, 以便特权基于规则的专家算法在其中找到安全的替代轨迹, (3)我们使用专家收集筛选场景的观测点对数据集 $\mathcal{D}_{crit}$, (4)我们在安全关键数据 $\mathcal{D}_{crit}$ 和原始数据集 $\mathcal{D}_{reg}$ 的混合上使用标准 L_1 损失 $\mathcal{L}$ 微调策略 π_ω

$$\omega^* = \underset{\omega}{\operatorname{argmin}} \mathbb{E}_{(\mathbf{o}_t, \mathbf{x}_{goal}, \mathbf{w}) \sim (\mathcal{D}_{crit} \cup \mathcal{D}_{reg})} [\mathcal{L}(\mathbf{w}, \pi_\omega(\mathbf{o}_t, \mathbf{x}_{goal}))]. \quad (6)$$

4 实验

我们现在展示在我们的实验研究中旨在回答的研究问题。

基于梯度的攻击能否在安全关键场景生成中超越黑盒优化 (BBO)? 我们对减少生成一组所需优化时间感兴趣。

基于梯度的攻击能否在安全关键场景生成方面超越黑盒优化（BBO）？我们对减少生成一组非关键场景初始设置并找到有趣场景所需的优化时间感兴趣。考虑到计算梯度并执行反向传播的计算开销，我们在第4.2节分析了基于梯度的攻击相对于BBO在此任务中可以实现的收益。此外，如图3所示，梯度通过模拟器有两个路径。我们旨在了解反向传播通过每个路径的计算成本以及相应的碰撞率增益。

基于梯度的攻击适用于非可微分的模拟器吗？我们的主要实验使用可微分的模拟器进行，该模拟器渲染 AIM-BEV 的 BEV 网格输入。在 4.3 节，我们旨在研究 KING 对非微分渲染函数（如 CARLA 的相机和 LiDAR 传感器）的适用性。

通过在训练分布中增加关键场景，我们能提高鲁棒性吗？我们对分析使用 3. 节中描述的数据增强策略进行微调的 IL 模型的鲁棒性感兴趣。在 4.4 节，我们在常规基准（手工场景）和 KING 生成的安全关键测试场景上调查了这一点。

4.1 在手工场景上基准测试 IL 代理

为了初步了解其鲁棒性，我们首先使用 CARLA² 的手工场景对研究中使用的代理进行基准测试。作为一个旨在通过此类场景实现最大交通交互的附加基准，我们选择了一组穿过涉及密集交通的交叉口的短路线。我们将在下文中描述这些基准。结果为我们的 AIM-BEV 代理和现有的 TransFuser 代理在这些与后续实验相关的设置上的性能提供了参考。所有实验均使用 CARLA 版本 0.9.10.1 进行。

实验设置：AIM-BEV 和 TransFuser [27] 通过监督学习训练，以模仿在包含常规 CARLA 交通的数据上的特权专家。该专家是一个基于规则的算法，类似于 CARLA 交通管理器的自动驾驶系统³。我们在两个基准上评估这些模型：(1) 来自 [26] 的 NEAT 验证路线，以及 (2) CARLA Town10 中 82 条穿过密集交通交叉口的路线。NEAT 路线提供了对驾驶性能的整体评估，但评估过程耗时。该集合包含长度从 100 米到 3 公里的路线，包含常规 CARLA 交通和手工设计的场景。由于部分路线较长且交通密度较低，碰撞避免能力差对最终指标的影响有限。为了更专注于交通碰撞的评估，Town10 交叉口路线的长度更短（80 米-100 米）。在此设置中，我们通过 CARLA 模拟器在每个可能的生成点生成车辆，确保动态代理的高密度。此外，每条路线都保证包含一个手工设计的场景，其中多辆车从不同方向同时进入交叉口。我们选择 Town10 作为此基准，因为在初步实验中我们发现它最具挑战性。

指标：在这两个基准测试中，我们报告了 CARLA 排行榜的官方指标，包括路线完成率（RC）、违规分数（IS）和驾驶分数（DS）。RC 是指智能体在受阻或偏离路线之前完成的路线百分比。IS 是对每个红灯违规、停车标志违规、碰撞和车道违规的累积乘法惩罚。DS 是最终指标，计算为每条路线的 RC 乘以 IS。每个模型使用三种不同的评估种子进行测试。此外，我们还报告了碰撞率（CR），即智能体在通过交叉路口时发生碰撞的路线百分比。有关驾驶指标、基于规则的专家和驾驶策略的训练数据集的更多详细信息，请参阅补充材料。

结果：表 1 展示了两种驾驶代理以及使用特权信息的基于规则的专家的性能。请注意，这三种方法具有不同的输入，不能直接比较。AIM-BEV 在 IS 和 DS 方面优于 TransFuser。

²<https://leaderboard.carla.org/scenarios> ³
https://carla.readthedocs.io/en/latest/adv_traffic_manager

	NEAT验证路由 [26]				城镇10交叉口			
方法	RC $\uparrow$	IS $\uparrow$	DS $\uparrow$	CR $\downarrow$	RC $\uparrow$	IS $\uparrow$	DS $\uparrow$	CR $\downarrow$
AIM-BEV	96.77 $\pm$ 3.32	0.95 $\pm$ 0.00	92.24 $\pm$ 3.32	2.38 $\pm$ 4.12	93.86 $\pm$ 0.14	0.92 $\pm$ 0.01	86.74 $\pm$ 0.67	17.48 $\pm$ 1.86
TransFuser [27]	99.25 $\pm$ 1.30	0.78 $\pm$ 0.03	77.59 $\pm$ 2.01	11.90 $\pm$ 4.12	93.68 $\pm$ 2.01	0.85 $\pm$ 0.00	80.03 $\pm$ 0.79	17.48 $\pm$ 0.70
特权专家	99.83 $\pm$ 0.07	1.00 $\pm$ 0.00	99.83 $\pm$ 0.07	0.00 $\pm$ 0.00	94.89 $\pm$ 0.33	0.97 $\pm$ 0.00	92.81 $\pm$ 0.53	3.66 $\pm$ 0.00

表1: 手工构建场景下的性能表现。我们展示了在3次评估中的平均 $\pm$ 标准差。在NEAT验证路线上, AIM-BEV比TransFuser的违规行为更少。然而, 在这两种智能体中, 超过17%的Town10交叉口路线上发生了碰撞。

特别是, 它在NEAT路线上的IS显著更高, 表明在稀疏和非对抗性的CARLA交通中放置时, 它擅长避免碰撞。在Town10交叉口, AIM-BEV的IS优于TransFuser, 但我们观察到两个代理的CR相似 (17.48%)。这远高于专家 (CR=3.66%), 表明在密集交通中手工设计的场景对当前的基于IL的方法仍然具有挑战性。这些手工设计的场景对被测试的代理不具有适应性, 即对AIM-BEV和TransFuser都使用了相同的场景。在下文中, 我们研究更针对性的方法, 即主动生成对被攻击代理具有适应性的安全关键场景。

4.2 与BBO在安全关键场景生成中的比较

接下来, 我们通过将其与用于攻击 AIM-BEV 的几个 BBO 基线进行比较, 分析 KING 在生成安全关键场景方面的有效性。

实验设置: 我们实验设置中的一个场景涉及在20秒的模拟时间 (80个时间步, 4fps) 内推出一项政策。我们发现这个时间范围足以让自我代理从起点位置行驶到终点位置, 同时靠近对抗代理。我们在80个此类场景上比较了几种对抗优化技术。我们从CARLA模拟器中获取了4张地图 (Town03-Town06)。这4张地图具有各种道路布局, 包括十字路口、单车道道路、多车道高速公路、出口和环岛 (补充材料中有更多细节)。我们从这4张地图中所有可用的交叉路口集合中为自我代理采样密集的候选起点位置和终点位置。我们评估中的80个自我代理路线是通过在每个CARLA城镇中均匀采样20个候选路线获得的。

初始化背景交通: 在我们的评估中, 针对每个自我代理路线, 我们现在旨在检索处于自我代理直接周围的对立方代理的初始路线。为此, 我们从紧密经过自我代理路线的密集候选起始和结束位置集中检索所有潜在路线。这些路线被分配为该场景中对立方代理的相应起始和结束位置。我们使用特权专家沿着分配的路线驾驶对立方代理。这产生了一个非关键的初始场景, 模拟了CARLA交通, 并允许显式控制涉及的对立方代理数量。在我们的评估中, 我们使用了三种交通密度: 1个代理、2个代理和4个代理。更多详情, 请参阅补充材料。

指标: 我们使用碰撞率 (CR) 评估对抗场景, 该指标是指满足行为约束条件下, 对抗场景搜索产生碰撞的路线百分比。具体来说, 只有当所有对抗智能体都保持在可驾驶区域 (即道路) 且不与其它对抗智能体发生碰撞时, 搜索才被视为成功。为了评估收敛性, 我们报告达到50%碰撞率的平均时间 ($t_{50\%}$)。这衡量了在80%的总场景中找到50%碰撞所需的平均计算成本 (以GPU秒为单位)。最后, 我们报告每种技术的运行时间, 作为每次迭代的平均优化秒数 (s/it)。KING以及所有基线的 $t_{50\%}$ 和s/it指标均在单个RTX 2080Ti GPU上评估。对于所有方法, 我们在单个GPU上为每条路线分配180秒的计算预算, 导致80条路线的总实验预算高达4 GPU小时。

	1个代理			2个代理			4个代理			总体		
方法	CR ↑	$t_{50\%}$ ↓	s/it ↓	CR ↑	$t_{50\%}$ ↓	s/it ↓	CR ↑	$t_{50\%}$ ↓	s/it ↓	CR ↑	$t_{50\%}$ ↓	s/it ↓
随机搜索	62.50	9.25	1.30	68.75	7.38	1.35	68.75	15.22	1.48	66.67	9.66	1.38
贝叶斯优化	63.75	11.88	1.46	68.75	10.01	1.66	63.75	22.12	2.06	65.00	14.34	1.73
SimBA [12]	60.00	14.14	1.30	71.25	14.35	1.35	61.25	19.68	1.48	64.17	15.84	1.38
CMA-ES [14]	67.50	9.34	1.31	75.00	6.73	1.36	62.50	9.39	1.52	68.33	8.17	1.40
Bandit-TD [13]	37.50	-	3.87	30.00	-	4.39	21.25	-	5.02	29.58	-	4.43
KING 直接 +间接	78.75	19.33	3.17	72.50	14.68	3.25	76.25	14.67	3.40	75.83	16.14	3.27
KING (我们)	86.25	9.98	1.78	82.50	6.96	1.88	78.75	6.40	2.03	82.50	7.78	1.90

表2: 在CARLA上的关键场景生成。我们展示了三种交通设置下不同优化技术的平均CR、 $t_{50\%}$ 以及s/it, 以及聚合指标。KING在超过80%的初始化中检测到碰撞, 显著优于所有基线。仅使用直接路径(我们)会导致最高的CR, 并且比同时使用直接和间接路径的梯度更快。

所有方法, 我们在单个GPU上为每条路线分配180秒的计算预算, 导致80条路线的总实验预算高达4 GPU小时。

结果: 我们现在评估KING与BBO的效率。为此, 我们在表2中报告了我们的方法和几个基线的CR、 $t_{50\%}$ 以及s/it。我们分别考虑三种交通密度设置, 以及完整 80×3 场景集的总体指标。我们的基线通过BBO优化场景参数。特别是, 除了随机搜索和贝叶斯优化外, 我们还考虑了SimBA [12], CMA-ES [14]和Bandit-TD [13]。SimBA是随机搜索的一个变体, 贪婪地最大化目标, CMA-ES是一种最先进的进化算法。最后, Bandit-TD通过将先验集成到有限差分方法中计算数值梯度。

KING 在所有 3 种设置中获得的 CR 明显高于 BBO 基线, 使发现安全关键扰动的场景数量增加了 20% 以上。在 BBO 基线中, CMA-ES 在 CR 和 $t_{50\%}$ 方面取得了最佳总体得分。有趣的是, BBO 的最佳性能通常出现在 $N = 2$ 智能体上。随着我们将 N 从 1 增加到 2, 基线更容易找到一个附近的智能体, 可以扰动使其与自我智能体发生碰撞。然而, 进一步将 N 增加到 4 使维持合理的轨迹变得更加困难, 其中对抗性智能体不会相互碰撞或偏离道路, 导致性能下降。随着搜索空间维度的增加(例如, $N = 4$), KING 在 $t_{50\%}$ 方面开始以巨大优势超越基线。

我们还比较了 KING 中提出的近似方法与使用整个模拟中的梯度(包括驾驶策略和渲染器, “KING 直接 + 间接”表 2 中的设置)。虽然也能可靠地发现安全关键扰动, 但通过间接路径反向传播的计算开销导致在相同的计算预算下结果更差。这表明 KING 中的近似方法对于高效生成安全关键场景是合理的。关于 BBO 超参数选择的其他结果和详细信息提供了补充材料。由于我们观察到仅通过直接路径的梯度就足够, 我们现在进行详细的定性分析, 将 KING 应用于攻击 TransFuser, 这需要使用 CARLA 的非可微相机和 LiDAR 传感器进行渲染。

4.3 安全关键场景分析

在本节中, 我们详细分析了KING为AIM-BEV和TransFuser生成的安全关键场景。具体来说, 我们展示了在交通密度为 $N = 4$ 个智能体的场景分布情况, 如图4所示。对于两种驾驶智能体, 我们首先过滤掉KING无法找到碰撞解(“无碰撞”)以及基于规则的专家系统无法解决的场景。然后使用k-means(类似于[47])对剩余场景进行聚类, 以获得6种故障模式簇, 如切入(a_1)、追尾(a_2)以及在没有保护转弯中的不安全行为(e,f)。从图4中“无碰撞”场景的频率, 我们观察到





图4: 碰撞类型。对于4个智能体的交通密度, 我们观察到KING生成了多样化且可解决的挑战场景。我们将这些场景分为6个簇 (a-f)。簇的插图以红色表示自我智能体, 以蓝色表示对抗智能体。场景包括 (a) 自我智能体前方切入和自我智能体造成的追尾, (b) 迎头碰撞, (c) 合并, (d) 与对向交通的侧面碰撞, 以及交叉路口的T型碰撞 (e和f)。



(a) 我们展示了KING生成的两个场景, 其中 AIM-BEV进入交叉路口且未能让行于受扰动的背景交通。这导致T型碰撞, 由自我智能体 (左图) 或对抗智能体 (右图) 造成, 对应图4中的簇 (e) 和 (f)。

(b) 我们展示了TransFuser [27]在安全临界情况前两秒和零秒时的场景、相机和LiDAR输入。该模型无法减速以避免与在交叉路口内停止的对抗智能体 (红色框) 发生碰撞。

图5: KING生成的安全关键场景的定性示例。红色为自我代理, 蓝色为对抗代理。最佳观看效果为放大查看。

AIM-BEV和TransFuser在至少80%的场景中发生碰撞。这与表1中基准测试中两种模型的避碰能力存在显著差异, 当时它们的碰撞率 (CR) 均低于20%。TransFuser的大量碰撞表明, KING在应用于具有非可微渲染函数的驾驶模拟器时, 能够取得令人满意的结果。

我们在图5中展示了定性示例, 并在补充材料中提供了更多示例。当AIM-BEV和TransFuser遇到与训练期间观察到的交通行为不同的交通时, 它们在交叉路口频繁发生碰撞。重要的是, “不可解决”列表明, 对于两个智能体, 只有大约20%的场景没有可行的替代轨迹。这留下了图4中所示的6个集群中大量可解场景。两种模型的常见失效模式出现在集群(a)和(b)中, 这些集群涉及切入、追尾和迎头碰撞。基于规则的专家通过利用特权信息准确预测对抗性智能体的运动来解决这些具有挑战性的场景。有趣的是, 失效案例在涉及碰撞智能体之间各种相对方向的6个集群中分布得相当均匀。图4中的示例对应于集群(e)和(f)。

	保留的 KING 场景	手工制作的场景 (Town10 交叉口)			
数据集	CR ↓	RC ↑	IS ↑	DS ↑	CR ↓
无微调	100.00±0.00	93.86±0.14	0.92±0.01	86.74±0.67	17.48±1.86
$\mathcal{D}_{reg}$	57.14±0.00	95.66±0.51	0.90±0.00	86.85±0.62	19.51±0.00
$\mathcal{D}_{crit}$	28.57±0.00	91.92±0.19	0.96±0.00	88.37±0.41	6.10±0.00
$\mathcal{D}_{crit} \cup \mathcal{D}_{reg}$	28.57±0.00	94.42±0.36	0.96±0.36	90.20±0.00	8.13±0.70

表3: AIM-BEV的鲁棒训练。显示的结果是3个评估种子的均值和标准差。使用安全关键场景进行微调, 可以将CR在其余安全关键场景以及CARLA中的手工制作场景上降低50%以上。



(a) 合并时保持安全距离。

(b) 减速以避免追尾。

图6: 使用AIM-BEV在保留的KING场景中改进的碰撞避免。原始模型(左)与在 $\mathcal{D}_{crit} \cup \mathcal{D}_{reg}$ 上微调的鲁棒模型(右)的比较。自车为红色, 对抗车为蓝色。最佳效果需缩放查看。

我们为实验在图6中突出了来自集群(a₁)和(a₂)的示例。KING生成的可解场景的高频率和多样性表明其有可能增强IL模型的原始训练数据, 我们将在下一部分进行调查。

4.4 微调后的鲁棒性评估

最后, 我们分析了生成的场景在增强原始训练分布以产生更鲁棒的驾驶代理方面的有效性。在这里, 我们评估鲁棒性, 既针对由KING生成的安全关键场景, 也针对CARLA模拟器中的手工制作场景(使用Town10交叉口基准)。

实验设置: 本实验的目标是收集用于改进避撞训练的数据。为此, 我们通过使用CARLA Town03-Town06的初始化参数攻击AIM-BEV, 构建了大量安全关键场景, 并使用 $N = 4$ 个智能体。为确保监督的有效性, 我们筛选出KING能发现且专家可解决的碰撞场景。最终得到约300个场景, 从中抽取20%用于评估。我们通过防止具有相同自行车起始位置的路线同时出现在训练集和评估集中, 确保了训练和评估数据在此分割过程中无重叠。有关训练数据和超参数的更多细节, 请参见补充材料。

结果: 我们在表3中报告了AIM-BEV在 $\mathcal{D}_{crit} \cup \mathcal{D}_{reg}$ 上微调后的驾驶性能。由于对抗智能体的轨迹在通过KING优化后是固定的, 因此某些场景可能只需采用不同的整体驾驶风格即可解决, 而不是在避撞方面变得更加熟练。为了量化这一点, 我们仅使用原始训练数据 $\mathcal{D}_{reg}$ 作为基线对每个模型进行微调, 在保留的KING场景上, CR从100%降低到57.14%。此外, 我们还比较了仅在关键场景 $\mathcal{D}_{crit}$ 上微调 and 表1中的初始检查点(“未微调”)的微调策略。在三种微调策略中, 仅使用 $\mathcal{D}_{reg}$ 会导致不理想的结果, 在Town10交叉路口基准测试中CR为19.51%。仅使用 $\mathcal{D}_{crit}$ 会导致在两个评估场景上CR大幅降低。然而, 与 $\mathcal{D}_{crit} \cup \mathcal{D}_{reg}$ 基线相比, 该模型的RC较低, 在Town10交叉路口上DS略有提升。最后, 使用 $\mathcal{D}_{reg}$ 的组合数据集取得了最佳结果。在此设置中, 我们在KING场景上获得了28.57%的CR, 这与仅使用 $\mathcal{D}_{crit}$ 微调的模型相同。然而, 该模型在Town10上的DS提高了3分以上, 因为它在保持与原始模型相似的RC的同时降低了CR。这表明, 在常规和安全关键数据混合上进行微调的简单策略是学习KING生成的场景的有效方法。

设置。然而，与 $\mathcal{D}_{reg}$ 基线相比，该模型的RC较低，在Town10交叉路口上DS仅略有提升。最后，使用 $\mathcal{D}_{crit} \cup \mathcal{D}_{reg}$ 的组合数据集取得了最佳结果。在此设置中，我们在KING场景上获得了28.57%的CR，这与仅使用 $\mathcal{D}_{crit}$ 微调的模型相同。然而，该模型在Town10上的DS提高了3分以上，因为它在保持与原始模型相似的RC的同时降低了CR。这表明，在常规和安全关键数据混合上进行微调的简单策略是学习KING生成的场景的有效方法。

在图6中，我们展示了原始和微调的AIM-BEV智能体在KING场景中的定性驾驶示例，这些场景属于图4中所属的簇(a₁)和(a₂)。虽然这些场景对专家驾驶员来说很简单，但AIM-BEV无法在两条车道之间停车的车辆前刹车，也无法在合并操作中保持安全距离，这突显了它在o.o.d场景中的脆弱性。这些场景类型不会频繁地从CARLA模拟器的背景代理行为中自然出现，该行为控制着 $\mathcal{D}_{reg}$ 。通过在训练中结合来自 $\mathcal{D}_{crit}$ 的数据，驾驶智能体可以学习安全地处理这些场景。

5 结论

我们在生成安全关键型交通场景方面取得了重大进展。我们提出了一种新的基于梯度的生成程序KING，与现有的基于BBO的方法相比，它实现了显著更高的成功率，同时效率更高。我们成功的关键在于通过运动学模型计算高效的直接梯度路径来指导对抗性场景生成过程。我们的分析表明，当将我们的方法直接应用于任意驾驶智能体时，可以实现有前景的结果。此外，我们表明，尽管作为输入可以访问特权BEV语义地图，但最先进的基于状态的学习驾驶策略对背景演员行为的微小扰动表现出惊人的脆弱性。通过用KING场景增强其训练数据，我们能够显著提高其避碰能力。探索具有不同训练程序（例如RL）的智能体的鲁棒性为未来的研究提供了一个有趣的方向。

致谢

本研究由德国联邦经济事务与气候行动部（项目编号：19A19013A、19A19013O）、德国联邦教育与研究部（蒂宾根人工智能中心，项目编号：01IS18039A、01IS18039B）以及德国研究基金会（SFB 1233，鲁棒视觉：推理原理与神经机制，项目编号：276693517）资助。我们感谢国际智能系统马克斯·普朗克研究院（IMPRS-IS）对Katrin Renz和Kashyap Chitta的支持。作者还感谢Aditya Prakash和Bernhard Jaeger的校对。

参考文献

- [1] J. Janai, F. Güney, A. Behl, and A. Geiger. *Computer Vision for Autonomous Vehicles: Problems, Datasets and State of the Art*, volume 12. Foundations and Trends in Computer Graphics and Vision, 2020. 1
- [2] M. O' Kelly, A. Sinha, H. Namkoong, R. Tedrake, and J. C. Duchi. Scalable end-to-end autonomous vehicle testing via rare-event simulation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. 1, 3
- [3] J. Norden, M. O'Kelly, and A. Sinha. Efficient black-box assessment of autonomous vehicle safety. *arXiv.org*, 1912.03618, 2019. 1
- [4] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun. CARLA: An open urban driving simulator. In *Proc. Conf. on Robot Learning (CoRL)*, 2017. 1, 2
- [5] A. Kar, A. Prakash, M. Liu, E. Cameracci, J. Yuan, M. Rusiniak, D. Acuna, A. Torralba, and S. Fidler. Meta-sim: Learning to generate synthetic datasets. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019. 1
- [6] A. Filos, P. Tigas, R. McAllister, N. Rhinehart, S. Levine, and Y. Gal. Can autonomous vehicles identify, recover from, and adapt to distribution shifts? In *Proc. of the International Conf. on Machine learning (ICML)*, 2020. 1
- [7] S. R. Richter, Z. Hayder, and V. Koltun. Playing for benchmarks. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2017. 1
- [8] Carla autonomous driving leaderboard. <https://leaderboard.carla.org/>, 2020. 1
- [9] D. J. Fremont, E. Kim, T. Dreossi, S. Ghosh, X. Yue, A. L. Sangiovanni-Vincentelli, and S. A. Seshia. Scenic: A language for scenario specification and data generation. *arXiv.org*, 2010.06580, 2020. 1
- [10] Y. Abeyesirigoonawardena, F. Shkurti, and G. Dudek. Generating adversarial driving scenarios in high-fidelity simulators. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2019. 1, 3, 5
- [11] J. Wang, A. Pun, J. Tu, S. Manivasagam, A. Sadat, S. Casas, M. Ren, and R. Urtasun. Advsim: Generating safety-critical scenarios for self-driving vehicles. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021. 1, 3, 5
- [12] C. Guo, J. R. Gardner, Y. You, A. G. Wilson, and K. Q. Weinberger. Simple black-box adversarial attacks. In *Proc. of the International Conf. on Machine learning (ICML)*, 2019. 1, 2, 9
- [13] A. Ilyas, L. Engstrom, and A. Madry. Prior convictions: Black-box adversarial attacks with bandits and priors. In *Proc. of the International Conf. on Learning Representations (ICLR)*, 2019. 1, 2, 9
- [14] N. Hansen and A. Ostermeier. Completely derandomized self-adaptation in evolution strategies. *Evolutionary Computation*, 2001. 2, 9
- [15] M. Andriushchenko, F. Croce, N. Flammarion, and M. Hein. Square attack: A query-efficient black-box adversarial attack via random search. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020. 2
- [16] Y. Deng, X. Zheng, T. Zhang, C. Chen, G. Lou, and M. Kim. An analysis of adversarial attacks and defenses on autonomous driving models. *arXiv.org*, 2002.02175, 2020. 2
- [17] A. Ścibior, V. Lioutas, D. Reda, P. Bateni, and F. Wood. Imagining the road ahead: Multi-agent trajectory prediction via differentiable simulation. *arXiv.org*, 2104.11212, 2021. 2

- [18] O. Scheel, L. Bergamini, M. Wolczyk, B. Osinski, and P. Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients. In *Proc. Conf. on Robot Learning (CoRL)*, 2021. 2
- [19] L. Bergamini, Y. Ye, O. Scheel, L. Chen, C. Hu, L. D. Pero, B. Osinski, H. Grimmert, and P. Ondruska. Simnet: Learning reactive self-driving simulations from real-world observations. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021. 2
- [20] S. Suo, S. Regalado, S. Casas, and R. Urtasun. Trafficsim: Learning to simulate realistic multi-agent behaviors. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021. 2
- [21] M. Bojarski, D. D. Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, J. Zhang, X. Zhang, J. Zhao, and K. Zieba. End to end learning for self-driving cars. *arXiv.org*, 1604.07316, 2016. 2
- [22] A. Sadat, S. Casas, M. Ren, X. Wu, P. Dhawan, and R. Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020. 2, 5
- [23] S. Casas, A. Sadat, and R. Urtasun. Mp3: A unified model to map, perceive, predict and plan. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021. 2, 5
- [24] F. Codevilla, M. Miiller, A. López, V. Koltun, and A. Dosovitskiy. End-to-end driving via conditional imitation learning. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2018. 2
- [25] A. Prakash, A. Behl, E. Ohn-Bar, K. Chitta, and A. Geiger. Exploring data aggregation in policy learning for vision-based urban autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020. 2
- [26] K. Chitta, A. Prakash, and A. Geiger. Neat: Neural attention fields for end-to-end autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021. 2, 3, 7, 8
- [27] A. Prakash, K. Chitta, and A. Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021. 2, 3, 7, 8, 10
- [28] D. Chen, V. Koltun, and P. Krähenbühl. Learning to drive from a world on rails. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021. 2, 4
- [29] M. Toromanoff, E. Wirbel, and F. Moutarde. End-to-end model-free reinforcement learning for urban driving using implicit affordances. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020. 2
- [30] D. Pomerleau. ALVINN: an autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems (NIPS)*, 1988. 2
- [31] F. Codevilla, E. Santana, A. M. López, and A. Gaidon. Exploring the limitations of behavior cloning for autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019. 2
- [32] E. Ohn-Bar, A. Prakash, A. Behl, K. Chitta, and A. Geiger. Learning situational driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020. 2
- [33] A. Sauer, N. Savinov, and A. Geiger. Conditional affordance learning for driving in urban environments. In *Proc. Conf. on Robot Learning (CoRL)*, 2018. 2
- [34] Y. Xiao, F. Codevilla, C. Pal, and A. M. López. Action-Based Representation Learning for Autonomous Driving. In *Proc. Conf. on Robot Learning (CoRL)*, 2020. 2

- [35] A. Behl, K. Chitta, A. Prakash, E. Ohn-Bar, and A. Geiger. Label efficient visual abstractions for autonomous driving. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2020. 2, 3
- [36] Y. Zhou, P. Sun, Y. Zhang, D. Anguelov, J. Gao, T. Ouyang, J. Guo, J. Ngiam, and V. Vasudevan. End-to-end multi-view fusion for 3d object detection in lidar point clouds. In *Proc. Conf. on Robot Learning (CoRL)*, 2019. 2
- [37] Z. Zhang, A. Liniger, D. Dai, F. Yu, and L. Van Gool. End-to-end urban driving by imitating a reinforcement learning coach. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021. 2
- [38] K. Mani, S. Daga, S. Garg, N. Sai Shankar, K. Murthy Jatavallabhula, and K. Madhava Krishna. MonoLayout: Amodal scene layout from a single image. In *Proc. of the IEEE Winter Conference on Applications of Computer Vision (WACV)*, 2020. 3
- [39] T. Roddick and R. Cipolla. Predicting semantic map representations from images using pyramid occupancy networks. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020. 3
- [40] B. Pan, J. Sun, H. Y. T. Leung, A. Andonian, and B. Zhou. Cross-view semantic segmentation for sensing surroundings. *IEEE Robotics and Automation Letters (RA-L)*, 2020. 3
- [41] N. Hendy, C. Sloan, F. Tian, P. Duan, N. Charchut, Y. Xie, C. Wang, and J. Philbin. Fishing net: Future inference of semantic heatmaps in grids. *arXiv.org*, 2006.09917, 2020. 3
- [42] A. Hu, Z. Murez, N. Mohan, S. Dudas, J. Hawke, V. Badrinarayanan, R. Cipolla, and A. Kendall. FIERY: future instance prediction in bird’s-eye view from surround monocular cameras. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021. 3
- [43] J. Philion and S. Fidler. Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020. 3
- [44] A. Loukkal, Y. Grandvalet, T. Drummond, and Y. Li. Driving among Flatmobiles: Bird-Eye-View occupancy grids from a monocular camera for holistic trajectory planning. *arXiv.org*, 2008.04047, 2020. 3
- [45] W. Ding, M. Xu, and D. Zhao. Learning to collide: An adaptive safety-critical scenarios generating method. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2020. 3, 5
- [46] W. Ding, B. Chen, B. Li, K. J. Eun, and D. Zhao. Multimodal safety-critical scenarios generation for decision-making algorithms evaluation. *IEEE Robotics and Automation Letters (RA-L)*, 6(2):1551–1558, 2021. 3
- [47] D. Rempe, J. Philion, L. J. Guibas, S. Fidler, and O. Litany. Generating useful accident-prone driving scenarios via a learned traffic prior. In *arXiv.org*, volume 2112.05077, 2021. 3, 9
- [48] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl. Learning by cheating. In *Proc. Conf. on Robot Learning (CoRL)*, 2019. 3
- [49] P. Polack, F. Altché, B. d’Andréa Novel, and A. de La Fortelle. The kinematic bicycle model: A consistent model for planning feasible trajectories for autonomous vehicles? In *Proc. IEEE Intelligent Vehicles Symposium (IV)*, 2017. 4
- [50] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu. Spatial transformer networks. In *Advances in Neural Information Processing Systems (NIPS)*, 2015. 4
- [51] W. Zeng, W. Luo, S. Suo, A. Sadat, B. Yang, S. Casas, and R. Urtasun. End-to-end interpretable neural motion planner. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2019. 5