

从风险中学习：基于大语言模型的先验知识安全关键场景生成

王宇航^a, 黄鹤业^{b,c,*}, 许振华^d, 孙凯来^{b,c}, 郭宝申^{b,c}, 赵金华^{b,c}

^a中国科学院, 中国

^b新加坡-麻省理工学院联合研究与技术中心 (SMART), 新加坡^c麻省理工学院城市研究与规划系, 美国^d清华大学车辆与交通学院, 中国

摘要

自动驾驶在罕见长尾事件和复杂多智能体交互方面面临关键挑战, 这些事件在真实世界数据中稀缺, 但对稳健安全验证至关重要。本文提出了一种高保真场景生成框架, 该框架集成了条件变分自编码器 (CVAE) 和大语言模型 (LLM)。CVAE将大规模自然数据集中的历史轨迹和地图信息编码为潜在的交通结构, 从而生成物理一致的基准场景。在此基础上, LLM作为对抗推理引擎, 将非结构化场景描述解析为特定领域的损失函数, 并动态指导跨不同风险水平的场景生成。这种知识驱动的优化在真实性和可控性之间取得平衡, 确保生成的场景既合理又具有风险敏感性。在CARLA和SMARTS中的大量实验表明, 我们的框架显著提高了高风险和长尾事件的覆盖率, 改善了模拟与现实世界交通分布的一致性, 并使自动驾驶系统接触到比现有规则或数据驱动方法生成的更具挑战性的交互。这些结果为安全验证开辟了新途径, 能够对自动驾驶系统在罕见但具有重大影响的事件下进行原则性压力测试。代码可在 <https://github.com/echoleaeperw/LRF> 获取

关键词: 场景生成, 大型语言模型, 安全关键场景, 仿真到真实差距

1. 引言

自动驾驶的安全性和可靠性取决于在各种测试条件下进行严格验证, 尤其是在高风险、高度交互和安全关键场景中 (王等, 2021; Hossain, 2025)。然而, 这类事件在真实世界数据集中极为罕见, 导致开发测试与部署需求之间存在持续差距。基于仿真的方法通过生成大量罕见和对抗性环境, 提供了一种有效的替代方案, 从而缓解数据稀缺性并实现受控的安全评估 (黄等, 2020)。然而, 现有的场景生成方法面临关键局限性:

*通讯作者邮箱地址: wangyuhang22@mails.ucas.ac.cn (王宇航), heyeh@mit.edu (黄鹤), zhenhuaxu@tsinghua.edu.cn (徐振华), skl24@mit.edu (孙凯来), baoshen@mit.edu (郭宝申), jinhua@mit.edu (赵金花)

(1) 基于规则或参数化的方法提供可解释性和可控性，但缺乏行为多样性，无法再现真实世界人类驾驶的复杂性（赵等，2016；孙等，2021；杨等，2023）；(2) 数据驱动的重放或模仿方法可以再现历史交互，但无法合成未见过的长尾风险（苏等，2021；Bergamini等，2021）；以及(3) 近期生成模型虽然更灵活，但仍难以同时确保可控性、真实性和可扩展性（Stoler等，2025；Shao等，2024；张等，2024）。

为应对这些挑战，本文提出了一种风险知识引导的交通场景生成框架，该框架集成了条件变分自动编码器（CVAE）与大型语言模型（LLM）。与以往仅对特定风险案例进行采样或重放的研究不同，该框架建立了一个通用且可控的流程，用于在变化的风险条件下合成多样化的安全关键场景。CVAE从真实世界轨迹中学习潜在的时空表示，并将其映射生成物理上连贯的基础场景，而LLM则作为知识驱动的控制，解释场景语义，分析多智能体风险交互，并动态调整优化目标，以引导生成达到期望的行为复杂度和风险暴露水平。通过这种双重机制和知识引导的损失适应过程，该框架能够在低风险、高风险和长尾风险状态下实现可解释和可控的生成，有效弥合了仿真与现实世界安全验证之间的差距。主要贡献如下：

1. 我们提出了一种集成了基于CVAE的运动学习与LLM引导优化的高保真安全关键场景生成框架。该设计实现了一个通用且可控的流程，用于合成多样化的、对风险敏感的驾驶场景。
2. 我们提出了一种知识驱动的损失自适应机制，其中大型语言模型（LLM）解释风险语义并动态调整优化目标。这确保了在整个生成过程中物理合理性、行为一致性和可解释的风险水平。
3. 我们提出了一种跨风险分布策略，系统性地覆盖低风险、高风险和长尾场景。它增强了长尾表示，并有效地在自动驾驶验证中弥合了仿真与现实之间的差距。

2. 相关工作

现有的交通场景生成研究可以大致分为三类（Chen 等人，2024；Gao 等人，2025）：（1）基于规则或参数化的采样方法，（2）数据驱动的模拟方法，以及（3）生成式和对抗性建模方法。基于规则和采样方法强调可控性和可解释性，但缺乏多样性。数据驱动方法通过利用大规模数据集提高了真实性，但难以生成未见过的关键事件。最近，生成式和对抗性方法，包括基于扩散和 LLM 驱动的框架，提高了可控性和风险覆盖范围，尽管它们仍然面临效率和可扩展性的挑战。

(1) 基于规则和参数化的采样方法。早期的交通场景生成方法依赖于基于规则的日志重放或参数化采样。这些方法提供了强大的可解释性以及可控性，因为人类设计师可以执行交通规则或指定事件触发器，例如切入或突然停车（刘等人，2024；邓等人，2025）。像SUMO和CARLA这样的经典模拟器提供了可配置的环境，其中可以插入对抗性代理或扰动轨迹以

对系统进行压力测试。重要性采样技术和替代模型也得到了发展，通过从手动定义参数空间中重新采样来加速稀有安全关键事件的评估（Zhao 等人，2016 年；Sun 等人，2021 年）。虽然这些方法实现了效率和可重复性，但它们对预定义规则和参数的依赖限制了它们表示现实世界人类驾驶多样性和随机性的能力。因此，它们探索的行为空间受限于设计者的假设，一旦规则或参数范围固定，就不会出现真正新颖的交互。此外，大多数基于规则的框架未能保留多个智能体之间的联合动态，导致在扩展到密集交通时出现不现实或过于简化的响应。这些手工设计也难以反映强烈影响现实世界风险的驾驶员意图和反应时序的微妙变化。结果，此类方法往往过拟合于合成边界情况，而不是暴露真实的接近失事情况，这使得难以评估自主策略在微妙不确定性下的表现。因此，基于规则和采样方法经常遗漏对安全验证最关键的长尾交互（Rempe 等人，2022 年；Zhou 等人，2025 年）。

(2) 数据驱动模拟方法。随着大规模自然驾驶数据集（例如，nuScenes（Caesar 等人，2020 年）、Waymo Open Motion 数据集（Sun 等人，2020 年）、highD（Krajewski 等人，2018 年）、inD（Bock 等人，2020 年））的可用性，基于学习的交通模拟已成为更现实的替代方案。TrafficSim（Suo 等人，2021 年）和 SimNet（Hennigh 等人，2021 年）等方法从记录的轨迹中学习多智能体运动先验，能够回放和合成合理的交互（Chen 等人，2025 年；Lin 等人，2025 年；Wang 等人，2025 年；Sun 等人，2025a）。更近期的努力利用生成对抗网络和模仿学习直接从数据中模拟复杂的交通行为，允许更动态和现实的多智能体交互（Bergamini 等人，2021 年）。与基于规则的方法相比，这些数据驱动方法显著提高了真实性和多样性。然而，它们通常缺乏可控性，因为生成行为受限于训练数据集中观察到的分布（Stoler 等人，2025 年）。这种数据依赖性限制了它们复制在自然数据中很少出现的、安全关键性边缘情况的能力。此外，在特定区域或交通条件下训练的模型可能泛化能力差，导致模拟结果出现偏差和不稳定性。生成的场景也倾向于重复统计上频繁出现的模式，而不是策略上宝贵的罕见事件。此外，通过随机扰动或对抗性噪声尝试提高多样性，往往会降低物理真实性或破坏智能体之间的协调。因此，纯粹的数据驱动模拟在长尾或对抗性条件下进行系统测试是不够的（Liu 等人，2025 年；Aiersilan，2025 年）。

(3) 生成式和对抗性建模方法。为了克服纯基于规则和数据驱动方法的局限性，生成式模型已被越来越多地应用于交通场景生成（Sheng 等人，2025）。这些方法旨在通过从数据中学习，同时实现未见过的安全情况的合成，来平衡真实性、多样性和可控性。

潜变量生成模型（如 STRIVE）利用基于图的条件 VAE，在真实世界数据上训练，以扰动潜在空间中的现有轨迹，从而创建易发生事故但合理的场景（Rempe 等人，2022）。通过优化对抗性目标，这些模型生成多样化的碰撞并识别规划器弱点。类似的方法采用了 GAN 或概率运动先验来丰富场景多样性（Feng 等人，2023）。然而，它们对基于梯度的优化的依赖限制了可扩展性，并且在扩展到多智能体交互时通常限制了可解释性。此外，这些模型的可控性通常仅限于几个预定义的数值指标，使得指定“激进切入”或“近距离合并”等语义目标变得困难。

基于扩散的模型通过从噪声逐渐细化轨迹到物理上连贯的运动，进一步增强真实感和可控性（Xu等人，2025）。它们提供强大的生成能力，并能以高保真度对复杂的多模态分布进行建模，产生在安全行为和危险行为之间的连续过渡。更近期的 studies 将扩散模型扩展了辅助引导信号，这些信号编码场景语义和几何先验，从而实现轨迹真实感和交互强度的细粒度控制。这些方法显著扩展了安全关键条件下的覆盖范围，同时保持了自然运动模式。然而，基于扩散的模型仍然计算成本高昂，并且需要对每个样本进行大量去噪步骤，这限制了它们在大规模测试和实时模拟中的可扩展性。

除了扩散模型和对抗采样之外，近期研究探索了使用大型语言模型（LLMs）（Sun 等人，2025b）来指导强化学习和交通模拟中损失函数或奖励函数的形成。Liu 等人提出了一种基于 LLM 的分层推理框架，结合思维链提示和弗莱内特框架成本函数，提升了模型对空间关系和交互意图的理解（Liu 等人，2024）。这些设计增强了语义可控性，允许对场景难度、车辆角色和交互类型进行结构化操作。Han 等人进一步证明，LLMs 可以通过迭代反思自动生成和优化高速公路驾驶的奖励函数，实现了更高的训练成功率并减少了人工设计的工作量（Han 等人，2024）。这类方法突显了语言驱动的监督在人类可解释和自适应方式下塑造优化目标的潜力。然而，当单独应用时，基于 LLM 的方法往往缺乏物理一致性运动先验的支撑，在密集多智能体条件下会导致不稳定或不真实的行为。

3. 方法论

3.1. 总体框架

我们提出了一种用于生成安全关键交通场景的统一框架，该框架将数据驱动的运动先验与知识引导的推理相结合。如图1所示，该框架由三个相互连接的模块组成。(1) 基于CVAE-GNN的交通场景生成。来自高D和nuScenes等大规模数据集的历史轨迹和高分辨率地图数据由基于图的条件变分自动编码器编码。编码器捕获多智能体交互和车道拓扑，形成表示随机交通行为的潜在变量 $z \sim \mathcal{N}(\mu, \sigma^2)$ ，而解码器重建物理一致的基场景 $\hat{Y}$ 作为现实且多样的运动先验。(2) LLM引导的损失函数优化。包含轨迹、地图上下文和智能体间关系的结构化场景描述由LLM解析，通过思维链推理识别事件类型和潜在风险。LLM输出自适应损失权重（例如， $L_{\text{AdversarialCrash}}$, $L_{\text{MinDist lat}}$, L_{YawRate} , L_{TTC} ），这些权重通过基于物理的风险场模型迭代优化，以确保语义可解释性和动态稳定性。(3) 跨风险场景分布。优化的潜在空间被重塑以持续覆盖低、中、高风险区域。通过调节学习到的分布，该框架在变化的风险水平上生成均衡的场景，使自动驾驶策略在各种安全关键条件下能够进行系统性的压力测试。总体而言，该框架将传统的数据驱动重放转变为知识引导的生成范式，将语义推理与潜在空间优化相结合，用于生成可控、物理一致且具有风险意识的安全关键交通场景。




图1: 概述所提出的 LLM 指导的 CVAE-GNN 框架, 用于安全关键交通场景生成。左侧模块从大规模数据集 (highD、nuScenes) 中学习运动先验, 并将多智能体交互编码为潜在变量 z 。中间模块解析场景语义, 并采用思维链提示生成自适应损失提示。高级控制器将这些提示与风险场模型集成, 该模型计算全向风险指标和梯度反馈, 动态调整损失权重 ($L_{\text{AdversarialCrash}}$, $L_{\text{MinDist lat}}$, L_{YawRate} , L_{TTC})。右侧模块重塑潜在空间, 以生成覆盖低、中、高风险区域的场景, 从而产生连续的风险感知驾驶交互分布。

3.2. 使用CVAE-GNN学习交通先验知识

为了生成现实且多样的交通场景, 我们构建了一个深度生成模型, 该模型从真实交通数据中学习潜在分布, 并从中采样以合成新的轨迹。基于STRIVE (Rempe等人, 2022年), 这个生成先验是构建安全关键场景的基础。通过在潜在空间中进行优化, 该框架确保生成的轨迹保持物理可行性, 同时表现出可控水平的交互风险。

我们采用变分自编码器 (CVAE) 作为核心生成器, 并将图神经网络 (GNN) 集成到其编码器中 (Rahmani 等人, 2023), 以捕获复杂的多智能体依赖关系。在这种公式中, 车辆被表示为节点, 而它们之间的成对关系, 如距离、相对速度和潜在冲突区域, 则被编码为边。通过消息传递, 编码器聚合关系信息, 并生成一个捕获随机但结构化的交通动态的潜在变量 $z \sim \mathcal{N}(\mu, \sigma^2)$ 。然后解码器重建空间上连贯且运动学上一致的智能体轨迹。将场景生成建模为潜在空间中的优化过程, 使框架能够在真实性、行为多样性和对抗性挑战之间取得平衡, 提供了一种在连续风险谱中表示安全关键交互的原则性方法。自然交通中的高风险行为——如变道、合并和激进操作——在城市和高速公路环境中都会发生。为了捕获这种多样性, 我们的实现同时在 nuScenes 和 highD 数据集上进行联合训练。nuScenes 涵盖复杂的城市道路和交叉口, 具有丰富的多模态上下文, 而 highD 提供高频高速公路轨迹, 具有平滑和连续的运动。我们通过与 highD 重建车道结构并将其栅格化为以自车为中心的局部网格图来改进地图处理模块。这确保了生成的场景保持上下文一致性, 并能适应不同的道路几何形状。组合数据集

使用使模型能够在交通域中泛化，涵盖从城市交叉口到高速高速公路交互的安全关键条件。

3.2.1. CVAE模型架构

作为核心轨迹生成模型，CVAE负责从车辆轨迹数据及其在交通数据中的交互中学习低维潜在空间 Z ，然后解码该潜在空间 Z 以生成目标轨迹场景。该架构由三个主要组件组成：

编码器网络 $q_\phi(z | X, \mathcal{M})$ ：编码器将高维输入数据，即所有智能体的历史轨迹 X 和地图信息 $\mathcal{M}$ ，映射到潜在空间 Z 。具体来说，它估计潜在变量 z 的后验高斯分布的参数，包括均值 μ_z 和方差 σ_z^2 ：

$$\mu_z, \log \sigma_z^2 = \text{Encoder}_\phi(X, c), \quad (1)$$

其中 Encoder_ϕ 是参数化为 ϕ 的编码器网络， c 是从 $\mathcal{M}$ 推导出的上下文向量， (μ_z, σ_z^2) 参数化近似后验分布 $q_\phi(z | X, \mathcal{M})$ 。

解码器网络 $p_\theta(Y | z, \mathcal{M})$ ：解码器负责轨迹生成。采样一个潜在向量 $z \sim \mathcal{N}(\mu_z, \sigma_z^2)$ ，在 z 和地图特征 $\mathcal{M}$ 的条件下，解码器为所有智能体生成联合未来[^]轨迹 Y ：

$$\hat{Y} = \text{Decoder}_\theta(z, c), \quad (2)$$

[^]其中 Decoder_θ 是由 θ 参数化的解码器网络，而 Y 表示在 z 和 c 条件下的预测未来轨迹。

先验网络 $p_\psi(z | \mathcal{M})$ ：先验网络仅基于地图上下文 $\mathcal{M}$ 估计潜变量 z 的先验分布。在训练过程中，该网络作为正则化项，使后验分布与学习到的先验分布对齐：

$$\mu_{\text{prior}}, \sigma_{\text{prior}} = \text{Prior}_\psi(c), \quad (3)$$

其中 Prior_ψ 是由 ψ 参数化的先验网络，而 $(\mu_{\text{prior}}, \sigma_{\text{prior}})$ 定义了先验分布。

损失函数 $\mathcal{L}_{\text{CVAE}}$ ：整体损失函数由一个重建项、一个 Kullback-Leibler (KL) 散度项和一个基于交互的碰撞项组成：

$$\mathcal{L}_{\text{CVAE}} = \mathcal{L}_{\text{recon}} + w_{\text{KL}} \mathcal{L}_{\text{KL}} + w_{\text{coll}} \mathcal{L}_{\text{coll}}, \quad (4)$$

其中 w_{KL} 和 w_{coll} 是权重系数。各个损失分量定义为：

$$\mathcal{L}_{\text{recon}} = -\mathbb{E}_{q_\phi(z|X,c)} [\log p_\theta(X | z, c)], \quad (5)$$

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(z | X, c) \| p(z | c)), \quad (6)$$

$$\mathcal{L}_{\text{coll}} = f_{\text{collision}}(\hat{Y}), \quad (7)$$

$\mathcal{L}_{\text{recon}}$ 衡量重建保真度， $\mathcal{L}_{\text{KL}}$ 通过将后验与先验对齐来强制对潜在空间进行正则化，而 $\mathcal{L}_{\text{coll}}$ 惩罚物理上不可行的结果，例如智能体之间的碰撞。这些术语共同确保CVAE生成的场景既真实又具有风险敏感性。

3.2.2. 基于GNN的多智能体交互建模

遵循STRIVE框架，为了捕捉交通场景中的关系动态，我们将GNN集成到我们的模型架构中，以精确建模智能体之间的动态交互。

场景图构建：在每个时间步沿历史轨迹中，场景被表示为一个有向图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 。每个车辆被建模为一个节点 $v_i \in \mathcal{V}$ ，其关联的特征向量 $h_i^{(0)}$ 编码了其历史运动状态，包括位置、速度和航向。车辆 i 和 j 之间的交互通过边 $e_{ij} \in \mathcal{E}$ 表示，其特征描述了相对属性，如距离、速度差和潜在冲突度量。这种基于图的公式允许模型整合关于环境和智能体之间关系的信息结构。

消息传递机制：车辆交互的演化通过迭代更新节点表示来建模。在每个层 l 中，节点 i 的隐藏状态 $h_i^{(l)}$ 从其邻居 $\mathcal{N}(i)$ 聚合信息：

$$h_i^{(l+1)} = \text{Update} \left(h_i^{(l)}, \bigoplus_{j \in \mathcal{N}(i)} \text{Message}(h_i^{(l)}, h_j^{(l)}, e_{ij}) \right), \quad (8)$$

其中 $\text{Message}(\cdot)$ 定义了对来自邻居节点 j ， $\bigoplus$ 的信息应用的转换，聚合算子 $\bigoplus$ 表示如求和或平均， $\text{Update}(\cdot)$ 通常是多层感知器，用于细化节点 i 的状态。通过堆叠多层，GNN 捕获了通过间接连接产生的第一阶交互和更高阶依赖。

3.3. 基于LLM的知识引导损失函数优化

在CVAE框架中，生成逼真的轨迹依赖于有效塑造潜在空间分布 Z 。损失项的形式和权重决定了这种分布，进而影响生成行为的真实性和风险特性。为了实现可控且可解释的风险感知场景生成，损失函数必须根据上下文风险知识动态生成和优化，而不是使用固定权重。我们提出了一种由LLM驱动的知识引导推理框架，该框架生成和细化损失函数，以自适应地指导CVAE优化。如图2所示，该框架在场景理解、语义推理和潜在空间优化之间形成闭环。它由两个组件组成：一个知识引导场景理解模块，从非结构化输入中提取结构化风险线索；以及一个基于LLM的损失生成和优化模块，将这些线索转化为定量损失项和自适应权重系数。LLM解释场景语义，分析多智能体交互，并计算TTC、最小横向距离和曲率等风险指标。基于这些线索，它合成一组加权子损失函数，并调整其系数 w_i 以匹配检测到的风险上下文。总优化目标表示为

$$L_{\text{total}}(z) = \sum_i w_i L_i(\text{Decoder}(z, C)), \quad z^* = \arg \min_z L_{\text{total}}(z), \quad (9)$$

在生成的损失项确保收敛到物理可行且风险敏感的轨迹上。通过迭代推理和梯度反馈，LLM持续优化损失函数的结构和权重。解码器随后重建物理一致的轨迹 $Y = \text{Decoder}(z^*, C)$ ，这些轨迹跨越低风险、高风险和长尾风险区域，在CVAE-GNN框架内形成一个端到端的知识引导优化过程。

物理上自治，并跨越低风险、高风险和长尾风险状态，在 CVAE-GNN 框架内形成一个端到端的知识指导优化过程。




图2：知识引导的损失函数优化框架概述。LLM通过思维链推理解释场景语义和风险指标，计算自适应损失权重，并指导CVAE潜在空间优化，以生成物理一致且风险可控的交通场景。

3.3.1. 交通场景描述与分析

仅使用CVAE或固定损失函数难以平衡“真实性”和“可控风险分布”。为此，LLM对每个场景进行结构化推理，将异构输入转换为量化线索，指导CVAE优化过程中的损失自适应。该过程包括两个阶段：结构化场景描述和基于LLM的推理与评估。

场景描述输入。(1) 动态轨迹：车辆位置、速度和航向随时间变化，将数值坐标转换为文本描述以提高可读性。(2) 静态地图环境：道路几何形状、车道边界、交通信号和障碍物定义物理环境。

(3) 关系线索：车辆间距离、相对速度和潜在冲突区域，这些特征多智能体交互。

基于LLM的推理与评估。(1) 行为知识库：一个包含预定义行为（例如，跟车、变道、紧急制动）的库，涵盖低风险和高风险情况，由历史场景和多模态数据构建。(2) 思维链推理：一种结构化的多步分析，将场景分解为智能体行为、时空关系和风险指标（如TTC、最小距离和净空距离），识别可能演变为长尾风险的交互。(3) 结构化输出：LLM以机器可读形式表达推理结果，例如{"侧": "右",

"type": "剪切_in", "强度": 0.9}, 这些被传递到下游模块，例如基于字段的风险评估模型。(4) 自我评估：每个推理链都会被验证其逻辑完整性和一致性，并分配一个置信度分数来指示可靠性。

该分层过程将非结构化的场景描述转换为结构化、可优化的表示形式，使LLM能够动态指导损失加权，提高风险感知场景生成的可解释性和可控性。

3.3.2. 风险指标设计

根据3.3.1节中的语义推理，下一步是将高级行为意图转化为可在CVAE潜在空间中优化的定量目标。这需要识别风险最可能发生的地点，并量化交互的严重程度。为此，我们设计了一个风险指标模块，该模块集成了势场模型与辅助指标计算。

势场模型。用于风险点计算的势场模型将语义意图（例如，切入、突然制动）转化为具体的几何锚点。驾驶环境被表示为一个二维标量场，其中每个点 $p = (x, y)$ 具有势能 $U(p)$ 。总势能为

$$U_{\text{total}}(p) = w_{\text{rep}}U_{\text{rep}}(p) + w_{\text{attr}}U_{\text{attr}}(p), \quad (10)$$

其中 U_{rep} 编码碰撞和边界避让， U_{attr} 将自车吸引到与意图一致的区域，而 $w_{\text{rep}}, w_{\text{attr}} > 0$ 则平衡它们的影响。平衡点 $p^* = \arg \min_p U_{\text{total}}(p)$ 表示潜在高风险事件的最关键点。

辅助指标。尽管 p^* 可以本地化风险，但它并不能完全描述交互强度。因此，我们将其扩展为一个目标向量

$$\mathbf{T} = [p^*, d_{\text{lat}}^*, \text{TTC}^*, \kappa^*], \quad (11)$$

其中 (1) 最小横向间隙 d_{lat}^* 。较小的横向距离是切入或侧面碰撞的强烈指标。通过显式约束 d_{lat}^* ，我们确保生成的场景能够捕捉近距离交互，这些交互是避让动作的常见触发因素。(2) 碰撞时间 TTC^* 。 TTC 直接反映了交互的紧迫性。非常小的值（例如， ≤ 1 秒）表示关键、险些发生的状况，这些状况在真实数据中很少观察到，但对安全测试至关重要。显式针对 TTC^* 允许框架生成挑战自动驾驶系统响应时间的长尾案例。(3) 路径曲率 κ^* 。这描述了动作的几何难度，例如急转弯或转向轨迹。加入曲率确保场景既动态真实又物理一致。

通过结合基于字段的本地化与这些辅助指标，语义意图被锚定到一个结构化且可解释的目标向量 $\mathbf{T}$ 中。这种表示方式捕捉了风险交互发生的地点和方式，并作为后续损失权重生成的直接输入，将高级推理与轨迹级优化联系起来。

3.3.3. 基于LLM的长尾行为生成与损失优化

要生成长尾、安全关键场景，仅本地化风险点和计算指标是不够的；这些语义提示必须转化为直接塑造轨迹合成的优化目标。在我们的框架中，这个角色由LLM承担，它作为高级控制器。给定语义描述和指标向量 $\mathbf{T}$ ，LLM为不同的损失项分配权重，从而决定每个行为约束应如何影响潜在空间优化。例如，当 TTC^* 极小时，会增加 TTC 惩罚的权重以强制紧急交互，

而狭窄的 d_{lat}^* 则会提高横向距离惩罚的权重以诱导近距离切入。通过这种方式，抽象的语义风险被转化为具体的优化信号，使轨迹生成偏向高风险区域。

为提高一致性和可解释性，LLM 被提供了可用损失函数的结构化定义以及一个包含代表性 {场景, 权重} 示例的紧凑语料库。这使得模型能够从规范交通行为（例如超车、突然制动）泛化到新的风险组合，从而实现少样本推理。输出是一个权重向量 $\mathbf{w}$ ，它平衡了对抗性挑战与物理合理性。通过这种机制，非结构化场景描述被系统地转化为可操作的优化目标，连接了高级推理和低级轨迹生成。

在基于 CVAE 的生成器中，潜在变量 $\mathbf{z} \in \mathcal{Z}$ 通过解码器参数化轨迹 $\mathbf{X}' \in \mathcal{X}$ ：

$$\mathbf{X}' = \text{Decoder}(\mathbf{z}, \mathbf{C}), \quad (12)$$

其中 $\mathbf{C}$ 表示上下文信息，例如道路几何形状或周围车辆。这种映射是可微分的，确保 $\mathbf{z}$ 的变化会传播到生成的轨迹。

总目标是由多个设计项的加权求和组成：

$$\mathcal{L}_{\text{total}}(\mathbf{z}) = \sum_{i=1}^n w_i \mathcal{L}_i(\text{Decoder}(\mathbf{z}, \mathbf{C})), \quad (13)$$

其中每个 $\mathcal{L}_i$ 编码一个属性，例如碰撞接近度、碰撞时间或运动学平滑度，而 w_i 是 LLM 分配的权重。优化寻求

$$\mathbf{z}^* = \arg \min_{\mathbf{z}} \mathcal{L}_{\text{total}}(\mathbf{z}),$$

确保轨迹既符合现实，又满足期望的风险水平。

当引入新的行为先验时，目标变为：

$$\mathcal{L}'_{\text{total}}(\mathbf{z}) = \mathcal{L}_{\text{total}}(\mathbf{z}) + w_{\text{new}} \mathcal{L}_{\text{new}}(\text{Decoder}(\mathbf{z}, \mathbf{C})). \quad (14)$$

这会修改指导优化的梯度场：

$$\nabla_{\mathbf{z}} \mathcal{L}'_{\text{total}}(\mathbf{z}) = \nabla_{\mathbf{z}} \mathcal{L}_{\text{total}}(\mathbf{z}) + w_{\text{new}} \nabla_{\mathbf{z}} \mathcal{L}_{\text{new}}(\mathbf{z}), \quad (15)$$

其中附加项通过链式法则计算：

$$\nabla_{\mathbf{z}} \mathcal{L}_{\text{new}}(\mathbf{z}) = \frac{\partial \mathcal{L}_{\text{new}}}{\partial \mathbf{X}'} \frac{\partial \mathbf{X}'}{\partial \mathbf{z}}, \quad \mathbf{X}' = \text{Decoder}(\mathbf{z}, \mathbf{C}). \quad (16)$$

最后，在学习率 $\eta > 0$ 下，潜在更新变为：

$$\mathbf{z}_{t+1} = \mathbf{z}_t - \eta (\nabla_{\mathbf{z}} \mathcal{L}_{\text{total}}(\mathbf{z}_t) + w_{\text{new}} \nabla_{\mathbf{z}} \mathcal{L}_{\text{new}}(\mathbf{z}_t)). \quad (17)$$

公式(17)表明，由LLM推导的系数加权的新损失项，使优化路径偏向满足附加行为先验的区域。因此，系统收敛到一个新的

平衡原始目标与风险敏感要求的平衡点 z'^* 。这种设计建立了从语义风险描述到可微分的优化的直接管道。通过结合LLM驱动的权重分配与潜在空间梯度更新，该框架系统地生成在风险水平连续体上对抗但可行的轨迹。

3.4. 用于对抗且可行的轨迹的复合目标

我们目标轨迹用于测试，需物理一致且与环境几何兼容。我们将目标分解为三组，

$$\mathcal{L}_{\text{total}} = \alpha_1 \mathcal{L}_{\text{traj}} + \alpha_2 \mathcal{L}_{\text{geom}} + \alpha_3 \mathcal{L}_{\text{interact}}, \quad (18)$$

其中 $\mathcal{L}_{\text{traj}}$ 捕获单智能体运动学， $\mathcal{L}_{\text{geom}}$ 强制地图和几何一致性， $\mathcal{L}_{\text{interact}}$ 编码多智能体交互和对抗意图。系数 α_i 由结构化风险评估设定，反映安全关键事件标准，而非临时调优。

3.4.1. 具有碰撞感知的物理约束

点到点碰撞损失：我们将本车前部拉向目标车后部以诱导追尾接触：

$$\mathcal{L}_{\text{collision-point}} = \|\mathbf{p}_{\text{ego}}^{\text{front}} - \mathbf{p}_{\text{victim}}^{\text{rear}}\|_2. \quad (19)$$

此处 $\mathbf{p}_{\text{ego}}^{\text{front}}, \mathbf{p}_{\text{victim}}^{\text{rear}} \in \mathbb{R}^2$ 或 $\mathbb{R}^3$ 表示保险杠中心位置。由此产生的梯度提供强连续拉力以实现物理接触。当与方向或速度控制项结合以塑造接近轮廓时，该损失有效。

侧面碰撞最小距离损失：为了引发横向碰撞，我们将本车前方吸引至受害者身体的最近点：

$$\mathcal{L}_{\text{side-impact}} = \min_{\mathbf{p} \in \mathcal{B}_{\text{victim}}} \|\mathbf{p}_{\text{ego}}^{\text{front}} - \mathbf{p}\|_2, \quad (20)$$

其中 $\mathcal{B}_{\text{victim}}$ 是受害者几何形状的边界框代理。内部最小化更新目标点以随几何形状演变，产生动态目标追踪行为，适用于T型碰撞和激进切入场景。

3.4.2. 行为一致性及交互目标

碰撞时间惩罚：当估计的碰撞时间（TTC）低于阈值时，我们惩罚不安全的接近速率：

$$\mathcal{L}_{\text{TTC}} = \max(0, T_{\text{safe}} - \text{TTC})^2. \quad (21)$$

这里 T_{safe} 是安全裕度，例如2秒，TTC沿视线方向根据相对速度计算。二次惩罚加强了临界边界附近的梯度，这有助于优化器在对抗性搜索中从安全区域过渡到接近碰撞区域。

横向间隙调整：我们减少车辆之间的自由横向间隙，以引发具有挑战性的交互：

$$\mathcal{L}_{\text{lat}} = k (d_{\text{lat-gap}})^2, \quad (22)$$

with

$$d_{\text{lat-gap}} = d_{\text{lat}} - \left(\frac{w_{\text{ego}}}{2} + \frac{w_{\text{target}}}{2} \right). \quad (23)$$

其中 d_{lat} 表示车辆中心距, w_{ego} 和 w_{target} 表示车辆宽度, $k > 0$ 是一个权重。平滑的二次型支持稳定的梯度。当 $d_{\text{lat-gap}} \rightarrow 0$ 时, 边缘接近接触, 负值表示重叠, 这对应于碰撞。

横摆角速度侵略性: 我们鼓励剧烈、不舒适的转向以测试控制器:

$$\mathcal{L}_{\text{yaw}} = \frac{1}{\max(0, |\omega| - \omega_{\text{thresh}}) + \epsilon}, \quad (24)$$

其中 ω 是计划的横摆角速度, ω_{thresh} 是舒适阈值, $\epsilon > 0$ 避免除零错误。逆形式在 $|\omega| \leq \omega_{\text{thresh}}$ 时会产生较大惩罚, 并且当 $|\omega|$ 超过阈值时会衰减, 这激励在对抗性生成期间进行高侵略性操作。

公式 (19)–(24) 形成了交互、邻近性和操作侵略性的互补方面。结合在 (18) 中, 它们揭示了清晰的、可微分的路径, 梯度可以通过 (16) 和 (17) 从高级行为先验流向潜在更新。这种设计能够针对评估生成具有物理可行性且安全关键的可重复场景。

3.5. 跨风险场景生成与分布控制

优化的 CVAE-LLM 框架不仅支持逼真的轨迹生成, 还支持跨不同交通条件进行可控的风险调节。为确保生成的场景系统地覆盖从正常到极端长尾事件的整个风险范围, 我们建立了一个统一的风险定义和动态分布控制策略。

风险等级定义: 为全面评估自动驾驶安全性, 场景被分为三个等级: 低风险、高风险和长尾风险, 如表1所示。这些代表从稳定、日常交通到罕见但安全关键事件的连续谱系。

表1: 场景风险等级的定义和示例

等级	关键特征	示例
低风险	稳定流, 足够裕量, 交互最小化。	车头距保持, 巡航, 合规 lane 变道。
高风险	强相互作用, 短反应时间, 安全关键差距。	突然制动, 密集切入, 遮挡交叉。
长尾	罕见、极端或对抗性事件。	非常短的TTC, 滑行, 高速振动。

动态风险控制: 数据驱动生成器倾向于重复低风险分布, 这不足以评估安全边界。为解决此限制, 我们设计了一个闭环控制流程, 动态平衡不同风险等级场景的比例, 如表2所示。风险评估使用定量指标, 包括: (1) TTC (碰撞时间), 表示在当前速度下两个智能体碰撞前的剩余时间; (2) THW (车头时距), 指与前车的纵向时间距离; (3) TLC (换道时间), 测量当前运动状态下的横向稳定性。

该领域模型持续监控这些指标以识别风险转换并指导采样过程。当风险指标低于预定义阈值（参见表格 2）时，模型通过调整潜在采样和损失权重来触发高风险场景生成。该机制确保生成的场景在低风险、高风险和长尾条件下均保持多样性和可控覆盖范围。因此，风险驱动控制机制使框架能够生成平衡、物理一致且安全关键的交通场景，支持在交互强度和风险暴露程度不同的条件下对自动驾驶系统（ADS）进行全面验证。

表2: 场景风险等级的定量阈值

风险等级	TTC (s)	TLC (s)	THW (s)
低风险	$\geq 5-7$	$\geq 1.5-2.0$	$\geq 2.5-3.0$
高风险	1.5-3.0	0.8-1.5	1.0-2.5
长尾事件	≤ 1.5 (尤其 ≤ 1.0)	≤ 0.8 (尤其 $\leq 0.5-0.6$)	≤ 1.0 (尤其 $\leq 0.5-0.7$)

4. 实验与结果分析

本节介绍了所提出的框架的实验评估及其在生成安全关键场景方面的有效性。我们首先评估 CVAE 模块，以验证其生成逼真且多样化的基础场景的能力，作为后续优化的基础。然后，我们评估 LLM 驱动的推理如何在不同风险级别下增强对抗性生成，特别是在覆盖长尾事件方面。因此，实验重点关注三个方面：

(1) CVAE 生成的场景在多个数据集上的逼真性和多样性；(2) LLM 指导优化对风险敏感生成的贡献；(3) 长尾覆盖率和系统鲁棒性的整体提升。

4.1. 数据集和预处理

我们的实验在两个大规模自然驾驶数据集上进行：highD 和 nuScenes，它们共同涵盖了从结构化高速公路到复杂城市交叉口的多样化交通环境。

- highD。该数据集在德国高速公路上使用无人机收集，提供了高频车辆轨迹，捕捉了结构化交通中的变道、合并和其他高风险操作。静态航拍图像被转换为两层（可行驶区域和车道分隔线），并矢量化为以自车为中心的 420×100 米局部地图，分辨率为每米 2 个像素。
- nuScenes。在新加坡和波士顿的城市中录制，nuScenes 提供多模态传感器数据、动态物体标注以及覆盖交叉路口、弯曲道路和遮挡城市区域的详细高清地图。车道分隔线、停止线和交通信号等矢量化的地图元素被直接整合到预处理流程中，以保持空间和语义的一致性。

这种统一的预处理使 CVAE 能够学习一个共享的潜在表示，该表示能够捕捉结构化高速公路运动和复杂的城市交互，为风险感知场景生成和分布控制提供多样化的基础。

4.2. 模拟环境和基准

为了评估在闭环环境中生成的场景的有效性，我们在两个在关注点和保真度上互补的主流仿真平台上进行实验：

- CARLA：一个高保真度的模拟器，提供逼真的物理和视觉渲染效果，用于在接近真实世界条件下评估自动驾驶系统（ADS）的感知和决策性能。
- SMARTS：一个可扩展的多智能体模拟器，强调交互式交通流和行为多样性，适用于在密集、动态环境中测试ADS的战略推理和协作能力。

此外，为了突出框架的优势，建立了两个基准设置进行比较。

- 基准场景：由CVAE直接生成的场景，无需LLM指导。这作为主要基准用于量化LLM的增量贡献。该基准集成了VAE和GNN，GNN编码历史轨迹和上下文场景信息，以自回归方式生成未来轨迹序列。生成过程受复合损失函数约束，具有固定的经验权重系数(w_1, w_2, w_3)，无法自适应调整不同的风险水平。作为一个纯粹的数据驱动模型，它可能产生统计上合理但物理上不可行的轨迹，并且其泛化到紧急避让等罕见的“长尾”场景仍然有限。

- 参数扰动：一种在基础场景中对关键运动参数（例如，车辆加速度、变道持续时间）引入随机扰动的基线方法。尽管此方法通过参数噪声提供有限的变异性，但它仍然是场景无关的，缺乏语义理解，这说明了LLM引导的自适应优化相对于原始方法的优越性

随机扰动。

4.3. 评估指标

为了全面且定量地评估所提出的两阶段场景生成框架，我们在四个维度上定义了关键指标：轨迹真实性、交互一致性、长尾事件覆盖率和对物理合理性违反的鲁棒性。

轨迹真实性：轨迹真实性衡量CVAE生成的轨迹与真实世界轨迹之间的相似度。我们定义一个复合真实性得分 TR 为多个子指标的加权平均值：

$$TR = \frac{1}{n} \sum_{i=1}^n M_i, \quad M_i = Z_m + Z_t + Z_s + Z_{ms} + Z_{tc}, \quad (25)$$

n 表示子指标的个数。 Z_m 表示对抗样本和原始样本在潜在空间中的偏差距离， Z_t 表示对抗潜在分布的标准差， Z_s 是先验下对抗变量的对数似然分数， Z_{ms} 衡量运动学平滑度（例如，加加速度）， Z_{tc} 量化轨迹的几何连续性。

交互一致性：交互一致性确保对抗场景中的车辆交互在物理上合理且逻辑上连贯。我们定义一个复合交互分数 I ：

$$I = \frac{1}{5}(D_r + V_c + P_r + S_c + C_r), \quad (26)$$

D_r 表示车辆间距离的合理性， V_c 捕捉速度的连续性， P_r 反映对不可行操作的概率推理， S_c 表示交互车辆间的空间一致性，而 C_r 用于平衡碰撞风险。例如， D_r 确保车辆间距离保持在合理范围内，避免不切实际的重叠或过度分离。

长尾事件覆盖率：为了量化生成场景覆盖长尾事件的能力，我们基于预定义的度量系统评估场景。如果生成场景同时满足表2中定义的所有三个“长尾”相关指标的阈值要求，则将其识别为长尾事件。我们定义长尾覆盖率（LCR）为满足三个长尾指标阈值的场景比例。具体来说，

$$\text{LCR} = \frac{|\{s \in \mathcal{S} \mid I_1(s) \geq \tau_1, I_2(s) \geq \tau_2, I_3(s) \geq \tau_3\}|}{|\mathcal{S}|}, \quad (27)$$

其中 I_1 、 I_2 、 I_3 是表2中描述的度量函数， τ_1 、 τ_2 、 τ_3 是它们的相应阈值，而 $|\cdot|$ 表示集合的基数。

Sim-to-Real：该指标旨在量化生成轨迹与真实世界数据之间的差异，确保生成场景的真实性。我们从四个维度评估Sim-to-Real差距：统计分布、运动特征、频域特性和高级语义行为

$$\text{STR} = \frac{1}{4}(G_{\text{dist}} + G_{\text{motion}} + G_{\text{freq}} + G_{\text{sem}}), \quad (28)$$

其中 G_{dist} 计算模拟轨迹 ($\mathcal{T}_{\text{sim}}$) 与真实轨迹 ($\mathcal{T}_{\text{real}}$) 在关键运动学特征分布上的差异； G_{freq} 测量基本运动学统计上的差异； G_{sem} 通过比较频域中轨迹的特征来评估运动的平滑度和周期性；评估高级驾驶行为模式中的频率差异。

4.4. 基础场景生成验证

我们在引入任何对抗性精炼之前，首先评估CVAE模块。如表3所示，CVAE在highD和InuScenes上均实现了均方误差低于 0.5 m^2 ，表明空间重建准确。加速度分布的KL散度保持在 $[1.08, 2.75]$ 以内，曲率KL低于0.30，证实生成轨迹保留了真实车辆动力学的主要统计特性。

这些结果表明，CVAE-GNN学习到了一个稳定且结构化的潜在空间，能够在高速公路和城市环境中重现多样且物理一致的动态模式。定性检查进一步显示了连贯的保持车道、合并和变道行为，表明该模型捕捉了基本的多人交互模式。这种高质量的生成先验对于后续的LLM引导优化至关重要。由于潜在空间已经具有物理基础和分布一致性，对抗优化过程保持稳定可控，使整个框架能够在不产生不切实际伪影的情况下探索高风险区域。

表3: 高D和nuScenes上CVAE基础场景生成的定量评估

指标	nuScenes	高D	描述
MSE (m ²) ↓	0.460	0.420	轨迹重建误差
加速度 KL ↓	2.75	1.08	加速度分布的 KL 散度
曲率 KL ↓	0.17	0.26	曲率分布的 KL 散度

4.5. 基于LLM的对抗增强评估

我们评估了基于LLM的对抗推理模块的有效性，该模块作为智能引擎来优化风险敏感场景并让ADS暴露于罕见但关键的交互。在CARLA中总共进行了120次模拟试验，涵盖了交通风险案例（TRC）和相对安全的条件。

整体性能。表4比较了不同的场景生成方法。所提出的CVAE+ LLM框架实现了22.8%的最高长尾事件覆盖率，超过了仅CVAE基线（17%）和CVAE + 扰动变体（21.6%）。同时，轨迹真实性（52.34%）、交互一致性（75.4%）和仿真到现实的可迁移性（51.1%）与基线水平相当。这表明基于LLM的推理在有效扩展稀有、高风险事件覆盖范围的同时，并未牺牲生成轨迹的真实性或连贯性。

表4: 不同场景生成方法的性能比较

方法	长尾 事件覆盖率 (%) ↑	轨迹 现实主义 (%) ↑	交互 一致性 (%) ↑	模拟到真实 (%) ↑
仅CVAE (基础)	17.0	53.9	75.5	49.8
CVAE + 扰动	21.6	50.0	73.0	46.7
CVAE + LLM (我们)	22.8	52.3	75.4	51.1

表5: 长尾事件生成能力对比

方法	激进切入	不安全合并	危险变道
CVAE-Only (基础)	21.0	15.8	15.8
CVAE + LLM (我们)	35.9	20.5	25.6

注意：数值表示 prop 部分 g 被识别为长尾事件的生成场景。覆盖率 (%) 越高表示合成罕见、安全关键交互的能力越强。

长尾事件多样性。如表5所示，基于LLM的优化显著提高了高风险和罕见交互的覆盖率。具体而言，激进切入的比例从21.0%上升到35.9%，不安全合并从15.8%上升到20.5%，危险变道从15.8%上升到25.6%。这些结果表明行为谱系得到了拓宽，涵盖了基线随机采样很少捕捉到的关键驾驶模式。长尾覆盖率约增加40%证实了对抗推理机制有效地将生成推向具有挑战性和安全关键性的子空间。

场景风险的对立影响。表6比较了LLM增强的极端挑战性场景（TRC）和相对安全的基线场景之间的关键性能指标。

碰撞率在LLM增强组中达到97.1%，而在基线组中为96.2%，证实了关键交互频率更高。平均TTC从0.89秒急剧下降到0.34秒，而车辆之间的平均距离从3.03米缩小到0.30米。类似地，横向TLC从7.05秒降至4.91秒，表明横向冲突动态加剧。尽管平均THW从1.72秒增加到3.84秒，但这反映了由于高频避让动作导致的间距控制中的时间波动。这些指标共同验证了LLM指导的推理在保持物理真实性的同时，成功放大了对立风险暴露。

表6: LLM增强场景与基准场景下关键性能指标对比

性能指标	极具挑战性 (LLM增强, TRC)	相对安全 (基准响应)
碰撞率 (%) ↑	97.1	96.2 (-0.9)
平均总价 (秒) ↓	0.34	0.89 (+0.55)
平均总时长 (秒) ↓	4.91	7.05 (-2.14)
平均距离 (米) ↓	0.30	3.03 (+2.73)
平均THW (秒) ↓	3.84	1.72 (-2.12)

注意: ↑ 表示高 g她的数值更好 ; ↓ 表示数值越低越好。蓝色数值表示增加, 红色数值表示相对于基线的减少。

总体而言，结果表明基于LLM的对抗推理显著增强了框架发现稀有但重要的场景的能力。与传统的CVAE或随机扰动方法相比，所提出的方法将长尾事件覆盖率提高了30-40%以上，拓宽了行为多样性，并使ADS面临更激烈的纵向和横向冲突（如TTC和车辆间距离的减少所示）。同时，真实性和交互一致性保持稳定，证实了这种增强源于智能对抗推理而非随机干扰。生成的场景涵盖了广泛的高风险行为，包括超速、错道驾驶、激进合并和迎头超车，为在长尾条件下进行安全验证提供了全面且具有挑战性的基准。

4.6. 生成风险场景的定性分析

图3展示了所提出的LLM引导框架生成的典型长尾场景，展示了车辆交互如何在不同冲突类型和风险水平下演变。可视化包括三类——合并、转向和交叉口冲突——每类都在 $T = 0\text{s}$ 、 3s 和 6s 时随时间演变。TTC和THW的变化清晰地说明了正常交互如何逐渐升级为接近碰撞状态。(a) 合并冲突：最初($T = 0\text{ s}$)，两辆车保持适度的安全距离 ($TTC \approx 3.5\text{ s}$, $THW \approx 2\text{ s}$)。当其中一辆进行意外合并时，TTC和THW降至 1.5 s 和 1 s ，并在强制切入和减速期间最终降至 0.4 s 和 0.2 s ，标志着从安全跟随到高风险交互的明显转变。(b) 转向冲突：两辆车在交叉口执行平行左转。由于横向运动，TTC未定义，但THW从约 3 s 降至 1.6 s ，反映了由于有限可视性和路权模糊而加剧的近距离。(c) 交叉口冲突：多辆车通过相反、顺序和迎头路径汇聚。当它们接近交叉口中心时，TTC和THW急剧下降（例如， $THW \approx 0.2\text{ s}$ ），留下极少的反应时间，形成接近碰撞条件。总体而言，这些结果表明所提出的框架能够




图3：长尾交通场景中车辆交互的演化。行对应冲突类型：(a) 合并，(b) 转弯，以及 (c) 交叉口；列展示在 $T = 0, 3$ 和 6 秒时的时序演化。TTC 和 THW 说明了从安全到接近碰撞状态的进展，突出了该框架生成动态、风险敏感交互的能力。

在保持空间和运动学一致性的同时重现真实的时序风险升级。能够综合这种演变的、高风险场景，为其在 ADS 安全关键评估中的有效性提供了强有力的定性证据。

图4展示了原始安全轨迹与其LLM生成的长尾对应物之间的典型比较。每对（左侧：原始，右侧：LLM驱动）说明了该框架如何通过解释场景语义和自适应优化风险敏感目标，将正常驾驶行为转化为安全关键交互。场景（a-c）表示从低风险到高风险条件的过渡。在（a）中，自车最初沿车道减速，突然向左转并截断对向车辆，形成左转冲突。在（b）中，两辆依次向左转的车辆被加速的右侧车辆和越过车道的掉头车辆干扰，形成多车转向冲突。在（c）中，一辆车辆为避开停放的卡车减速，被快速接近的车辆追尾，形成高风险碰撞。




图4：原始场景与LLM驱动场景的对比。每对图展示了框架如何将安全的轨迹（左）转化为高风险的长尾事件（右）：(a) 左转冲突；(b) 多车转弯冲突；(c) 追尾碰撞；(d) 道路入口冲突；(e) 突然减速；(f) 交叉路口多智能体风险。LLM引导的过程解释场景语义并自适应优化风险目标，以重现真实多样的安全关键交互。

场景（d-f）展示了更复杂的多智能体交互。在（d）中，一辆停放的车辆突然启动并向左转入车流，产生路边进入冲突。在（e）中，两辆同向行驶的车辆同时减速并停车，形成接近碰撞事件。在（f）中，几辆车在十字路口同时变道和转向路径，导致强制入侵、突然减速，




图 5：新加坡 One-North 城市交叉口长尾风险识别与生成的案例研究。主车在涉及静止和移动车辆的多个智能体交互下执行左转。底部流程图展示了五个步骤：(1) 场景识别，(2) 风险指标计算，(3) 行为选择，(4) LLM 引导的场景生成，以及 (5) 验证。该流程结合了定量指标（TTC、THW、TLC、距离）与推理，以生成逼真的长尾交通场景。

以及重叠风险。这些结果表明，LLM 引导的框架可以将安全轨迹演变为多样化、高风险的情况，同时保持行为真实性和物理可行性，为评估 ADS 在罕见但关键的交互下的安全性提供了广泛的场景。

图5展示了一个案例研究，说明了所提出的LLM引导框架的长期风险识别和场景生成过程。该场景位于新加坡的One-North城市交叉口，其中主车执行左转，并与六个周围车辆在部分遮挡下交互。最初，主车向南行驶，速度约为4 m/s，左前方有一个静止障碍物，东北方向有一个以4.6 m/s速度驶来的对向车辆。随着交互的演变，主车加速至5.4 m/s，在转弯、对向和静止车辆之间产生了复杂的时空耦合。图的下部展示了五步推理流程：(1) 识别所有动态和静态参与者；(2) 计算关键指标，如TTC、THW、TLC和距离；(3) 分析主车与车辆的关系并选择长期风险案例；(4) 在LLM引导下生成行为，以合成可能的高风险交互；(5) 验证物理和语义一致性。该案例研究突出了框架如何将定量指标与基于语言的推理相结合，以重现稀有但现实的长期交互，从而将数据驱动理解与可解释、可控的场景合成相结合。




图6：在城市停车场环境中LLM指导的长尾场景生成。原始场景包含四辆车合规低速行驶。框架通过量化指标（TTC、最小距离、THW）识别出高风险的驾驶舱-车辆2对，并通过 +2.0 m/s调整车辆2的速度，模拟激进的后方右切入。最终交互在物理上可行且语义有效，实现85%场景成功概率和0.88置信度评分，展示了安全关键行为的可控合成示例。

长期风险交互，将数据驱动理解与可解释、可控的场景合成相结合。

图6展示了一个城市停车场环境中的LLM指导生成示例，说明一个正常低风险情况如何通过语义推理和风险敏感优化演变为高风险激进切入场景。原始场景包含四辆车低速合规行驶，驾驶舱车辆以约5.3 m/s速度开始左转轨迹，而周边车辆保持适当间距。

在步骤1中，系统识别所有动态参与者及静态元素，构建场景的结构化表示。步骤2计算关键风险指标，包括TTC、最小距离和THW。车辆2与主车的配对超过了定义的风险阈值，表明存在潜在危险。在步骤3中，LLM通过 +2.0 m/s调整车辆2的速度，模拟更激进的操作，同时确保物理可行性和遵守交通逻辑。结果，车辆2向主车路径执行右后切入，形成临界近距离条件。最终，生成的行为被标记为“激进切入”事件，场景成功概率为85%，置信度为0.88。此案例证实，LLM引导的推理不仅增强了场景真实性，还实现了对安全关键交互的可控合成，这些交互保留了运动学有效性和上下文一致性。生成的场景为评估ADS在受限、近碰撞条件下的响应能力和安全裕度提供了有效的基准。

5. 结论

本文介绍了“从风险中学习”（Learning from Risk），这是一个通过将CVAE与aLLM集成而生成安全关键交通场景的高保真框架。该框架针对稀有长尾事件和复杂

本文提出了“从风险中学习”（Learning from Risk）这一高保真框架，通过将CVAE与aLLM集成，生成安全关键型交通场景。针对自然数据集中稀有长尾事件和复杂多智能体交互的匮乏问题，该框架统一了数据驱动结构学习与知识引导推理，以实现物理一致性、行为真实性和风险敏感性场景生成。CVAE-GNN模块从highD和nuScenes数据集中学习潜在交通动态，能够合成跨高速公路和城市环境的多样化基础场景。在此基础上，LLM解析场景描述，分析交互模式，并自适应调整损失函数，以生成系统性地覆盖多级风险水平的场景。在CARLA和SMARTS中的实验表明，所提出的框架在基础轨迹上实现了低重建误差和高分布保真度，同时显著提升了长尾事件覆盖率，并生成了多样化的对抗性交互，如激进变道、不安全合并和近碰撞遭遇。与基线方法相比，该框架始终能生成更真实、更具挑战性的场景，揭示ADS的潜在脆弱性，为风险敏感性安全验证提供了一种原则性工具。未来工作将扩展框架至实时闭环测试，并整合天气和道路条件等环境因素，以在更多样化的环境下模拟长尾事件。此外，还将探索在LLM驱动的权重过程中缓解潜在的物理或语义幻觉问题，以确保轨迹真实性并提升框架在异构交通领域的可靠性。

作者贡献

王宇航：软件、可视化、验证、写作——审阅与编辑。黄鹤业：概念化、方法论、形式分析、写作——初稿、可视化。徐振华：形式分析、写作——审阅与编辑。孙凯来：研究、可视化、验证。郭宝申：数据管理、研究、写作——审阅与编辑。赵金花：监督、概念化、写作——审阅与编辑。

利益冲突声明

作者声明他们没有已知的利益冲突或个人关系可能影响本论文报告的工作。

数据可用性

数据将在要求时提供。

参考文献

- Aiersilan, A. (2025). Generating traffic scenarios via in-context learning to learn better motion planner. In *Proceedings of the AAAI Conference on Artificial Intelligence* (pp. 14539–14547). volume 39.
- Bergamini, L., Ye, Y., Scheel, O., Chen, L., Hu, C., Del Pero, L., Osinski, B., Grimmert, H., & Ondruska, P. (2021). Simnet: Learning reactive self-driving simulations from real-world observations. In *2021 IEEE International Conference on Robotics and Automation (ICRA)* (pp. 5119–5125). IEEE.
- Bock, J., Krajewski, R., Moers, T., Runde, S., Vater, L., & Eckstein, L. (2020). The ind dataset: A drone dataset of naturalistic road user trajectories at german intersections. In *2020 IEEE Intelligent Vehicles Symposium (IV)* (pp. 1929–1934). IEEE.

- Caesar, H., Bankiti, V., Lang, A. H., Vora, S., Liong, V. E., Xu, Q., Krishnan, A., Pan, Y., Baldan, G., & Beijbom, O. (2020). nuscenes: A multimodal dataset for autonomous driving. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 11621–11631).
- Chen, D., Zhu, M., Yang, H., Wang, X., & Wang, Y. (2024). Data-driven traffic simulation: A comprehensive review. *IEEE Transactions on Intelligent Vehicles*, 9, 4730–4748.
- Chen, K., Sun, W., Cheng, H., & Zheng, S. (2025). Rift: Closed-loop rl fine-tuning for realistic and controllable traffic simulation. *arXiv preprint arXiv:2505.03344*, .
- Deng, Y., Tu, Z., Yao, J., Zhang, M., Zhang, T., & Zheng, X. (2025). Target: Traffic rule-based test generation for autonomous driving systems. *IEEE Transactions on Software Engineering*, .
- Feng, S., Sun, H., Yan, X., Zhu, H., Zou, Z., Shen, S., & Liu, H. X. (2023). Dense reinforcement learning for safety validation of autonomous vehicles. *Nature*, 615, 620–627.
- Gao, Y., Piccinini, M., Zhang, Y., Wang, D., Moller, K., Brusnicki, R., Zarrouki, B., Gambi, A., Totz, J. F., Storms, K. et al. (2025). Foundation models in autonomous driving: A survey on scenario generation and scenario analysis. *arXiv preprint arXiv:2506.11526*, .
- Han, X., Yang, Q., Chen, X., Chu, X., & Zhu, M. (2024). Generating and evolving reward functions for highway driving with large language models. In *2024 IEEE 27th International Conference on Intelligent Transportation Systems (ITSC)* (pp. 831–836). IEEE.
- Hennigh, O., Narasimhan, S., Nabian, M. A., Subramaniam, A., Tangsali, K., Fang, Z., Rietmann, M., Byeon, W., & Choudhry, S. (2021). Nvidia simnet™: An ai-accelerated multi-physics simulation framework. In *International conference on computational science* (pp. 447–461). Springer.
- Hossain, A. (2025). A taxonomy and comprehensive survey of scenario generation for autonomous driving: Methods, challenges, and emerging trends in safety-critical testing, .
- Huang, H., Zheng, X., Yang, Y., Liu, J., Liu, W., & Wang, J. (2020). An integrated architecture for intelligence evaluation of automated vehicles. *Accident Analysis & Prevention*, 145, 105681.
- Krajewski, R., Bock, J., Kloeker, L., & Eckstein, L. (2018). The highd dataset: A drone dataset of naturalistic vehicle trajectories on german highways for validation of highly automated driving systems. In *2018 21st international conference on intelligent transportation systems (ITSC)* (pp. 2118–2125). IEEE.
- Lin, H., Huang, X., Phan, T., Hayden, D., Zhang, H., Zhao, D., Srinivasa, S., Wolff, E., & Chen, H. (2025). Causal composition diffusion model for closed-loop traffic generation. In *Proceedings of the Computer Vision and Pattern Recognition Conference* (pp. 27542–27552).
- Liu, Y., Niedoba, M., Harvey, W., Scibior, A., Zwartsenberg, B., & Wood, F. (2025). Rolling ahead diffusion for traffic scene simulation. *arXiv preprint arXiv:2502.09587*, .
- Liu, Z., Li, L., Wang, Y., Lin, H., Liu, Z., He, L., & Wang, J. (2024). Controllable traffic simulation through llm-guided hierarchical chain-of-thought reasoning. *arXiv preprint arXiv:2409.15135*, .
- Rahmani, S., Baghbani, A., Bouguila, N., & Patterson, Z. (2023). Graph neural networks for intelligent transportation systems: A survey. *IEEE Transactions on Intelligent Transportation Systems*, 24, 8846–8885.
- Rempe, D., Pillion, J., Guibas, L. J., Fidler, S., & Litany, O. (2022). Generating useful accident-prone driving scenarios via a learned traffic prior. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 17305–17315).
- Shao, H., Hu, Y., Wang, L., Song, G., Waslander, S. L., Liu, Y., & Li, H. (2024). Lmdrive: Closed-loop end-to-end driving with large language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 15120–15130).

- Sheng, Z., Huang, Z., Qu, Y., Leng, Y., & Chen, S. (2025). Talk2traffic: Interactive and editable traffic scenario generation for autonomous driving with multimodal large language model. In *Proceedings of the Computer Vision and Pattern Recognition Conference* (pp. 3788–3797).
- Stoler, B., Navarro, I., Francis, J., & Oh, J. (2025). Seal: Towards safe autonomous driving via skill-enabled adversary learning for closed-loop scenario generation. *IEEE Robotics and Automation Letters*, (pp. 1–8).
- Sun, J., Zhang, H., Zhou, H., Yu, R., & Tian, Y. (2021). Scenario-based test automation for highly automated vehicles: A review and paving the way for systematic safety assurance. *IEEE transactions on intelligent transportation systems*, 23, 14088–14103.
- Sun, K., Wang, X., Liu, S., Zhao, Q., Huang, G., & Liu, C. (2025a). Towards pedestrian head tracking: A benchmark dataset and a multi-source data fusion network. *Engineering Applications of Artificial Intelligence*, 158, 111265.
- Sun, K., Wang, X., Miao, X., & Zhao, Q. (2025b). A review of ai edge devices and lightweight cnn and llm deployment. *Neurocomputing*, 614, 128791.
- Sun, P., Kretschmar, H., Dotiwalla, X., Chouard, A., Patnaik, V., Tsui, P., Guo, J., Zhou, Y., Chai, Y., Caine, B. et al. (2020). Scalability in perception for autonomous driving: Waymo open dataset. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 2446–2454).
- Suo, S., Regalado, S., Casas, S., & Urtasun, R. (2021). Trafficsim: Learning to simulate realistic multi-agent behaviors. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 10400–10409).
- Wang, J., Huang, H., Li, K., & Li, J. (2021). Towards the unified principles for level 5 autonomous vehicles. *Engineering*, 7, 1313–1325.
- Wang, R., Xu, Y., & Ji, J. (2025). Traffic scenario logic: A spatial-temporal logic for modeling and reasoning of urban traffic scenarios. In *Proceedings of the AAAI Conference on Artificial Intelligence* (pp. 15195–15202). volume 39.
- Xu, C., Petiushko, A., Zhao, D., & Li, B. (2025). Diffscene: Diffusion-based safety-critical scenario generation for autonomous vehicles. In *Proceedings of the AAAI Conference on Artificial Intelligence* (pp. 8797–8805). volume 39.
- Yang, J., Sun, H., He, H., Zhang, Y., Liu, H. X., & Feng, S. (2023). Adaptive safety evaluation for connected and automated vehicles with sparse control variates. *IEEE Transactions on Intelligent Transportation Systems*, 25, 1761–1773.
- Zhang, J., Xu, C., & Li, B. (2024). Chatscene: Knowledge-enabled safety-critical scenario generation for autonomous vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 15459–15469).
- Zhao, D., Lam, H., Peng, H., Bao, S., LeBlanc, D. J., Nobukawa, K., & Pan, C. S. (2016). Accelerated evaluation of automated vehicles safety in lane-change scenarios based on importance sampling techniques. *IEEE transactions on intelligent transportation systems*, 18, 595–607.
- Zhou, R., Huang, H., Zhang, G., Zhou, H., & Bian, J. (2025). Crash-based safety testing of autonomous vehicles: Insights from generating safety-critical scenarios based on in-depth crash data. *IEEE Transactions on Intelligent Transportation Systems*, .