

PathPainter: 将图像生成模型的泛化能力迁移至具身导航

王一锦^{1,2,*} 田宇如^{1,2,*} 黄夕杰^{1,2,*} 盖伟琪^{2,3} 朱漠^{1,2} 周欣² 吴宇泽^{1,2,†} 高飞^{1,2,‡}

摘要: 鸟瞰图 (BEV) 图像已被广泛证明可为导航提供宝贵的前置信息。鉴于此类视图提供的全局信息, 仍存在两大关键挑战: 如何充分利用该信息以及如何在执行过程中可靠地使用它。在本文中, 我们提出一个使用鸟瞰图作为全局先验的导航系统, 该系统专为地面及近地面机器人平台设计。该系统采用图像生成模型来解读自然语言中的人类意图, 识别目标目的地, 并生成可通行掩码。在执行过程中, 我们引入跨视图定位技术, 将机器人的里程计与鸟瞰图对齐, 以缓解传统里程计中的长期漂移。我们进行了广泛的基准实验来评估所提出的方法, 并在无人机平台上进一步验证。仅使用传统的局部运动规划器, 无人机成功完成了160米户外长距离导航任务。这项工作展示了如何将基础模型的世界理解能力迁移至具身导航, 使机器人能够受益于现有图像生成模型的强大泛化能力。

关键词: 机器人导航、BEV先验、基础模型、跨视角局部定位、图像生成模型

1 引言

从空中或卫星视角获取的BEV图像能为机器人提供宝贵的全局先验信息, 用于户外导航, 包括道路拓扑、开阔区域、障碍物布局以及目标与周围结构的空间关系 [1, 2, 3]。这些先验信息对于自然语言引导的导航尤为重要, 机器人必须将语言指令与复杂场景相结合, 并推断可行路径 [4, 5]。因此, 鸟瞰视图信息已广泛应用于空地协同导航 [6, 7, 8, 9], 基于卫星地图的导航 [1, 2, 10], 以及高低空协同导航 [11, 12, 13]。

现有的基于BEV的导航系统仍难以将空中观测转化为可执行的导航先验。许多方法将BEV图像压缩为语义图、拓扑地图或类别级表示, 以便高效规划 [6, 7]。尽管这些表示方法紧凑, 但可能会丢弃导航所需的几何细节和视觉线索, 例如道路边界、通道宽度、障碍物布局和开阔区域的连续性。

此外, 可达性, 即一个区域是否能够支持可行的机器人运动, 通常由人类预定义的语义类别近似表示, 尤其是道路 [6]。这种以道路为中心的先验知识在结构化场景中非常有效, 但在开放户外环境中却无法捕捉多样的可达区域, 在这些区域中, 可行的导航可能涉及人行道、小径、越野路线以及穿越广场、海滩和其他开阔空间。

¹浙江大学。 ²微分机器人。 ³北京航空航天大学。 *同等贡献。 [†]通讯作者: wuyuze000@zju.edu.cn, fgaoaa@zju.edu.cn。




图1: 导航系统概述。左: 交叉视角定位从RGB-D观测重建的局部地面特征中提取嵌入, 并将其与BEV地图中的特征嵌入进行匹配, 以估计机器人的全局里程计。右: 给定目标提示和BEV地图, 图像生成模型用生成的星形标记标记目标区域, 并生成可通行性掩码。红色路径是通过在掩码上运行A* 获得的。

最近的基石模型在视觉、语言和空间理解方面展现了强大的泛化能力。特别是, 图像生成模型 [14, 15] 编码了关于空间布局、物体关系和导航线索的丰富先验知识。已有研究表明, 视觉理解任务可以被重新表述为图像生成问题 [16]。

这些观察结果促使我们提出了一个核心问题: BEV导航能否被重新表述为一个图像生成问题, 使图像生成模型能够为目标接地、可通行性估计和全局路径规划生成密集的导航先验, 并进一步将其转换为结构化、可搜索、可由真实机器人执行的路径?

在本文中, 我们提出了PathPainter, 一个用于自然语言条件BEV导航的路径规划框架, 如图1所示。给定一个BEV图像、机器人的起始位置和语言指令, PathPainter推断目标区域, 生成面向导航的可通行性掩码, 并应用A* 搜索以获得可执行的全局路径。我们进一步将PathPainter集成到一个结合了交叉视角定位、基于BEV的全局规划和局部运动执行的实时长距离导航系统中。交叉视角定位使机器人轨迹与BEV地图对齐, 而无需依赖精确的GPS/RTK定位。

PathPainter 展示了一种实用方法, 通过 BEV 先验解释将图像生成模型的泛化能力迁移到具身导航中。我们的主要贡献包括: (1) 我们提出了 PathPainter, 通过目的地推理、可通行性掩码生成和基于搜索的规划, 将生成式视觉先验迁移到自然语言条件下的 BEV 导航。(2) 我们开发了一个结合跨视场局部定位、BEV 全局规划和局部运动规划的实时长程导航系统, 用于近地面的户外机器人。(3) 我们在真实世界的导航和路径生成基准上验证了 PathPainter, 展示了其鲁棒性。代码将在 <https://github.com/E-hash-42/PathPainter> 上发布。

2 相关工作

2.1 基于先验的导航

与机载局部观测相比, 先验信息提供了更大范围的环境结构和潜在目标位置, 从而降低了远程导航中的探索成本。现有

工作使用先验信息如OpenStreetMap [4, 17], 抽象拓扑地图 [18], 和航拍地图 [19,20] 进行全局规划、子目标选择或局部规划约束。为将这些先验信息用于导航, 先前的作品通常将其抽象为道路图、拓扑节点或语义区域, 并研究如何在执行过程中将机载观测与全局先验信息对齐。虽然这些抽象对规划和定位很有用, 但它们可能会丢弃航拍图像中的细粒度几何形状、视觉外观和局部可通行性线索。相比之下, 我们的工作直接从航拍图像中提取可通行区域, 用于在生成的掩码上进行基于A*的规划, 并引入跨视图定位, 以在执行过程中将机器人里程计与航拍先验信息对齐。

2.2 基于基础模型的导航

近期研究将基础模型引入导航领域, 使机器人能够理解人类指令, 并在复杂环境中执行以目标、物体和语言引导的导航。这些方法主要遵循两种范式: 视觉-语言模型直接根据指令 [21, 22], 预测动作或高级航点, 而视频生成模型合成指令条件下的未来视频并从中推断可执行动作 [23, 24]。一些方法进一步结合了这两种范式 [25]。总体而言, 这些方法展示了基础模型的语义理解和跨场景泛化能力, 推动了开放世界导航的发展。

3 方法

3.1 流程

如图2所示, 本文提出了一种基于鸟瞰图的导航规划框架。该系统以航拍正射影像和自然语言指令为输入, 输出可执行的导航路径, 并将其部署在空中机器人平台上进行自主执行。

整体流程包含两个层级: 高层路径生成和低层运动执行。在高层, 系统首先使用图像生成模型对BEV地图进行语义理解, 绘制可通行掩码, 并根据起始点和目标点提取全局路径。在低层, 系统通过跨视点定位将全局路径映射到机器人的局部坐标系, 并结合激光雷达里程计与鲁棒局部规划器 [26] 进行实时避障和轨迹跟踪。




图2: 我们的导航系统流程。




图3: PathPainter的工作流程。列1: 自然语言目的地查询。列2: 包含当前机器人位置的原始地图。列3: 可通行性掩码。列4: 最终规划结果, 其中生成的可通行性掩码、预测的目标位置和规划的路径叠加在原始地图上。

这种分层设计将高层语义推理与低层运动控制解耦, 使机器人在复杂和非结构化的户外环境中实现稳定导航。

3.2 通过图像到图像生成提取可执行路径

我们将路径规划问题表述为图像到图像生成过程, 从而利用图像生成模型的空间理解和语义推理能力, 将高级地图理解转换为可执行的导航路径。如图3所示, 图像生成模型负责两项主要任务: 目标位置预测和可通行性掩码分割。具体而言, 我们首先在BEV地图上用绿色星标标记机器人的当前位置。基于此起点和自然语言指令, 图像生成模型被提示推断并绘制目标位置。

与此同时, 系统采用精心设计的提示来引导图像生成模型生成一张代表可通行区域的图像掩码, 称为可通行性掩码。这张掩码明确编码了场景中的可步行区域, 例如道路、人行道和开阔空间,

同时抑制不可通行区域，如建筑物、植被和障碍物。对于被树木部分遮挡但语义上仍连续的道路区域，模型可以根据全局上下文推理来保留其连通性。因此，这个过程可以被视为从原始视觉输入到可导航空间表示的映射。

最后，我们从生成的可通行性掩码中进一步提取一条连接起始点和目标点的可行路径。具体来说，在对应可通行区域的二值掩码上执行A* 搜索。为了鼓励规划的路径靠近道路中心，我们将基于边界距离的惩罚项引入A* 代价函数：离可通行区域边界更远的路径点会被分配更低的代价。这鼓励生成的路径远离边界，从而提高安全性和可执行性。

3.3 跨视角定位

为了执行BEV全局路径，我们使用BEV-Patch-PF [27] 将机器人的局部里程计帧与BEV地图帧对齐。它估计机器人位于BEV地图上的位姿为 $\mathbf{x}_t^M = (x_t^M, y_t^M, \theta_t^M)$ ，其中 M 表示地图帧。

给定全局路径 $\mathcal{P}^M = \{\mathbf{p}_1^M, \dots, \mathbf{p}_K^M\}$ ，我们根据当前全局里程计选择一个前瞻航点 $\mathbf{p}_k^M$ ，并将其转换到局部里程计帧 O ：

$$\tilde{\mathbf{p}}_k^O = \mathbf{T}_M^O \tilde{\mathbf{p}}_k^M, \quad (1)$$

其中 $\mathbf{T}_M^O$ 是根据交叉视图定位结果和当前里程计估计计算得出的，而 $\tilde{\mathbf{p}}$ 表示齐次航点坐标。转换后的航点被发送给局部规划器作为短期导航目标，允许高频率局部规划，同时定期校正长期里程计漂移。

4 实验

4.1 评估路径生成方法

需要注意的是，我们的目标并非纯粹的语义分割或完整的道路拓扑重建。相反，我们目标是导航优先的穿越性生成。这项任务需要 (1) 识别可见道路，(2) 推理遮挡下的连续性和模糊区域中可能的穿越性，以及 (3) 捕捉超越道路结构的多样化穿越形式。尽管 SAM 3.1 [28] 等模型和 RINGDet++ [29]、SAMRoad [30] 等道路拓扑模型在其设计目标内表现强大，但它们的输出未必是下游路径规划的最佳选择。然而，我们从两个角度基准测试这些代表性方法：它们生成稳定可见道路先验的能力以及它们对下游路径规划的实用性。

可见道路分割基准。我们在DeepGlobe [31]、UAVid [32]、和VDD [33]上评估了零样本可见道路分割。所有方法均未进行任务特定训练、微调或人工校正。对于图像生成模型，我们遵循原始提示格式 [16]，使用目标关键词road，并将输出转换为二值掩码。对于开放词汇分割基线，包括SAM 3.1和Text2Seg [34]，我们使用road作为类别提示。

表1显示，Gemini在所有三个数据集上都实现了强大的召回率，表明它倾向于生成更连续的道路区域。这一特性有利于后续的骨架化和A* 搜索。SAM 3.1实现了更高的精度和更低的推理时间，表明它是一个高效可靠的可见道路分割器。然而，它更保守，无法自然地执行遮挡补全或任务级别的可遍历性推理。

下游路径规划基准。为了进一步评估这些先验知识是否对导航有用，我们在 CityScale [35] 和 Global-Scale [36] 上构建了一个起点-终点路径规划基准。这两个数据集都包含高分辨率的 2048×2048 航空图像以及地面真实道路标注。对于每张图像，我们随机采样 1000 个起点-终点对，并评估每个

数据集	方法	IoU	精度	Rec.	F1	时间 (秒)
DeepGlobe [31]	GPT [15]	0.288	0.331	<u>0.672</u>	0.439	48.19
	Gemini [14]	0.490	<u>0.613</u>	0.738	0.657	47.68
	SAM 3.1 [28]	<u>0.375</u>	0.659	0.512	<u>0.602</u>	0.17
	Text2Seg [34]	0.063	0.100	0.527	0.148	0.46
UAVid [32]	GPT [15]	0.403	0.541	0.648	0.583	91.41
	Gemini [14]	0.629	<u>0.713</u>	0.838	0.754	41.12
	SAM 3.1 [28]	<u>0.604</u>	0.848	<u>0.691</u>	0.781	0.17
	Text2Seg [34]	0.373	0.514	0.500	0.539	<u>0.48</u>
VDD [33]	GPT [15]	0.248	0.281	0.625	0.454	154.40
	Gemini [14]	<u>0.530</u>	<u>0.576</u>	0.843	<u>0.736</u>	50.65
	SAM 3.1 [28]	0.580	0.750	<u>0.732</u>	0.757	0.18
	Text2Seg [34]	0.268	0.380	0.445	0.555	<u>0.45</u>

Table1: 可见道路分割基准。所有方法仅分割道路类别。




图4: 高度分布外场景的真实世界测试。

方法	本域 (CityScale) [35]			分布外 (Global-Scale) [36]			时间 (s)
	成功	有效	Len.	成功	有效	Len.	
Gemini [14]	<u>0.902</u>	0.932	<u>1.007</u>	0.766	0.904	<u>1.071</u>	61.60
Gemini-Direct [14]	0.280	0.910	1.242	<u>0.293</u>	0.828	1.038	86.58
SAMRoad [30]	0.853	0.994	1.095	0.339	0.975	1.164	9.34
RNGDet++ [29]	0.972	<u>0.969</u>	1.005	0.252	<u>0.949</u>	1.148	39.95
SAM 3.1 [28]	0.018	0.016	0.829	0.042	0.040	0.887	0.266

表2: 下游路径规划基准。所有方法仅在道路类别上进行评估。有效值 (Validity) 和长度比 (Len.) 仅针对成功样本进行计算。Len.指标在值接近1时表示性能更优。




图5: Gemini预测了地面真实中未标记的道路。

方法是否能够支持它们之间的路径规划。CityScale 作为领域内 (in-domain) 仅包含道路的基准, 而 Global-Scale 的域外 (out-of-domain, OOD) 拆分则用于评估跨域泛化能力。为了公平比较, 所有方法仅在道路类别上进行评估: 它们的输出被转换为二值道路可达性掩码, 并传递给相同的 A* 规划器。尽管我们的完整系统旨在支持更广泛的可达性, 但这个基准仅限于道路, 因为现有的公共数据集只提供道路标注。对于 Gemini, 提示词也针对道路可达性, 同时鼓励先验知识保留全局拓扑连通性。

我们报告了 Succ., 表示在预测的可达性掩码上找到连通路程的采样起始-目标对的比例。对于成功案例, Valid. 衡量路径在真实可达区域内所占的比例, Len. 表示预测到真实的最短路径长度比率, 值越接近 1 越好。还报告了平均推理时间。

如表 2 所示, RNGDet++ 和 SAMRoad 在领域内 CityScale 划分上表现良好, 但在领域外 Global-Scale OOD 划分上由于缺少或断开的道路段而成功率显著下降。SAM 3.1 进一步受到道路分割碎片化影响, 无法识别卫星图像中的狭窄路径。如图 4 所示, 这些基准方法在实际场景中往往不实用。相比之下, Gemini 实现了更高的领域外可达性和更稳定的长度比率, 显示出更强的全局路线生成鲁棒性。其较低的有效性部分是由于标注不匹配: 如图 5 所示, Gemini 可能使用视觉上合理的类似道路区域, 这些区域保留了连通性但未标注为道路, 导致有效性较低。其领域外成功率轻微下降主要来自森林覆盖、树木遮挡和道路外观杂乱。尽管如此, Gemini 比基于图的基线提供了更可靠的全局路径候选, 且仅以适度的有效性权衡为代价。

我们还测试了 Gemini-Direct, 其中模型在起点和终点之间直接生成路径导向的掩码, 而不是先进行完整可达性检测。然后将相同的 A* 规划器应用于这个路径导向掩码, 以进行公平比较。

它的成功率较低且路径质量不稳定，表明直接路径掩码生成不够可靠，经常在不可通行区域生成无效的捷径。因此，我们的系统采用先生成后搜索的流程。

4.2 实际应用结果

如图2所示，我们通过在四旋翼无人机平台上进行实际部署来评估我们的系统。该平台集成了一个Intel RealSense D455相机用于跨视角定位，以及一个Livox Mid-360激光雷达用于状态估计和局部地图构建。为确保近地飞行安全并模拟地面移动平台的视角，无人机被限制在1米的固定高度飞行。通过使用大疆Neo无人机拍摄航拍图像，并使用WebODM进行处理，构建了一个地理参考的正射影像图（TIFF），其中包含比例信息，并作为BEV地图。整个流程运行在NVIDIA Orin NX（16GB）边缘计算平台上。对于跨视角定位，我们直接使用BEV-Patch-PF [27] 中的特征提取器，且在实验场景中未进行微调。由于板载计算资源的限制，跨视角定位模块以1Hz的频率输出全局里程计。我们将此与局部规划堆栈解耦：1Hz的全局里程计仅用于周期性漂移校正和局部目标更新，而一个局部运动规划器独立以10Hz的频率运行，使用通过融合FAST-LIO2 [37] 与IMU测量得到的200Hz里程计进行实时避障和轨迹跟踪。

我们在7种真实场景下，针对不同布局和天气条件下的21条导航路线，对完整系统进行了评估。在所有测试中，目的地着陆和可通行区域生成均使用Gemini进行在线处理。本节报告了两个场景中的三个代表性实验，如图6和图7所示。每次测试均评估从自然语言指令到物理执行的完整流程。系统在21条路线中的15条上成功运行，实现了71.4%的端到端成功率。两次测试因可通行性掩膜断开而失败，四次测试因跨视角定位错误而失败。



图6：实验1。公园内的导航。初始全局位姿估计包含相对较大的误差，使得FAST-LIO2单独不足以进行长距离导航。




图7：实验2：公园导航。即使初始位姿准确，长距离导航过程中仍会发生不可接受的漂移。实验3：结构复杂建筑中的导航。

实验1（图6）在商业地图服务中未标注路径的城市公园进行，突出了在线环境理解和路径规划的需求。原始FAST-LIO2表现出较大的初始位姿误差和长期漂移，不适合直接长距离导航。相比之下，跨视角模块提供连续的全局定位和局部导航目标的动态校正。由于缺乏可靠的RTK/GPS真值，我们使用同步的RGB和航拍视频，并手动标注航点，对轨迹进行定性验证，显示无人机沿规划的走廊飞行。

实验2和3（图7）展示了基于语言的导航能力。实验3在工业园区进行，由于存在较大的GPS偏差和波动，可靠的全球定位具有挑战性。该系统通过解释自然语言指令提取语义目标线索，生成可行路径，并执行任务。

5 结论与局限性

我们提出了一种基于BEV的导航规划框架，该框架由图像生成模型驱动。通过将目标选择和可通行性掩码生成表述为图像生成任务，并利用跨视角定位实现可靠的全球里程计，我们的方法将图像生成模型的强泛化能力迁移到长距离户外导航。

仍存在一些局限性。该系统依赖于精确的空域先验信息，因为未对齐或非正射校正的地图会降低性能。此外，2D正射影像缺乏高程信息，在不规则或多层场景中会导致歧义。最后，机载计算限制将跨视角定位频率限制在1Hz，这可能会在高速运动时限制性能。

参考文献

- [1] M. Elnoor, K. Weerakoon, G. Seneviratne, R. Xian, T. Guan, M. K. M. Jaffar, V. Rajagopal, and D. Manocha. Robot navigation using physically grounded vision-language models in outdoor environments. *arXiv preprint arXiv:2409.20445*, 2024.
- [2] C. Klammer and M. Kaess. Bevloc: Cross-view localization and matching via birds-eye-view synthesis. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 5656–5663. IEEE, 2024.
- [3] J. Zhang, H. Dong, J. Yang, J. Liu, S. Huang, K. Li, X. Tang, X. Wei, and X. You. Dual-bev nav: Dual-layer bev-based heuristic path planning for robotic navigation in unstructured outdoor environments. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8872–8879. IEEE, 2025.
- [4] J. Lee, T. Miyanishi, S. Kurita, K. Sakamoto, D. Azuma, Y. Matsuo, and N. Inoue. City-nav: A large-scale dataset for real-world aerial navigation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 5912–5922, 2025.
- [5] C. Huang, O. Mees, A. Zeng, and W. Burgard. Visual language maps for robot navigation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10608–10615. IEEE, 2023.
- [6] F. Cladera, Z. Ravichandran, J. Hughes, V. Murali, C. Nieto-Granda, M. A. Hsieh, G. J. Pappas, C. J. Taylor, and V. Kumar. Air-ground collaboration for language-specified missions in unknown environments. *IEEE Transactions on Field Robotics*, 2025.
- [7] H. Liu, Z. Ma, Y. Li, J. Sugihara, Y. Chen, J. Li, and M. Zhao. Hierarchical language models for semantic navigation and manipulation in an aerial-ground robotic system. *Advanced Intelligent Systems*, 8(2):e202500640, 2026. doi:<https://doi.org/10.1002/aisy.202500640>. URL <https://advanced.onlinelibrary.wiley.com/doi/abs/10.1002/aisy.202500640>.
- [8] Z. Li, R. Mao, N. Chen, C. Xu, F. Gao, and Y. Cao. Colag: A collaborative air-ground framework for perception-limited ugvs’ navigation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 16781–16787. IEEE, 2024.
- [9] J. Deng, J. Liu, and J. Hu. Tightly-coupled air-ground collaborative system for autonomous ugv navigation in gps-denied environments. *Drones*, 9(9):614, 2025.
- [10] Y. Huang, H. Dugmag, T. D. Barfoot, and F. Shkurti. Stochastic planning for asv navigation using satellite images. In *2023 IEEE international conference on robotics and automation (ICRA)*, pages 1055–1061. IEEE, 2023.
- [11] R. Wu, Y. Zhang, J. Chen, L. Huang, S. Zhang, X. Zhou, L. Wang, and S. Liu. Aeroduo: Aerial duo for uav-based vision and language navigation. In *Proceedings of the 33rd ACM International Conference on Multimedia*, pages 2576–2585, 2025.
- [12] I. Munasinghe, A. Perera, and R. C. Deo. A comprehensive review of uav-ugv collaboration: Advancements and challenges. *Journal of Sensor and Actuator Networks*, 13(6):81, 2024.
- [13] Y. Zhang, H. Yan, D. Zhu, J. Wang, C.-H. Zhang, W. Ding, X. Luo, C. Hua, and M. Q.-H. Meng. Air-ground collaborative robots for fire and rescue missions: Towards mapping and navigation perspective. *arXiv preprint arXiv:2412.20699*, 2024.
- [14] Google. Introducing nano banana pro. <https://blog.google/innovation-and-ai/products/nano-banana-pro/>, Nov. 2025. Google Blog. Accessed: 2026-04-27.
- [15] OpenAI. Chatgpt images 2.0 is now available. <https://openai.com/zh-Hans-CN/index/introducing-chatgpt-images-2-0/>, Apr. 2026. Accessed: 2026-04-27.

- [16] V. Gabeur, S. Long, S. Peng, P. Voigtlaender, S. Sun, Y. Bao, K. Truong, Z. Wang, W. Zhou, J. T. Barron, K. Genova, N. Kannen, S. Ben, Y. Li, M. Guo, S. Yogin, Y. Gu, H. Chen, O. Wang, S. Xie, H. Zhou, K. He, T. Funkhouser, J.-B. Alayrac, and R. Soricut. Image generators are generalist vision learners, 2026. URL <https://arxiv.org/abs/2604.20329>.
- [17] A. Li, Z. Wang, J. Zhang, M. Li, Y. Qi, Z. Chen, Z. Zhang, and H. Wang. Urbanvla: A vision-language-action model for urban micromobility. *arXiv preprint arXiv:2510.23576*, 2025.
- [18] A. H. Tan, A. Fung, H. Wang, and G. Nejat. Mobile robot navigation using hand-drawn maps: A vision language model approach. *IEEE Robotics and Automation Letters*, 2025.
- [19] C. Moore, S. Mitra, N. Pillai, M. Moore, S. Mittal, C. Bethel, and J. Chen. Ura*: Uncertainty-aware path planning using image-based aerial-to-ground traversability estimation for off-road environments. *arXiv preprint arXiv:2309.08814*, 2023.
- [20] S. Shair, J. Chandler, V. Gonzalez-Villela, R. M. Parkin, and M. Jackson. The use of aerial images and gps for mobile robot waypoint navigation. *IEEE/ASME Transactions On Mechatronics*, 13(6):692–699, 2008.
- [21] J. Zhang, K. Wang, R. Xu, G. Zhou, Y. Hong, X. Fang, Q. Wu, Z. Zhang, and H. Wang. Navid: Video-based vlm plans the next step for vision-and-language navigation. *arXiv preprint arXiv:2402.15852*, 2024.
- [22] Y. Wu, M. Zhu, X. Li, Y. Du, Y. Fan, W. Li, Z. Han, X. Zhou, and F. Gao. Vla-an: An efficient and onboard vision-language-action framework for aerial navigation in complex environments. *arXiv preprint arXiv:2512.15258*, 2025.
- [23] H. Zhang, S. Liang, L. Chen, Y. Li, Y. Xu, Y. Zhong, F. Zhang, and H. Li. Sparse video generation propels real-world beyond-the-view vision-language navigation. *arXiv preprint arXiv:2602.05827*, 2026.
- [24] X. Huang, W. Gai, T. Wu, C. Wang, Z. Liu, X. Zhou, Y. Wu, and F. Gao. Navdreamer: Video models as zero-shot 3d navigators. *arXiv preprint arXiv:2602.09765*, 2026.
- [25] J. Hu, J. Chen, H. Bai, M. Luo, S. Xie, Z. Chen, F. Liu, Z. Chu, X. Xue, B. Ren, et al. Astranav-world: World model for foresight control and consistency. *arXiv preprint arXiv:2512.21714*, 2025.
- [26] X. Zhou, Z. Wang, H. Ye, C. Xu, and F. Gao. Ego-planner: An esdf-free gradient-based local planner for quadrotors. *IEEE Robotics and Automation Letters*, 6(2):478–485, 2020.
- [27] D. Lee, J. Quattrociochi, C. Ellis, R. Rana, A. Adkins, A. Uccello, G. Warnell, and J. Biswas. Bev-patch-pf: Particle filtering with bev-aerial feature matching for off-road geo-localization. *arXiv preprint arXiv:2512.15111*, 2025.
- [28] N. Carion, L. Gustafson, Y.-T. Hu, S. Debnath, R. Hu, D. Suris, C. Ryali, K. V. Alwala, H. Khedr, A. Huang, J. Lei, T. Ma, B. Guo, A. Kalla, M. Marks, J. Greer, M. Wang, P. Sun, R. Rädle, T. Afouras, E. Mavroudi, K. Xu, T.-H. Wu, Y. Zhou, L. Momeni, R. Hazra, S. Ding, S. Vaze, F. Porcher, F. Li, S. Li, A. Kamath, H. K. Cheng, P. Dollár, N. Ravi, K. Saenko, P. Zhang, and C. Feichtenhofer. Sam 3: Segment anything with concepts, 2025. URL <https://arxiv.org/abs/2511.16719>.
- [29] Z. Xu, Y. Liu, Y. Sun, M. Liu, and L. Wang. Rngdet++: Road network graph detection by transformer with instance segmentation and multi-scale features enhancement. *IEEE Robotics and Automation Letters*, 8(5):2991–2998, 2023.
- [30] C. Hetang, H. Xue, C. Le, T. Yue, W. Wang, and Y. He. Segment anything model for road network graph extraction. *arxiv. arXiv preprint arXiv:2403.16051*, 2024.

- [31] I. Demir, K. Koperski, D. Lindenbaum, G. Pang, J. Huang, S. Basu, F. Hughes, D. Tuia, and R. Raskar. Deepglobe 2018: A challenge to parse the earth through satellite images. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, pages 172–181, 2018.
- [32] Y. Lyu, G. Vosselman, G.-S. Xia, A. Yilmaz, and M. Y. Yang. Uavid: A semantic segmentation dataset for uav imagery. *ISPRS journal of photogrammetry and remote sensing*, 165:108–119, 2020.
- [33] A. Yeshchenko, J. Mendling, C. Di Ciccio, and A. Polyvyanny. Vdd: A visual drift detection system for process mining. 2020.
- [34] J. Zhang, Z. Zhou, G. Mai, M. Hu, Z. Guan, S. Li, and L. Mu. Text2seg: Remote sensing image semantic segmentation via text-guided visual foundation models. *arXiv preprint arXiv:2304.10597*, 2023.
- [35] S. He, F. Bastani, S. Jagwani, M. Alizadeh, H. Balakrishnan, S. Chawla, M. M. Elshrif, S. Madden, and M. A. Sadeghi. Sat2graph: Road graph extraction through graph-tensor encoding. In *European Conference on Computer Vision*, pages 51–67. Springer, 2020.
- [36] P. Yin, K. Li, X. Cao, J. Yao, L. Liu, X. Bai, F. Zhou, and D. Meng. Towards satellite image road graph extraction: A global-scale dataset and a novel method. *arXiv preprint arXiv:2411.16733*, 2024.
- [37] W. Xu, Y. Cai, D. He, J. Lin, and F. Zhang. Fast-lio2: Fast direct lidar-inertial odometry. *IEEE Transactions on Robotics*, 38(4):2053–2073, 2022.