

通过学习交通先验生成实用的事故易发驾驶场景

Davis Rempe^{1,2}Jonah Philion^{2,3,4}Leonidas J. Guibas¹Sanja Fidler^{2,3,4}Or Litany²¹斯坦福大学²英伟达³多伦多大学⁴矢量研究所

nv-tlabs.github.io/STRIVE

摘要

评估和改进自动驾驶车辆的规划需要可扩展地生成成长尾交通场景。为了实用，这些场景必须真实且具有挑战性，但又不至于无法安全驾驶。在这项工作中，我们介绍了*STRIVE*，一种自动生成具有挑战性场景的方法，这些场景会导致给定的规划器产生不希望的行为，如碰撞。为了保持场景的合理性，关键思想是利用一个基于图的条件VAE的交通运动学习模型。场景生成被表述为在这个交通模型的潜在空间中的优化问题，通过扰动初始真实场景来生成与给定规划器发生碰撞的轨迹。随后的优化用于找到场景的“解决方案”，确保其有助于改进给定的规划器。进一步的分析根据碰撞类型对生成的场景进行聚类。我们攻击了两个规划器，并表明*STRIVE*在两种情况下都成功生成了真实且具有挑战性的场景。此外，我们还“闭环”并使用这些场景来优化基于规则的规划器的超参数。

1. 简介

当代自动驾驶汽车（AV）的安全性取决于其能否安全处理复杂的近碰撞场景。然而，这类场景在现实驾驶中极为罕见，导致数据稀缺问题，这对感知、预测和规划的数据驱动模型的开发与测试都极为不利。此外，模型越完善，这类事件就越罕见，使得模型的训练难度进一步加大。

一种自然的解决方案是在模拟中合成困难场景，而不是依赖真实世界数据，从而更容易、更安全地评估和训练自动驾驶系统。这种方法在规划方面尤其有吸引力，因为外观领域差距不是问题。例如，人们可以手动设计场景，通过插入对抗性参与者或修改轨迹来让自动驾驶系统可能失败，无论是从零开始还是通过对一小部分真实场景进行扰动。不幸的是，这种方法的手动性质在需要大量场景进行训练或全面评估时很快变得高成本。




图1. STRIVE为给定规划器生成具有挑战性的场景。对抗性优化在已学习的交通模型的潜在空间中扰动真实世界场景，导致对手（红色）与规划器（绿色）发生碰撞。随后的解优化找到一条避免碰撞的规划器轨迹，验证该场景对识别规划器改进是有用的。

当需要大量场景进行训练或全面评估时，这种手动方法很快变得高成本。

近期研究致力于自动生成具有挑战性的场景

[1, 12, 13, 27, 38, 52, 55]。通常，这些方法控制场景中的单个或少数“对手”，定义一个目标（例如，与自动驾驶汽车发生碰撞），然后优化对手的行为或轨迹以达成目标。虽然大多数方法仅能生成1或2个场景 [1, 9, 27, 38]，但近期研究 [55] 通过从真实世界交通场景出发并扰动预先选择的有限对手集合，提升了可扩展性。然而，这些方法缺乏对合理交通运动的先验知识，这限制了场景的真实性和多样性。特别是，场景中的对手实体是预先启发式选择的少量智能体；周围交通不会做出反应，因此扰动必须小心避免不合理的场景（例如，与辅助智能体发生碰撞）。此外，较少关注确定场景是否“无解” [1, 12, 13, 27, 38, 52, 55]，即，即使对于神谕自动驾驶汽车也无法避免碰撞。在这种退化情况下，该场景对评估/训练规划器没有用处。

场景是否“无解” [19]，即，即使对于神谕自动驾驶汽车也无法避免碰撞。在这种退化情况下，该场景对评估/训练规划器没有用处。

在这项工作中，我们介绍了STRIVE——一种用于生成挑战性场景以对给定自动驾驶系统进行压力测试的方法。STRIVE攻击自动驾驶堆栈中的预测、规划和控制子集，我们统称为规划器。如图1所示，我们的方法通过优化程序扰动初始真实场景，导致一个任意攻击者与给定规划器发生碰撞。我们的核心思想是在优化过程中通过学习到的交通运动生成模型下的场景可能性来衡量场景的合理性，从而鼓励场景既具有挑战性又具有真实性。因此，STRIVE不会提前选择特定的攻击者，而是联合优化所有场景智能体，从而产生多样化的场景。此外，为了适应实践中广泛使用的不可微分（或不便访问）的规划器，所提出的优化在学习的运动模型中使用规划器的可微分代理表示，从而允许使用标准的基于梯度的优化。

我们提出识别和表征对改进给定规划器有用的生成场景。我们首先搜索生成场景的“解决方案”以确定它们是否退化，然后根据碰撞属性对可解场景进行聚类。我们在两个自动驾驶规划器上测试了STRIVE，包括一个新的基于规则的规划器，并表明它在两种情况下都生成了合理且多样的碰撞场景。此外，我们使用生成场景通过识别其设计的基本限制和调整超参数来改进基于规则的规划器。

简而言之，我们的贡献是：(i) 一种为给定规划器自动生成合理且具有挑战性的场景的方法，(ii) 一种解决方案优化以确保场景实用性，以及 (iii) 一种通过碰撞类型对场景进行聚类的分析方法。这项工作的补充视频和材料可在项目网页上获取。

2. 相关工作

交通运动建模。场景回放不足以测试和开发自动驾驶车辆规划器，因为非自身车辆的运动会与自身规划器选择的行为紧密耦合。深度学习的进步使我们能够用能更好地捕捉交通复杂性的神经网络替代传统的动态和运动学模型 [28, 30, 54] 或基于规则的模拟器 [15, 34] [3, 39]。从简短的状态历史和高清地图中预测未来轨迹的努力通常可以根据编码技术、多模态建模、多智能体交互以及轨迹是否以单步或逐步方式估计来进行分类。每个智能体周围上下文的编码通常通过鸟瞰视图（BEV）栅格图像 [28, 30, 54] 完成，尽管一些工作 [15, 34] 用车道图表示替换了基于栅格的地图编码。SimNet [3, 39] 通过使用基于语义地图的条件生成模型初始化状态，增加了生成的模拟的多样性。为了处理多模态性，多个未来已经被直接或通过轨迹提案估计。使用密集图显式建模多智能体交互已被证明对车辆车道和行人有效。最后，逐步预测在整体轨迹的一步预测中表现良好。我们遵循这些工作，设计了一个使用智能体间图网络表示智能体交互并具有变分性的交通模型，使我们能够采样多个未来。

鸟瞰视图（BEV）栅格图像 [8, 10, 17]，尽管一些工作 [18, 32] 用车道图表示替换了基于栅格的地图编码。SimNet [4] 通过使用基于语义地图的条件生成模型初始化状态，增加了生成的模拟的多样性。为了处理多模态性，多个未来已经被直接 [10] 或通过轨迹提案 [8, 17, 33, 41] 估计。使用密集图显式建模多智能体交互已被证明对车辆 [6, 49]，车道 [32]，和行人 [21, 29, 47] 有效。最后，逐步预测在整体轨迹 [14] 的一步预测中表现良好。我们遵循这些工作，设计了一个使用智能体间图网络 [22] 表示智能体交互并具有变分性的交通模型，使我们能够采样多个未来。

我们的模型基于基于VAE的方法 [6, 49]，这些方法提供对可控潜在空间的先验知识 [43]。在其他设计差异中，我们通过自行车模型结合环境碰撞惩罚和结构预测来确保物理合理性。

挑战性场景生成。与完全依赖记录的驾驶数据相比，生成场景的潜力可以指数级地增加场景覆盖率。

CARLA [15] 和 NVIDIA 的 DRIVE Sim 等逼真模拟器的进步，以及大规模数据集 [5, 16, 20, 24, 48]，的可用性，对生成合理的场景图方法至关重要，这些方法可以改进感知 [11, 23, 44] 和规划 [4, 6, 25, 49]。我们的工作专注于生成挑战性——或称为“对抗性”¹——场景，由于这些场景在记录数据中非常罕见，因此它们更加关键。虽然大多数工作假设完美的感知并攻击规划模块 [9, 12, 13, 19, 27, 52]，但最近的努力利用了整个堆栈，包括图像或点云感知 [1, 31, 38, 50, 55]。我们的工作只专注于攻击规划器，尽管我们的场景参数化作为学习到的交通模型可以整合到端到端方法中。与我们的方法不同，该方法使用基于梯度的优化（由学习到的运动模型支持），大多数对抗性生成工作严重依赖黑盒优化，这可能很慢且不可靠。

我们的场景生成方法与 Ad- vSim [55]，最相似，但是，我们不是优化简单自行车模型的加速曲线，而是使用更丰富的数据驱动运动先验。这解决了之前同时控制多个对抗性智能体并以合理方式运行的困难。此外，我们通过提出“解决方案”优化阶段来过滤值得考虑的场景，从而避免攻击轨迹与回放 AV 相撞。先前工作 [9] 基于智能体的轨迹对变道场景进行聚类，而我们对基于敌手与规划器之间的碰撞属性进行聚类。

¹我们使用“具有挑战性”来指代那些不明确攻击感知或规划堆栈中特定模块的生成过程

AV 规划器。尽管最近学术界对基于端到端学习的规划器和 AV [3, 7, 45, 46, 59], 很感兴趣, 但在实际 AV 系统中, 基于规则的规划器仍然是标准做法 [53]。因此, 我们在 2007 年 DARPA 城市挑战赛 [36, 51] 中成功团队使用的基于车道图的规划器类似的基于规则的规划器上评估了我们的方法, 详情见第 4.2 节。

3. 挑战场景生成

STRIVE 旨在为给定规划器生成高风险交通场景, 这些场景随后可用于改进该规划器 (图1)。对于我们的目的, 规划器封装了预测、规划和控制, 即我们对系统即使感知完美仍出现不良行为的场景感兴趣。规划器以场景中其他智能体的过去轨迹为输入, 并输出其控制的车辆 (称为自我车辆) 的未来轨迹。假设它是黑盒: STRIVE 不了解规划器的内部结构, 也无法通过它计算梯度。不良行为包括与其他车辆碰撞、非可行行驶地形、驾驶不适 (例如高加速度) 以及违反交通法规。我们专注于生成涉及车辆与车辆碰撞且规划器易发生事故的场景, 尽管我们的公式是通用的, 原则上可以处理其他目标。

与先前工作类似, [55], 场景生成被表述为一个优化问题, 该问题从真实世界数据中扰动初始场景中智能体的轨迹。输入是一个规划器 f 、包含可行行驶区域和车道的语义层地图 $\mathcal{M}$, 以及一个用作优化初始化的预录真实世界场景序列。此初始场景包含 N 智能体, 其轨迹在 2D BEV 中表示为 $Y = \{\mathbf{Y}^i\}_{i=1}^N$, 其中 $\mathbf{Y}^i = [\mathbf{y}_1^i, \mathbf{y}_2^i, \dots, \mathbf{y}_T^i]$ 是智能体的状态序列。我们让 $\mathbf{Y}_t = [\mathbf{y}_t^1, \mathbf{y}_t^2, \dots, \mathbf{y}_t^N]$ 表示所有智能体在单个时间步的状态。智能体状态

$\mathbf{y}_t^i = [x_t, y_t, \theta_t, v_t, \dot{\theta}_t]$ 在时间 t 包含 2D 位置 (x_t, y_t) 、航向 θ_t 、速度 v_t 和横摆角速度 $\dot{\theta}_t$ 。

在场景中展开时, 在每个时间步, 规划器根据自身和其他智能体的过去运动输出下一个自我状态

$\mathbf{y}_t^{\text{plan}} = f(\mathbf{y}_{<t}^{\text{plan}}, \mathbf{Y}_{<t}, \mathcal{M})$ 。为简单起见, 我们将展开的规划器轨迹写为 $\mathbf{Y}^{\text{plan}} = f(Y, \mathcal{M})$, 其中

$\mathbf{Y}^{\text{plan}} = [\mathbf{y}_1^{\text{plan}}, \mathbf{y}_2^{\text{plan}}, \dots, \mathbf{y}_T^{\text{plan}}]$ 为本文其余部分的简称。场景生成扰动所有非自我智能体的轨迹, 以最佳满足对抗性目标 $\mathcal{L}_{\text{adv}}$ (例如, 与规划器发生碰撞):

$$\min_Y \mathcal{L}_{\text{adv}}(Y, \mathbf{Y}^{\text{plan}}), \quad \mathbf{Y}^{\text{plan}} = f(Y, \mathcal{M}). \quad (1)$$

人们可以显式地优化 Y 中的一个或一小组“对手”, 例如通过运动学自行车模型参数化 [28, 42, 55]。虽然这强制执行了合理的单智能体动力学, 但交互必须受到约束以避免非自主体之间的碰撞, 即使如此,

由此产生的交通模式可能是不现实的。我们提出使用神经网络来学习建模交通运动, 然后在优化时 (i) 将场景中的所有轨迹参数化为潜在空间中的向量, 以及 (ii) 作为场景合理性的先验。接下来, 我们描述这种交通模型, 然后是产生碰撞场景的“对抗”优化。

3.1. 建模“现实主义”: 学习型交通模型

我们希望生成易发生事故的场景, 这些场景被认为在短时间 (< 10 秒) [37] 发展。因此, 交通建模被表述为未来预测, 它根据所有智能体过去的运动轨迹预测它们未来的轨迹。我们学习 $p_\theta(Y|X, \mathcal{M})$ 以实现基于固定过去 $X = \{\mathbf{X}^i\}_{i=1}^N$ (定义方式与 Y 类似) 和地图 $\mathcal{M}$ 对未来场景 Y 的采样。交通模型的两个特性使其特别适合下游优化: 低维潜在空间以实现高效优化, 以及在此潜在空间上的先验分布以确定给定场景的合理性。受近期工作 [6, 49], 的启发, 我们设计了一种条件变分自编码器 (CVAE), 如图2所示, 它在学习准确且场景一致的联合未来预测的同时满足这些标准。我们在此简要介绍其架构和训练过程, 具体细节请参考补充材料。

架构。为了在测试时采样未来的运动, 使用条件先验和解码器; 两者都是图神经网络 (GNN), 在所有智能体的全连接场景图上运行。先验模型 $p_\theta(Z|X, \mathcal{M})$, 其中 $Z = \{\mathbf{z}^i\}_{i=1}^N$ 是一组智能体潜在向量。输入场景图中的每个节点包含从该智能体过去轨迹、局部光栅化地图、边界框大小和语义类别中提取的上下文特征 $\mathbf{h}^i$ 。经过消息传递后, 先验为场景中的每个智能体输出高斯 $p_\theta(\mathbf{z}^i|X, \mathcal{M}) = \mathcal{N}(\mu_\theta^i(X, \mathcal{M}), \sigma_\theta^i(X, \mathcal{M}))$ 的参数, 形成一个“分布式”潜在表示, 该表示捕获了可能未来的变化。

确定性解码器 $Y = d_\theta(Z, X, \mathcal{M})$ 在场景图上运行, 每个节点都具有采样的潜在 $\mathbf{z}^i$ 和过去的上下文 $\mathbf{h}^i$ 。解码器是自回归执行的: 在时间步 t , 一轮消息传递解决“交互”, 然后预测每个智能体的加速度 $\dot{v}_t, \dot{\theta}_t$ 。加速度立即通过运动学自行车模型 [28, 42] 以获得下一个状态 $\mathbf{y}_{t+1}^i$, 该状态更新 $\mathbf{h}^i$ 后再继续推进。解码器的确定性和图结构即使在智能体 $\mathbf{z}$ 独立采样时, 也鼓励场景一致的未来预测。对于潜在优化而言, 解码器通过使用运动学自行车模型确保合理的车辆动力学, 即使输入 Z 不太可能。

训练。训练是在 (X, Y_{gt}) 对上进行的




图2. 学习到的交通模型的测试时架构。为了联合采样场景中所有智能体的未来轨迹，先分别对每个智能体处理过去的运动和局部地图上下文。条件先验随后在每个节点输出一个潜空间分布，该分布可以被采样并通过自回归解码器来预测未来智能体轨迹。

使用改进的CVAE目标：

$$\mathcal{L}_{\text{cvae}} = \mathcal{L}_{\text{recon}} + w_{\text{KL}} \mathcal{L}_{\text{KL}} + w_{\text{coll}} \mathcal{L}_{\text{coll}}. \quad (2)$$

为了优化这个损失，引入了一个类似于先验的后验网络 $q_\phi(Z|Y_{\text{gt}}, X, \mathcal{M})$ ，但该网络联合处理过去的和未来的运动。未来轨迹特征被单独提取，而过去特征与先验中使用的相同。完整的训练损失使用来自后验 Y_{post} 和先验 Y_{prior} 的轨迹样本：

$$\mathcal{L}_{\text{recon}} = \sum_{i=1}^N \|Y_{\text{post}}^i - Y_{\text{gt}}^i\|^2 \quad (3)$$

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(Z|Y_{\text{gt}}, X, \mathcal{M}) \| p_\theta(Z|X, \mathcal{M})) \quad (4)$$

$$\mathcal{L}_{\text{coll}} = \mathcal{L}_{\text{agent}} + \mathcal{L}_{\text{env}} \quad 5$$

其中 $Y_{\text{post}}^i \in Y_{\text{post}}$, $Y_{\text{gt}}^i \in Y_{\text{gt}}$, 和 D_{KL} 是KL散度。碰撞惩罚 $\mathcal{L}_{\text{agent}}$ 和 $\mathcal{L}_{\text{env}}$ 使用碰撞检测的可微分近似，如 [49], 所示，该近似将车辆表示为一系列圆盘来惩罚 Y_{prior} 智能体之间的碰撞或与不可驾驶地图区域的碰撞。

3.2. 对抗优化

为了利用已学习的交通模型，用于初始化优化的真实世界场景被划分为过去 X 和未来 Y_{init} 。在优化过程中， X 中的过去轨迹（包括规划器的轨迹）保持固定，而未来轨迹被扰动以与给定的规划器 f 发生碰撞。这种扰动是在交通模型的学习潜在空间中进行的——如下所述，我们优化所有 N 非自身智能体

$Z = \{z^i\}_{i=1}^N$ 的潜在集，以及规划器的潜在表示 z^{plan} 。

潜在场景参数化通过两种方式鼓励合理性。首先，由于解码器在真实世界数据上进行了训练，如果 Z 保持接近学习到的流形，它将输出现实的交通模式。其次，学习到的先验网络给出一个潜在分布，该分布用于惩罚不太可能的 Z 。这种行为合理性的强先验使得可以联合优化场景中的所有智能体，而不是预先选择一小部分特定的对手。

在优化的每一步（图3），扰动的 sce-




图3. 在对抗优化的每一步中，规划器和非自我智能体的潜在表示都通过学习到的解码器进行解码，非自我轨迹被提供给规划器以在场景中进行推演。最后，计算损失。

nario 使用 $d_\theta(Z, z^{\text{plan}}, X, \mathcal{M})$ 解码，非自我轨迹 Y 被传递给（黑盒）规划器，该规划器在计算损失之前先展开自我运动。对抗优化寻求两个同时的目标：

1. 匹配规划器。尽管优化对规划器的行为没有直接控制权——它只是一个在需要时才被查询的外部函数——但仍然需要在交通模型中表示规划器（即在场景图中包含它，并关联一个潜在 z^{plan} ），以便与其他智能体的交互是真实的。为此，解码器的未来预测包括对规划器轨迹 $\hat{Y}^{\text{plan}}$ 的估计，理想情况下，该轨迹应接近真实的规划器轨迹 $Y^{\text{plan}} = f(Y, \mathcal{M})$ 。请注意，这为规划器提供了一个可微分的近似，从而可以使用典型的基于梯度的优化来处理下面描述的第二目标。为了鼓励将真实的规划器输出与这个“内部”近似相匹配，我们使用

$$\min_{z^{\text{plan}}} \|\hat{Y}^{\text{plan}} - Y^{\text{plan}}\|^2 - \alpha \log p_\theta(z^{\text{plan}} | X, \mathcal{M}) \quad (6)$$

在适当术语轻微正则化 z^{plan} 以保持可能符合先验知识，并 α 平衡这两个术语的地方。

2. 与规划器碰撞。非自主智能体的目标是让规划器与另一辆车发生碰撞：

$$\min_Z \mathcal{L}_{\text{adv}} + \mathcal{L}_{\text{prior}} + \mathcal{L}_{\text{init}} + \mathcal{L}_{\text{coll}}. \quad (7)$$

对抗项通过最小化受控智能体与规划器当前交通模型近似之间的位置距离来促使碰撞：

$$\mathcal{L}_{\text{adv}} = \sum_{i=1}^N \sum_{t=1}^T \delta_t^i \cdot \|\mathbf{y}_t^i - \hat{\mathbf{y}}_t^{\text{plan}}\|^2 \quad (8)$$

$$\delta_t^i = \frac{\exp(-\|\mathbf{y}_t^i - \hat{\mathbf{y}}_t^{\text{plan}}\|)}{\sum_j \sum_t \exp(-\|\mathbf{y}_t^j - \hat{\mathbf{y}}_t^{\text{plan}}\|)} \quad (9)$$

$\mathbf{y}_t$ 的位置仅包括2D坐标。直观上，Eq. (9)中softmin定义的 δ_t^i 系数正在寻找一个候选智能体和时间段，以便与规划器发生碰撞。距离最大的智能体 δ_t^i 最有可能是基于距离的“对手”，而Eq. (8)优先考虑在允许梯度到达其他智能体的同时，使这个对手与规划器发生碰撞。这种加权有助于 $\mathcal{L}_{\text{prior}}$ 避免所有智能体都与规划器不切实际地发生碰撞。

先验项鼓励潜在值保持在学习的先验网络下：

$$\mathcal{L}_{\text{prior}} = -\frac{1}{N} \sum_{i=1}^N \gamma^i \cdot \log p_{\theta}(\mathbf{z}^i | X, \mathcal{M}) \quad (10)$$

$$\gamma^i = 1 - \sum_t \delta_t^i. \quad (11)$$

该 γ^i 系数将权重施加在接近零的对手上，即允许与规划器即将发生碰撞的智能体偏离学习到的交通流形，以表现出罕见且具有挑战性的行为。由于交通模型训练数据不包含碰撞，我们发现使用较大的先验损失很难让智能体与规划器发生碰撞，因此促成了Eq. (11)中的加权。请注意，即使 γ^i 很小，智能体也会保持物理上的合理性，因为解码器使用了运动学自行车模型。

$\mathcal{L}_{\text{init}}$ 鼓励在潜在空间中保持与初始化的接近性，因为其已经被认为是现实的：

$$\mathcal{L}_{\text{init}} = \frac{1}{N} \sum_{i=1}^N \gamma^i \cdot \|\mathbf{z}^i - \mathbf{z}_{\text{init}}^i\|^2 \quad (12)$$

那么 $\mathbf{z}_{\text{init}}^i \in Z_{\text{init}}$ 初始化优化的潜在在哪里。最后，类似于 CVAE 训练， $\mathcal{L}_{\text{coll}}$ 阻止非自我代理彼此以及非可驾驶区域发生碰撞。在实践中，所有损失项都通过手动检查一小部分生成的场景来平衡。

初始化与优化。给定一个真实场景， Z_{init} 通过后验网络 q_{ϕ} 获取，然后通过一种适用于所有智能体输入未来轨迹的初始化优化进行进一步细化（类似于公式(6)），包括初始规划器滚动。优化在 PyTorch [40] 中使用 ADAM [26] 并以学习率 0.05 实现。运行时间取决于规划器和智能体数量；对于我们的基于规则的规划器（见第 4.2 节），一个 10 个智能体的场景需要 6-7 分钟。

4. 分析和使用生成的场景

4.1. 过滤和碰撞分类

解优化。对抗优化可以产生合理的场景，但它不能保证这些场景是可解的和有用的：例如，一个自我被多辆车挤压的场景会导致不可避免的碰撞，因此对评估或改进规划器没有信息量。因此，我们执行额外的优化以识别避免碰撞的自我轨迹；如果此优化失败，该场景将被丢弃用于下游任务。此解优化从对抗优化的输出初始化，并本质上反转了第 3.2 节中描述的目标：非自我潜在 $\mathbf{z}$ 被调整以保持对抗轨迹，而 $\mathbf{z}^{\text{plan}}$ 被优化以避免碰撞并在先验条件下保持可能性。

聚类 and 标记。为了深入了解碰撞场景的分布并指导其下游使用，我们提出了一种简单的聚类和标记方法。具体来说，场景的特征在于碰撞发生时规划器和对手之间的显式关系：对手的相对方向和航向在规划器的框架内被计算并连接起来，形成每个场景的碰撞特征。这些特征使用 k -均值进行聚类，形成语义上相似的碰撞组，并由人工视觉检查进行标记。它们的分布可以像图 6 那样进行可视化。

4.2. 改进规划器

通过大量标记的碰撞场景，规划器可以从两个方面进行改进。首先，如果生成了许多相同类型的场景，可能需要对功能进行离散改进。例如，一个严格遵循车道的规划器会因为无法变道而受到正面或后方碰撞，这表明需要新的功能来离开车道图。其次，场景为调整超参数或学习参数提供了数据。

基于规则的规划器。为了展示STRIVE场景如何用于这些改进，我们引入了一个简单但功能完备的基于规则规划器，将其作为真实世界规划器的代理。我们的规划器非常适合评估STRIVE，因为它易于解释，使用少量超参数，并且具有已知的失效模式。简而言之，它完全依赖于车道图来预测非自身车辆的轨迹，并为自身车辆生成候选轨迹。在这些候选轨迹中，它选择覆盖距离最远且“碰撞概率”较低的轨迹。规划器行为受最大速度/加速度等超参数以及碰撞概率计算方式的影响。该规划器还有一个额外限制，即无法变道，而STRIVE生成的场景在5.3节中暴露了这一点。该规划器的详细信息包含在补充材料中。

5. 实验

接下来，我们重点介绍STRIVE带来的新功能。

5.1节展示了STRIVE在两个不同规划器上生成具有挑战性和实用性的场景的能力；这些场景包含多样化的碰撞类型，如5.2节分析所示。生成的场景用于在5.3节中改进我们的基于规则规划器。

数据集。使用nuScenes数据集 [5] 来训练交通模型并初始化对抗优化。它包含 20s 以 2 Hz 频率标注的交通片段，我们将其分割成 8s 个场景。仅使用汽车和卡车车辆，交通模型在栅格化的可驾驶区域、停车场区域、分隔带和车道分隔线地图层上运行。我们使用 nuScenes 预测挑战的划分和设置，该设置是 2s (4步) 的过去运动来预测 6s (12步) 的未来，这意味着碰撞场景是 8s 长的，但仅优化未来的 6s 轨迹。

规划器。场景生成在两个不同的规划器上评估。

Replay 规划器简单地回放 nuScenes 数据中的真实自我轨迹。这是一个开环设置，其中规划器的 6s 未来完全展开，无需重新规划。基于规则的规划器，如第 4.2 节所述，允许更现实的闭环设置，其中规划器在 5 Hz 频率下通过重新规划对周围智能体做出反应，在未来的展开过程中。

指标。碰撞率是指从 nuScenes 中优化的初始场景中，有多少比例成功导致规划器发生碰撞，这表明场景生成的样本效率。解决方案率是指这些发生碰撞的场景中有多少比例找到了解决方案，这衡量场景的实用性。加速度表示驾驶轨迹的舒适度；具有挑战性的场景通常应增加规划器的加速度，而对手的加速度应保持在合理水平以维持真实性。如果一个场景包含碰撞，加速度（和其他轨迹指标）仅计算到碰撞发生的时间。碰撞速度是指规划器和对手在碰撞时的相对速度；它指向碰撞的严重程度。

5.1. 场景生成评估

首先，我们证明 STRIVE 生成的场景具有挑战性，但可解，导致规划器发生碰撞并驾驶不舒适。此外，与不利用学习到的交通先验的替代生成方法相比，STRIVE 场景更真实。场景生成从 nuScenes 的 1200 8s 序列初始化。在对抗优化之前，场景通过启发式方法预先过滤，根据它们产生有用碰撞的可能性，留下 <500 场景进行优化。

规划器特定场景。表1显示，与在“常规”（未修改）nuScenes 场景上部署特定规划器相比，




图4。基于规则的规划器的定性结果。展示了对抗性和解优化结果。STRIVE 产生了包括变道、在规划器前方掉头以及并对向车流在内的多样化碰撞场景。

STRIVE 的挑战性场景会导致更多碰撞，驾驶体验也不如常规场景舒适。对于基于规则的规划器，挑战性场景的指标与它们原始的常规场景集（重放场景的常规场景因 nuScenes 数据不包含碰撞，且根据定义规划器行为不会改变而省略）进行了比较。

碰撞率和解率表明生成的场景具有事故倾向性且有用（可解）。对于基于规则的规划器，对抗性优化导致 27.4% 的场景发生碰撞，而常规场景中仅为 1.2%。生成的场景在速度方面包含更严重的碰撞，并引发更大的加速度，即驾驶体验更不舒适。对抗性优化结束时，近似 ($\hat{Y}^{plan}$) 和真实 (Y^{plan}) 规划器轨迹之间的位置和角度误差如图右侧所示（参见第 3.2 节）。

1.23m 的最大位置误差相对于规划器车辆的 4.084m 长度来说是合理的。基于规则的规划器的定性结果可视化了 2D 航点轨迹（图 4）；虽然未展示，STRIVE 也生成了速度和航向。

基线对比。STRIVE 与基线方法进行对比，以证明利用学习到的交通模型对于实现真实且有用的场景至关重要。先前的工作无法直接比较，因为它们专注于小规模场景生成（例如 [1,9]）和/或攻击完整的自动驾驶（AV）堆栈，而不是仅攻击规划器 [38,55]。因此，在 AdvSim [55] 的精神下，我们实现了自行车基线，该基线明确优化场景中单个预先选择的对手的动力学自行车模型参数（加速度曲线），以造成碰撞。它不使用学习到的交通模型，而是依赖自行车模型、碰撞惩罚和加速度正则化来保持合理性。这禁止使用来自交通模型的可微分规划器近似，因此需要梯度估计（例如有限差分）来为闭环设置进行梯度估计，我们发现这 [1,9] 更慢，并且需要数小时才能生成单个场景。因此，仅在 Replay 规划器上进行比较。

规划器	场景	碰撞 (%)	解决方案 (%)	规划轨迹		匹配规划误差	
				加速度 (m/s^2)	合速度 (m/s)	位置 (m)	角度 (deg)
重播	挑战	43.7 (+43.7)	82.4	0.85	7.82	0.28	1.32
基于规则的	常规	1.2	—	1.63	8.48	—	—
基于规则的	具有挑战性的	27.4 (+26.2)	86.8	1.91 (+0.28)	9.65 (+1.17)	1.23	3.79

表1. 生成的挑战性场景评估。生成的场景与对应的常规（未修改）场景相比，包含远更多的碰撞，以及更高的加速度和碰撞速度。加速度沿前进方向测量（即速度变化），因为基于规则的规划器无法变道。最右侧列显示 $\hat{Y}^{plan}$ 与 Y^{plan} 之间的小误差。

场景	对手轨迹 ↓ 的合理性			有用性 ↑	
	加速(m/s^2)	环境碰撞 (%)	神经网络距离 (m)	NLL 解 (%)	
自行车	2.00	16.5	0.97	962.9	73.4
STRIVE	0.98	10.8	0.72	323.4	83.5

表2. 与自行车基线（不利用学习到的交通模型）相比的回放规划器场景生成

这阻止了使用来自交通模型的可微分规划器近似，因此需要梯度估计（例如有限差分）来为闭环设置进行梯度估计，我们发现这 $\approx 40\times$ 更慢，并且需要数小时才能生成单个场景。因此，仅在 Replay 规划器上进行比较。

表2显示，自行车生成的场景表现出更多不切实际的对抗性驾驶，且更难以找到解决方案。所有指标仅报告在两种方法均成功导致碰撞的场景中。除了更高的加速度外，自行车的对手代理更频繁地与不可驾驶区域碰撞（环境碰撞），并且其典型轨迹较少，这通过 nuScenes 训练集中最邻近的自身轨迹的距离来衡量（最近邻距离）。在将自行车生成的场景拟合到我们的交通模型后，我们看到对手代理的行为也较不真实，这通过其潜在 z 在已学习的先验下的负对数似然（NLL）来衡量。这些观察结果在图5中得到了定性的支持。

5.2. 分析生成的场景

在改进给定的规划器之前，使用第4.1节的分析来通过过滤掉不可解场景和分类碰撞类型来识别有用场景。对于分类，碰撞特征使用 $k = 10$ 进行聚类，并将聚类可视化以手动分配图6中显示的语义标签。第5.1节中两个规划器生成的碰撞场景分布如图6(a)所示

（补充材料提供了来自聚类的可视化示例）。STRIVE生成了多样化的场景集，其中所有聚类中都能找到可解场景。“迎头相撞”是最常见的场景类型，可能是因为Replay是非反应性的，而基于规则的规划器无法变道。“后方碰撞”表现出最高的不可解场景率，因为从后面被撞击通常是因跟车车辆疏忽，而不是规划器的不理想行为。




图5. 回放规划器生成的场景的定性比较。自行车经常产生语义上不切实际的轨迹，因为它没有利用学习到的交通模型。

Replay由于是开环控制，因此更容易被强行变道，而闭环的基于规则的规划器可以成功反应以避免此类碰撞。

5.3. 改进基于规则的规划器

现在我们已经拥有大量标记的碰撞场景，除了包含“常规”场景（碰撞较少）的原始 nuScenes 数据集外，我们可以改进基于规则的规划器，使其更好地应对具有挑战性的情况。除了发现导致我们添加新功能的根本缺陷外，改进还基于通过网格搜索在可能的设置上进行超参数调整。对于每组超参数，规划器会在数据集的所有场景中部署，并根据最低碰撞率选择最佳调整。

规划器首先在常规场景上进行调优，然后再进行对抗性优化，以创建一组具有挑战性的场景来指导进一步的改进。表3顶行显示了该初始常规调优规划器在保留的常规（Reg）和碰撞（Coll）场景上的性能。在任何改进之前，规划器在68.6%的具有挑战性的场景和4.6%的常规场景中发生碰撞。请注意，在常规场景上完全避免碰撞是不可能的：即使我们为每个场景单独选择最优超参数，碰撞率仍然为3.2%。




图6. (底部) 显示了碰撞类型；箭头指示了对手的位置/方向。(a) 两个规划器生成的场景分布。(b) 用于调整多模式预言机规划器的场景。所有参数设置都导致碰撞的场景显示为红色。大多数迎头、从右侧前方和后方场景由于无法变道而总是失败。

改进	碰撞 (%)		速度(m/s)		加速 (m/s ²)	
	常规 / 碰撞	常规 / 碰撞	常规 / 碰撞	常规 / 碰撞	常规 / 碰撞	常规 / 碰撞
无 (常规调优)	4.6 / 68.6	4.59 / 10.48	1.96 / 2.26			
+ 数据挑战	6.0 / 51.4	5.48 / 13.88	2.29 / 2.50			
+ 额外学习模式	4.6 / 54.3	4.60 / 10.86	2.02 / 2.55			
+ 额外预言模式	4.6 / 54.3	4.59 / 10.40	1.96 / 2.39			

表3. 改进基于规则的规划器。包含具有挑战性的调优数据并添加一个额外的“模式”可提高在碰撞场景 (Coll) 中的性能，同时保持在常规场景 (Reg) 中的性能。加速是向前的。

在具有挑战性的场景上调优。第一个改进，如图3第二行所示，是将常规场景和具有挑战性的场景结合起来进行调优。组合调优大大降低了具有挑战性场景的碰撞率，但负面影响常规驾驶性能。这指向了一个首要的基本问题：规划器对所有驾驶情况使用同一组超参数，导致在具有挑战性的场景上调优时，在常规场景中驾驶过于激进。

多模式操作。为了解决这个问题，我们添加了一组第二参数，以便规划器为常规情况和易出事故的情况各有一个。使用这个第二“事故模式”的操作需要二进制分类

在回放过程中对当前场景进行分类。为此，我们为规划器增加了一个学习组件，该组件根据一个移动窗口来决定使用哪个参数集。

过去的交通 2s；它是基于STRIVE生成的场景进行训练的。额外的参数集仅在碰撞场景上进行调优。如表3的第三行所示，这种学习到的额外模式将具有挑战性的场景中的碰撞率降低了14.3%，而不会影响常规场景的性能。我们将其与一个自动在碰撞发生前切换到事故模式 2s 的预言版本（最下面一行）进行比较，

在生成的场景上使用笔，显示学习到的版本实现了接近最优的性能。

变道限制。规划器无法变道是碰撞场景暴露出的另一个基本问题。图6(b)显示了神谕多模式版本的调优场景分布；红色条表示所有评估的超参数集都发生冲突的“不可能”场景。大多数“迎头相撞”和“后方追尾”场景都是不可能的，这指出了变道限制。对抗优化确实利用了该缺陷，而提出的分析使其变得可见。

6. 讨论

STRIVE能够自动且可扩展地生成看似合理、易出事故的场景，以改进给定的规划器。然而，剩余的局限性为未来的研究方向提供了可能。我们的方法假设了完美的感知，并且只攻击规划器，但使用我们的交通模型来额外攻击检测和跟踪引起了极大的兴趣。STRIVE从现有数据生成场景，并且只考虑车辆之间的碰撞，但涉及行人和骑行者的其他事故也很重要，而添加/移除资产和改变地图拓扑等类型的对手将揭示额外的自动驾驶汽车 (AV) 弱点。我们的方法旨在通过让自动驾驶汽车暴露于类似真实世界的具有挑战性和罕见场景来提高其安全性。然而，我们的实验揭示了在调整规划器时，在常规数据和挑战性数据之间进行适当平衡的难度。必须小心地将生成的场景集成到自动驾驶汽车测试中，并设计能够稳健应对高度可变驾驶条件的统一规划器。

致谢。作者 Guibas 得到了范内瓦·布什教学奖学金的支持。作者们感谢 Amlan Kar 在整个项目中提供的富有成效的讨论和反馈。

参考文献

- [1] Yasasa Abeysirigoonawardena, Florian Shkurti, and Gregory Dudek. Generating adversarial driving scenarios in high-fidelity simulators. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 8271–8277. IEEE, 2019. 1, 2, 6
- [2] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016. 12
- [3] Mayank Bansal, Alex Krizhevsky, and Abhijit Ogale. Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst. In *Robotics: Science and Systems (RSS)*, 2019. 2, 3
- [4] Luca Bergamini, Yawei Ye, Oliver Scheel, Long Chen, Chih Hu, Luca Del Pero, Błażej Osiński, Hugo Grimmet, and Peter Ondruska. Simnet: Learning reactive self-driving simulations from real-world observations. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021. 2
- [5] Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multi-modal dataset for autonomous driving. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 11621–11631, 2020. 2, 6, 12, 13, 16, 18
- [6] Sergio Casas, Cole Gulino, Simon Suo, Katie Luo, Renjie Liao, and Raquel Urtasun. Implicit latent variable model for scene-consistent motion forecasting. In *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXIII 16*, pages 624–641. Springer, 2020. 2, 3, 12, 18
- [7] Sergio Casas, Abbas Sadat, and Raquel Urtasun. Mp3: A unified model to map, perceive, predict and plan. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14403–14412, 2021. 3
- [8] Yuning Chai, Benjamin Sapp, Mayank Bansal, and Dragomir Anguelov. Multipath: Multiple probabilistic anchor trajectory hypotheses for behavior prediction. In *Conference on Robot Learning (CoRL)*, pages 86–99. PMLR, 2020. 2
- [9] Baiming Chen, Xiang Chen, Qiong Wu, and Liang Li. Adversarial evaluation of autonomous vehicles in lane-change scenarios. *IEEE Transactions on Intelligent Transportation Systems*, 2021. 1, 2, 6
- [10] Henggang Cui, Vladan Radosavljevic, Fang-Chieh Chou, Tsung-Han Lin, Thi Nguyen, Tzu-Kuo Huang, Jeff Schneider, and Nemanja Djuric. Multimodal trajectory predictions for autonomous driving using deep convolutional networks. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 2090–2096. IEEE, 2019. 2
- [11] Jeevan Devaranjan, Amlan Kar, and Sanja Fidler. Meta-sim2: Unsupervised learning of scene structure for synthetic data generation. In *European Conference on Computer Vision*, pages 715–733. Springer, 2020. 2
- [12] Wenhao Ding, Baiming Chen, Bo Li, Kim Ji Eun, and Ding Zhao. Multimodal safety-critical scenarios generation for decision-making algorithms evaluation. *IEEE Robotics and Automation Letters*, 6(2):1551–1558, 2021. 1, 2
- [13] Wenhao Ding, Baiming Chen, Minjun Xu, and Ding Zhao. Learning to collide: An adaptive safety-critical scenarios generating method. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2243–2250. IEEE, 2020. 1, 2
- [14] Nemanja Djuric, Vladan Radosavljevic, Henggang Cui, Thi Nguyen, Fang-Chieh Chou, Tsung-Han Lin, Nitin Singh, and Jeff Schneider. Uncertainty-aware short-term motion prediction of traffic actors for autonomous driving. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 2095–2104, 2020. 2
- [15] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. Carla: An open urban driving simulator. In *Conference on robot learning*, pages 1–16. PMLR, 2017. 2
- [16] Scott Ettinger, Shuyang Cheng, Benjamin Caine, Chenxi Liu, Hang Zhao, Sabeek Pradhan, Yuning Chai, Ben Sapp, Charles Qi, Yin Zhou, et al. Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset. *ICCV*, 2021. 2
- [17] Liangji Fang, Qinhong Jiang, Jianping Shi, and Bolei Zhou. Tpnnet: Trajectory proposal network for motion prediction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 6797–6806, 2020. 2
- [18] Jiyang Gao, Chen Sun, Hang Zhao, Yi Shen, Dragomir Anguelov, Congcong Li, and Cordelia Schmid. Vectornet: Encoding hd maps and agent dynamics from vectorized representation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11525–11533, 2020. 2
- [19] Zahra Ghodsi, Siva Kumar Sastry Hari, Iuri Frosio, Timothy Tsai, Alejandro Troccoli, Stephen W Keckler, Siddharth Garg, and Anima Anandkumar. Generating and characterizing scenarios for safety testing of autonomous vehicles. In *2021 IEEE Intelligent Vehicles Symposium (IV)*, pages 157–164. IEEE, 2021. 2
- [20] J. Houston, G. Zuidhof, L. Bergamini, Y. Ye, A. Jain, S. Omari, V. Iglovikov, and P. Ondruska. One thousand and one hours: Self-driving motion prediction dataset. <https://level-5.global/level5/data/>, 2020. 2
- [21] Boris Ivanovic and Marco Pavone. The trajetron: Probabilistic multi-agent trajectory modeling with dynamic spatiotemporal graphs. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 2375–2384, 2019. 2
- [22] Daniel Johnson, Hugo Larochelle, and Daniel Tarlow. Learning graph structure with a finite-state automaton layer. *Advances in Neural Information Processing Systems*, 33:3082–3093, 2020. 2
- [23] Amlan Kar, Aayush Prakash, Ming-Yu Liu, Eric Cameracci, Justin Yuan, Matt Rusiniak, David Acuna, Antonio Torralba, and Sanja Fidler. Meta-sim: Learning to generate synthetic datasets. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4551–4560, 2019. 2
- [24] R. Kesten, M. Usman, J. Houston, T. Pandya, K. Nadhamuni, A. Ferreira, M. Yuan, B. Low, A. Jain, P. Ondruska, S. Omari, S. Shah, A. Kulkarni, A. Kazakova, C. Tao, L. Platinsky, W. Jiang, and V. Shet. Level 5 perception dataset 2020.

<https://level-5.global/level5/data/>, 2019. 2

- [25] Seung Wook Kim, , Jonah Philion, Antonio Torralba, and Sanja Fidler. DriveGAN: Towards a Controllable High-Quality Neural Simulation. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2021. 2
- [26] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015. 5, 13, 14, 15
- [27] Moritz Klischat and Matthias Althoff. Generating critical test scenarios for automated vehicles with evolutionary algorithms. In *2019 IEEE Intelligent Vehicles Symposium (IV)*, pages 2352–2358. IEEE, 2019. 1, 2
- [28] Jason Kong, Mark Pfeiffer, Georg Schildbach, and Francesco Borrelli. Kinematic and dynamic vehicle models for autonomous driving control design. In *2015 IEEE intelligent vehicles symposium (IV)*, pages 1094–1099. IEEE, 2015. 2, 3, 13
- [29] Vineet Kosaraju, Amir Sadeghian, Roberto Martín-Martín, Ian Reid, S Hamid Rezatofighi, and Silvio Savarese. Social-bigat: Multimodal trajectory forecasting using bicycle-gan and graph attention networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. 2
- [30] Stéphanie Lefèvre, Dizan Vasquez, and Christian Laugier. A survey on motion prediction and risk assessment for intelligent vehicles. *ROBOMECH journal*, 1(1):1–14, 2014. 2
- [31] Yiming Li, Congcong Wen, Felix Juefei-Xu, and Chen Feng. Fooling lidar perception via adversarial trajectory perturbation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 7898–7907, 2021. 2
- [32] Ming Liang, Bin Yang, Rui Hu, Yun Chen, Renjie Liao, Song Feng, and Raquel Urtasun. Learning lane graph representations for motion forecasting. In *European Conference on Computer Vision*, pages 541–556. Springer, 2020. 2
- [33] Yicheng Liu, Jinghuai Zhang, Liangji Fang, Qinhong Jiang, and Bolei Zhou. Multimodal motion prediction with stacked transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7577–7586, 2021. 2
- [34] Pablo Alvarez Lopez, Michael Behrisch, Laura Bieker-Walz, Jakob Erdmann, Yun-Pang Flötteröd, Robert Hilbrich, Leonhard Lücken, Johannes Rummel, Peter Wagner, and Eva-marie Wießner. Microscopic traffic simulation using sumo. In *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, pages 2575–2582. IEEE, 2018. 2
- [35] Yecheng Jason Ma, Jeevana Priya Inala, Dinesh Jayaraman, and Osbert Bastani. Likelihood-based diverse sampling for trajectory forecasting. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 13279–13288, 2021. 18
- [36] Michael Montemerlo, Jan Becker, Suhrid Bhat, Hendrik Dahlkamp, Dmitri Dolgov, Scott Ettinger, Dirk Haehnel, Tim Hilden, Gabe Hoffmann, Burkhard Huhnke, et al. Junior: The stanford entry in the urban challenge. *Journal of field Robotics*, 25(9):569–597, 2008. 3
- [37] Wassim G Najm, John D Smith, and Mikio Yanagisawa. *Pre-Crash Scenario Typology for Crash Avoidance Research*. U.S. Department of Transportation, National Highway Traffic Safety Administration, 2007. 3
- [38] Matthew O’Kelly, Aman Sinha, Hongseok Namkoong, Russ Tedrake, and John C Duchi. Scalable end-to-end autonomous vehicle testing via rare-event simulation. In *NeurIPS*, 2018. 1, 2, 6
- [39] Avik Pal, Jonah Philion, Yuan-Hong Liao, and Sanja Fidler. Emergent road rules in multi-agent driving environments. In *International Conference on Learning Representations*, 2020. 2
- [40] Adam Paszke, Sam Gross, Soumith Chintala, Gregory Chanan, Edward Yang, Zachary DeVito, Zeming Lin, Alban Desmaison, Luca Antiga, and Adam Lerer. Automatic differentiation in pytorch. In *Advances in Neural Information Processing Systems*, 2017. 5, 13
- [41] Jonah Philion, Amlan Kar, and Sanja Fidler. Learning to evaluate perception models using planner-centric metrics. In *CVPR*, 2020. 2
- [42] Philip Polack, Florent Althché, Brigitte d’Andréa Novel, and Arnaud de La Fortelle. The kinematic bicycle model: A consistent model for planning feasible trajectories for autonomous vehicles? In *2017 IEEE Intelligent Vehicles Symposium (IV)*, pages 812–818, 2017. 3, 13
- [43] Davis Rempe, Tolga Birdal, Aaron Hertzmann, Jimei Yang, Srinath Sridhar, and Leonidas J Guibas. Humor: 3d human motion model for robust pose estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11488–11499, 2021. 2
- [44] Cinjon Resnick, Or Litany, Amlan Kar, Karsten Kreis, James Lucas, Kyunghyun Cho, and Sanja Fidler. Causal bert: Improving object detection by searching for challenging groups. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*, pages 2972–2981, October 2021. 2
- [45] Abbas Sadat, Sergio Casas, Mengye Ren, Xinyu Wu, Pranaab Dhawan, and Raquel Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *European Conference on Computer Vision*, pages 414–430. Springer, 2020. 3
- [46] Abbas Sadat, Mengye Ren, Andrei Pokrovsky, Yen-Chen Lin, Ersin Yumer, and Raquel Urtasun. Jointly learnable behavior and trajectory planning for self-driving vehicles. In *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 3949–3956. IEEE, 2019. 3
- [47] Tim Salzmann, Boris Ivanovic, Punarjay Chakravarty, and Marco Pavone. Trajectron++: Dynamically-feasible trajectory forecasting with heterogeneous data. In *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVIII 16*, pages 683–700. Springer, 2020. 2, 18
- [48] Pei Sun, Henrik Kretschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, et al. Scalability in perception for autonomous driving: Waymo open dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2446–2454, 2020. 2

- [49] Simon Suo, Sebastian Regalado, Sergio Casas, and Raquel Urtasun. Trafficsim: Learning to simulate realistic multi-agent behaviors. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10400–10409, 2021. 2, 3, 4, 12, 13, 18
- [50] James Tu, Mengye Ren, Sivabalan Manivasagam, Ming Liang, Bin Yang, Richard Du, Frank Cheng, and Raquel Urtasun. Physically realizable adversarial examples for lidar object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13716–13725, 2020. 2
- [51] Christopher Urmson, Joshua Anhalt, J. Andrew (Drew) Bagnell, Christopher R. Baker, Robert E. Bittner, John M. Dolan, David Duggins, David Ferguson, Tugrul Galatali, Hartmut Geyer, Michele Gittleman, Sam Harbaugh, Martial Hebert, Thomas Howard, Alonzo Kelly, David Kohanbash, Maxim Likhachev, Nick Miller, Kevin Peterson, Raj Rajkumar, Paul Rybski, Bryan Salesky, Sebastian Scherer, Young-Woo Seo, Reid Simmons, Sanjiv Singh, Jarrod M. Snider, Anthony (Tony) Stentz, William (Red) L. Whittaker, and Jason Ziegler. Tartan racing: A multi-modal approach to the darpa urban challenge. Technical report, Carnegie Mellon University, Pittsburgh, PA, April 2007. 3
- [52] Sai Vemprala and Ashish Kapoor. Adversarial attacks on optimization based planners. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9943–9949. IEEE, 2021. 1, 2
- [53] Matt Vitelli, Yan Chang, Yawei Ye, Maciej Wolczyk, Błażej Osiński, Moritz Niendorf, Hugo Grimmett, Qiangui Huang, Ashesh Jain, and Peter Ondruska. SafetyNet: Safe planning for real-world self-driving vehicles using machine-learned policies. *arXiv preprint arXiv:2109.13602*, 2021. 3
- [54] Eric A Wan and Rudolph Van Der Merwe. The unscented kalman filter for nonlinear estimation. In *Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium (Cat. No. 00EX373)*, pages 153–158. Ieee, 2000. 2
- [55] Jingkan Wang, Ava Pun, James Tu, Sivabalan Manivasagam, Abbas Sadat, Sergio Casas, Mengye Ren, and Raquel Urtasun. Advsim: Generating safety-critical scenarios for self-driving vehicles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9909–9918, 2021. 1, 2, 3, 6, 15
- [56] Yuxin Wu and Kaiming He. Group normalization. In *Proceedings of the European conference on computer vision (ECCV)*, pages 3–19, 2018. 12
- [57] Ye Yuan and Kris Kitani. Dlow: Diversifying latent flows for diverse human motion prediction. In *European Conference on Computer Vision*, pages 346–364. Springer, 2020. 18
- [58] Ye Yuan, Xinshuo Weng, Yanglan Ou, and Kris Kitani. Agentformer: Agent-aware transformers for socio-temporal multi-agent forecasting. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021. 18
- [59] Wenyuan Zeng, Wenjie Luo, Simon Suo, Abbas Sadat, Bin Yang, Sergio Casas, and Raquel Urtasun. End-to-end interpretable neural motion planner. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8660–8669, 2019. 3

附录

在此，我们包含了一些因篇幅限制而省略于正文的补充技术细节和结果。附录A提供了主要技术方法的详细信息，附录B提供了实验的详细信息，附录C提供了补充正文中结果的额外结果。

视频结果。我们鼓励在项目页面上查看视频结果，以更好地了解STRIVE生成的场景类型。

A. 方法细节

在本节中，我们提供了关于正文第3、4和5节中介绍的方法的补充技术和实现细节。请注意，由于许多形式化的优化问题非常相似，数学符号通常会被重载，并且可能根据章节/优化问题的不同而略有不同。这一点在正文中始终会注明。

A.1. 学习型交通模型

学习型交通模型在主论文的3.1节中介绍。这里我们更详细地介绍了架构的主要组件。所有神经网络组件都使用ReLU激活和层归一化 [2]，除非另有说明。

状态表示。在实践中，用作交通模型输入和监督的轨迹表示为 $\mathbf{Y}^i = [\mathbf{y}_1^i, \mathbf{y}_2^i, \dots, \mathbf{y}_T^i]$ ，用于智能体 i ，包含 T 个时间步，其中时间 t 的状态是 $\mathbf{y}_t^i = [x_t, y_t, \theta_t^x, \theta_t^y, v_t, \dot{\theta}_t] \in \mathbb{R}^6$ ，包含2D位置 (x_t, y_t) 、航向单位向量 (θ_t^x, θ_t^y) 、速度 v_t 和偏航率 $\dot{\theta}_t$ 。

特征提取。首先基于以下内容提取场景中每个智能体的上下文特征：过去的轨迹 X^i 、地图 $\mathcal{M}$ 、语义类 s^i 的 one-hot 编码（在主论文的实验中为汽车或卡车）、以及智能体的边界框长/宽 $\mathbf{b}^i = (l, w)$ 。每个智能体的过去轨迹特征 $\mathbf{p}^i \in \mathbb{R}^{64}$ 是从 X^i 、 s^i 和 $\mathbf{b}^i$ 使用一个隐藏层大小为 128 的 4 层 MLP 进行编码的。为了处理 nuScenes [5]，中智能体未标注的缺失帧，过去编码 MLP 还会为每个输入时间步提供一个标志，指示该时间步的智能体状态是否有效，即是否为真实的 nuScenes 数据或已被填充为零的虚拟数据。地图特征 $\mathbf{m}^i \in \mathbb{R}^{64}$ 是从智能体在 X^i 最后一步周围的局部地图裁剪（大小为 256×256 ，17m 在后方，60m 在前方，38.5m 在两侧）中提取的。地图输入包含每个层级的通道数（nuScenes 中的可驾驶区域、停车场区域、道路分隔线和车道分隔线）；每层都是以 4 像素/m 的分辨率进行二值化图像栅格化的。地图提取网络是一个 CNN，包含 6 个卷积层（步长 2，卷积核大小 [7, 5, 5, 3, 3, 3]，和滤波器数量 i ），然后是一个全连接层。地图提取在层之间 $\mathcal{M}$ 使用组归一化。

38.5m 在两侧）中提取的。地图输入包含每个层级的通道数（nuScenes 中的可驾驶区域、停车场区域、道路分隔线和车道分隔线）；每层都是以 4 像素/m 的分辨率进行二值化图像栅格化的。地图提取网络是一个 CNN，包含 6 个卷积层（步长 2，卷积核大小 [7, 5, 5, 3, 3, 3]，和滤波器数量 i ），然后是一个全连接层。地图提取在层之间 $\mathcal{M}$ 使用组归一化。




图7。碰撞惩罚。(a) 通过一组5个圆盘为每辆车计算 $\mathcal{L}_{\text{agent}}$ 估计。(b) $\mathcal{L}_{\text{env}}$ 根据碰撞点 c 与车辆位置之间的距离计算。

和滤波器数量 [16, 32, 64, 64, 128, 128]，然后是一个全连接层。地图提取在层之间 [56] 使用组归一化。

先验网络。先验网络的输入是一个全连接的场景图，每个节点都有一个上下文特征，该特征是先前详细描述的特征 $\mathbf{h}^i = [\mathbf{p}^i, \mathbf{m}^i, \mathbf{s}^i]$ 的连接。在消息传递之前，每个 $\mathbf{h}^i$ 都会通过一个小型 3 层输入 MLP 进行进一步处理，使其大小为 128。

先验网络、后验网络和解码器都是与场景交互模块 [6, 49] 类似的图神经网络 (GNN)。它们执行一轮消息传递，该传递涉及边网络、聚合函数和更新网络。考虑场景图中的一个单个节点 i 。首先，为每条传入边计算交互特征。对于来自节点 $j \rightarrow i$ 的边，使用边网络 $\mathcal{E}$ 计算 $\mathbf{e}^{ij} = \mathcal{E}(\mathbf{h}^i, \mathbf{h}^j, \mathcal{T}^{ij})$ ，其中 $\mathcal{T}^{ij}$ 是智能体 j 在智能体 i 的局部坐标系中的相对位置和朝向。 $\mathcal{E}$ 是一个 3 层 MLP，具有 128 个隐藏层和输出层的大小。在计算所有边特征后，它们使用 maxpooling $\mathbf{e}^i = \max(\mathbf{e}^{i1}, \mathbf{e}^{i2}, \dots)$ 聚合为单个交互特征 $\mathbf{e}^i \in \mathbb{R}^{128}$ 。更新网络然后为每个节点 $\mathbf{o}^i = \mathcal{U}(\mathbf{h}^i, \mathbf{e}^i)$ 提供输出；它是一个具有 128 个隐藏层大小的 4 层 MLP。

对于先前的网络，每个节点的输出是高斯分布的参数。具体来说， $\mathbf{o}^i = [\mu^i, \sigma^i]$ 其中 $\mu^i \in \mathbb{R}^{32}$ 给出均值， $\sigma^i \in \mathbb{R}^{32}$ 参数化对角协方差矩阵，使得 $p_\theta(\mathbf{z}^i | X, \mathcal{M}) = \mathcal{N}(\mu_\theta^i(X, \mathcal{M}), \sigma_\theta^i(X, \mathcal{M}))$ 其中 θ 是先验网络的 learned 参数。

后置（编码器）网络。近似后置网络（在CVAEs中通常称为编码器）用于 (i) 训练期间和 (ii) 初始化对抗优化。它与先验网络几乎相同，但为每个智能体接收一个从未来轨迹中提取的额外未来特征。每个智能体的未来轨迹特征 $\mathbf{f}^i \in \mathbb{R}^{64}$ 使用隐藏层大小为 128 的 4 层 MLP 从 $\mathbf{Y}_{\text{gt}}^i$ 、 $\mathbf{s}^i$ 和 $\mathbf{b}^i$ 进行编码。场景图输入到后置网络的节点 i 包含 $[\mathbf{f}^i, \mathbf{p}^i, \mathbf{m}^i, \mathbf{s}^i]$ 的连接，其中 $\mathbf{p}^i$ 、 $\mathbf{m}^i$ 是提供给先验网络的相同过去和地图特征。输入处理和消息传递与先验网络相同，最终输出也是一个关于潜在分布 $q_\phi(\mathbf{z}^i | \mathbf{Y}_{\text{gt}}, X, \mathcal{M}) = \mathcal{N}(\mu_\phi^i(\mathbf{Y}_{\text{gt}}, X, \mathcal{M}), \sigma_\phi^i(\mathbf{Y}_{\text{gt}}, X, \mathcal{M}))$ 的分布，其中 ϕ 是网络的学习参数。

的参数。

解码网络。正如主论文所述，解码器以自回归的方式逐步推进，一次预测一个未来步骤。在预测步骤 t 时，输入场景图的每个节点都包含 $[z^i, \mathbf{p}_{t-1}^i, \mathbf{m}_{t-1}^i, \mathbf{s}^i, \mathbf{b}^i]$ 的串联，其中 z^i 从先验或后验输出中采样。过去和地图特征在整个自回归推进过程中更新，因此用时间下标表示；最初它们与提供给先验的完全相同，即 $\mathbf{p}_0^i = \mathbf{p}^i$ 和 $\mathbf{m}_0^i = \mathbf{m}^i$ 。

在推进的步骤 t ，串联的输入特征首先通过一个3层输入MLP（隐藏大小128）进行处理，以在每个节点获得一个64维特征。与先验相同的方式，进行一轮消息传递以在每个节点获得输出 $\mathbf{o}_t^i = [\dot{v}_t^i, \ddot{\theta}_t^i] \in \mathbb{R}^2$ ，其中包含当前的线性和角加速度。然后使用运动学自行车模型 [28, 42] 来获得实际智能体状态

$\mathbf{y}_t^i = \mathcal{K}(\mathbf{y}_{t-1}^i, \mathbf{o}_t^i, \mathbf{b}^i)$ 。在进行推进的下一步之前，必须根据新状态更新过去和地图上下文特征。特别是，使用一个3层门控循环单元RNN $\mathbf{p}_t^i = \text{GRU}(\mathbf{p}_{t-1}^i, \mathbf{y}_t^i)$ （GRU使用64大小的隐藏状态，此处为简洁省略）来更新过去特征。新的地图特征 $\mathbf{m}_t^i$ 使用与之前相同的CNN提取，但在局部帧 $\mathbf{y}_t^i$ 中使用了更新的地图裁剪。然后可以在每个节点更新特征为 $[z^i, \mathbf{p}_t^i, \mathbf{m}_t^i, \mathbf{s}^i, \mathbf{b}^i]$ ，然后再以完全相同的方式预测步骤 $t+1$ 。请注意解码器的自回归性质允许我们在需要时进一步推进到比6s训练范围更远的未来。

训练。训练使用改进的CVAE目标：

$$\mathcal{L}_{\text{cvae}} = \mathcal{L}_{\text{recon}} + w_{\text{KL}} \mathcal{L}_{\text{KL}} + w_{\text{coll}} \mathcal{L}_{\text{coll}} \quad (13)$$

$$\mathcal{L}_{\text{recon}} = \sum_{i=1}^N \|\mathbf{Y}_{\text{post}}^i - \mathbf{Y}_{\text{gt}}^i\|^2 \quad (14)$$

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_{\phi}(Z|\mathbf{Y}_{\text{gt}}, X, \mathcal{M}) \| p_{\theta}(Z|X, \mathcal{M})) \quad (15)$$

$$\mathcal{L}_{\text{coll}} = \mathcal{L}_{\text{agent}} + \mathcal{L}_{\text{env}}. \quad (16)$$

在实践中， $\mathcal{L}_{\text{recon}}$ 仅监督位置和朝向，即 $\mathbf{Y}_{\text{post}}^i$ 和 $\mathbf{Y}_{\text{gt}}^i$ 在公式(14)中仅包含 $[x_t, y_t, \theta_t^x, \theta_t^y]$ 。重建损失应用于后验分布中的一个样本，而碰撞损失使用先验分布中的一个样本。

$\mathcal{L}_{\text{agent}}$ 在TrafficSim [49]中被引入。它使用了一种可微分的车辆-车辆碰撞检测近似方法，该方法用圆盘表示所有 N 车辆。我们用5个半径为 r_i 的圆盘来估计每个智能体车辆 i ，如图7(a)所示，并通过对所有智能体对 $(\mathcal{L}_{\text{agent}}, [49])$ 在时间上的损失求和来计算损失

如下所示：

$$\mathcal{L}_{\text{agent}} = \frac{1}{N^2} \sum_{(i,j), i \neq j} \sum_{t=1}^T \mathcal{L}_{\text{pair}}(\mathbf{y}_t^i, \mathbf{y}_t^j) \quad (17)$$

$$\mathcal{L}_{\text{pair}}(\mathbf{y}_t^i, \mathbf{y}_t^j) = \begin{cases} 1 - \frac{d}{r_i + r_j}, & d \leq r_i + r_j \\ 0, & \text{otherwise} \end{cases} \quad (18)$$

其中 d 是所有代表智能体 i 和 j 的圆盘对之间的最小距离。

$\mathcal{L}_{\text{env}}$ 使用类似的想法来惩罚与不可行驶区域的碰撞。这种惩罚仅在nuScenes [5] 序列训练期间应用于标注的ego车辆，因为许多非ego车辆出现在标注地图之外。在每个 rollout 步骤中，通过检查 $\mathcal{M}$ 中栅格化的不可行驶层与栅格化的车辆边界框之间的重叠，检测ego车辆与不可行驶区域之间的碰撞，并将碰撞点 $\mathbf{c}$ 确定为所有与不可行驶区域重叠的车辆像素的平均值。然后计算损失：

$$\mathcal{L}_{\text{env}} = \frac{1}{T} \sum_{t=1}^T \mathcal{L}_{\text{drivable}}(\mathbf{y}_t, \mathcal{M}) \quad (19)$$

$$\mathcal{L}_{\text{drivable}}(\mathbf{y}_t, \mathcal{M}) = \begin{cases} 1 - \frac{d}{d_{\text{max}}}, & \text{if partial collision} \\ 0, & \text{otherwise} \end{cases} \quad (20)$$

d 表示车辆位置（边界框中心）与碰撞点 $\mathbf{c}$ 之间的距离， d_{max} 表示图7(b)中ego边界框对角线长度的一半。请注意，损失仅在发生部分碰撞时应用，即只有部分边界框与非可行区域重叠——这是因为如果车辆完全嵌入非可行区域，损失将不会提供有用的梯度。

交通模型使用PyTorch [40] 实现，并使用学习率为 $1e^{-5}$ 的ADAM优化器 [26] 训练110个epoch。损失使用 $w_{\text{KL}} = 4e^{-3}$ 加权， w_{coll} 被分为 $w_{\text{agent}} = 0.05$ 用于 $\mathcal{L}_{\text{agent}}$ 和 $w_{\text{env}} = 0.1$ 用于 $\mathcal{L}_{\text{env}}$ 。KL损失权重 w_{KL} 随时间线性退火，从训练开始时的0.0逐渐增加到第20个epoch时的最大值。

A.2. 初始化优化

如主论文第3.2节所述，对抗优化的初始化首先通过使用学习到的近似后验 $q_{\phi}(Z_{\text{init}}|\mathbf{Y}_{\text{init}}, X, \mathcal{M})$ 进行推理完成，然后运行初始化优化以获得最终 Z_{init} ，该最终结果封装了非自我代理 $Z = \{\mathbf{z}^i\}_{i=1}^N$ 以及潜在规划器 $\mathbf{z}^{\text{plan}}$ 。

初始化优化目标与主论文中的公式6几乎相同。它试图匹配非自主智能体（来自输入的nuScenes场景）和自主车辆（来自规划器滚动输出）在初始场景中的初始未来轨迹，这些轨迹包含在 $\{\mathbf{v}\}$ ：

(在初始场景内)

$$\min_{Z_{\text{init}}} w_{\text{match}} \|Y - Y_{\text{init}}\|^2 - w_{\text{prior}} \log p_{\theta}(Z_{\text{init}}|X, \mathcal{M}) \quad (21)$$

$Y = d_{\theta}(Z_{\text{init}}, X, \mathcal{M})$ 在哪里是解码后的初始场景，但仅使用位置和航向信息（即不使用速度）。为了初始化优化，我们使用 $w_{\text{match}} = 10.0$, $w_{\text{prior}} = 0.01$ ，并运行 175 次迭代。

A.3. 对抗优化

对抗优化在主论文的第 3.2 节中介绍。这里我们提供有关每个目标的详细信息。

匹配规划器。在实践中，主论文第 6 式中的目标仅使用 Y^{plan} 和 $\hat{Y}^{\text{plan}}$ 中包含的位置和航向信息（即不使用速度）。对于所有实验， $\alpha = 1e^{-5}$ 。

对抗损失。对抗目标（主论文第 8 式）中的 δ 系数可以显式地操纵，以阻止某些类型的场景。对于所有实验，如果代理 i 在时间 t 时“位于”规划器后面（即我们“屏蔽”这些代理），我们会动态设置 $\delta_t^i = 0$ 。“后面”是根据规划器的当前航向来确定的：如果代理在规划器的 180° 视野之外，则被认为在后面。这会阻止从后面发生的恶意碰撞的退化场景。

我们通过 $w_{\text{adv}} = 2.0$ 对主论文中公式 8 中的对抗损失进行加权。

先验损失。在实践中，我们不直接使用 γ^i 系数来为每个智能体加权先验损失。相反，我们使用它们通过在最小和最大超参数 $w_{\text{prior}}^{\min}$, $w_{\text{prior}}^{\max}$ 之间插值来为每个智能体计算动态权重。主论文中的公式 10 变为

$$\mathcal{L}_{\text{prior}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(\mathbf{z}^i|X, \mathcal{M}) \cdot w_{\text{prior}}(\gamma^i) \quad (22)$$

$$w_{\text{prior}}(\gamma^i) = \gamma^i w_{\text{prior}}^{\max} + (1 - \gamma^i) w_{\text{prior}}^{\min} \quad (23)$$

其中我们使用 $w_{\text{prior}}^{\min} = 5e^{-3}$ 和 $w_{\text{prior}}^{\max} = 1$ 。这比将其留给 $\gamma_i \in [0, 1]$ 提供了更细粒度的控制权。特别是，如果一个智能体很可能是对手（即接近与规划器发生碰撞），它的权重将接近 $w_{\text{prior}}^{\min}$ ，而距离较远的智能体将接近 $w_{\text{prior}}^{\max}$ 。

初始化损失。与之前的损失类似，初始化损失（主论文中的公式 12）实际上使用 γ^i 来插值最大和最小超参数，并写成：

$$\mathcal{L}_{\text{init}} = \frac{1}{N} \sum_{i=1}^N \|\mathbf{z}^i - \mathbf{z}_{\text{init}}^i\|^2 \cdot w_{\text{init}}(\gamma^i) \quad (24)$$

$$w_{\text{init}}(\gamma^i) = \gamma^i w_{\text{init}}^{\max} + (1 - \gamma^i) w_{\text{init}}^{\min} \quad (25)$$

其中我们使用 $w_{\text{prior}}^{\min} = 0.05$ 和 $w_{\text{prior}}^{\max} = 0.5$ 。

碰撞损失。对抗优化的碰撞项与用于训练交通模型的项相似：

$$\mathcal{L}_{\text{coll}} = w_{\text{agent}} \mathcal{L}_{\text{agent}} + w_{\text{env}} \mathcal{L}_{\text{env}} + w_{\text{plan}} \mathcal{L}_{\text{plan}}.$$

$\mathcal{L}_{\text{agent}}$ 与公式 (17) 中定义的相同，并应用于所有非本车，以避免它们相互碰撞。 $\mathcal{L}_{\text{env}}$ 与公式 (19) 中定义的相同，并应用于所有非本车（与 CVAE 训练中使用本车的情况不同），以鼓励保持在可行驶区域内。 $\mathcal{L}_{\text{plan}}$ 与 $\mathcal{L}_{\text{agent}}$ 相似，但不是通过阻止非本车代理之间的碰撞，而是通过阻止规划器与非本车代理之间发生碰撞（这些代理具有较大的 γ^i ，即不太可能是对手）。该术语仅影响那些靠近规划器但具有较大 γ^i 的代理，因为它们根据之前描述的方式被“屏蔽”了。直观上，我们不希望这些代理从后面“意外”与规划器发生碰撞。

所有碰撞损失都是基于通过 $\times 3$ 上采样后的轨迹计算的，以避免在低 nuScenes 频率（2 Hz）下遗漏碰撞。我们使用 $w_{\text{agent}} = w_{\text{env}} = w_{\text{plan}} = 20$ 。

优化。主论文中报告的对抗优化运行时使用了一台配备 NVIDIA Titan RTX GPU 和 12x Intel i7-7800X@3.50GHz CPU 的机器。我们使用 ADAM [26] 优化器进行 200 次迭代优化（我们发现 L-BFGS 对此问题过于容易陷入局部最小值），学习率为 0.05。

A.4. 解决方案优化

解决方案优化在主论文第 4.1 节中介绍。它试图为规划器找到一个避免对抗场景中碰撞的轨迹。与对抗优化类似，它优化 Z 和 $\mathbf{z}^{\text{plan}}$ 在交通模型的潜在空间中，并使用非常相似的目标：

1. 匹配对抗场景。所有非自车智能体应保持对抗优化输出的相同轨迹。令 Y_{adv} 为碰撞场景中的非自车轨迹集合， Y 为解决方案优化时的当前场景，则目标为：

$$\min_Z \|Y_{\text{adv}} - Y\|^2 - \alpha \log p_{\theta}(Z|X, \mathcal{M}) \quad (26)$$

与 $\alpha = 1e^{-4}$ 一起。请注意，我们需要实际优化 Z 而不是简单地固定它，是因为在交通模型解码器中的消息传递会导致非自我代理轨迹随着 $\mathbf{z}^{\text{plan}}$ 的优化而改变。

2. 避免碰撞。规划器的目标是避免在合理驾驶过程中与其他智能体和环境发生碰撞：

$$\min_{\mathbf{z}^{\text{plan}}} \mathcal{L}_{\text{prior}} + \mathcal{L}_{\text{coll}}. \quad (27)$$

先验损失是

$$\mathcal{L}_{\text{prior}} = -w_{\text{prior}} \log p_{\theta}(\mathbf{z}^{\text{plan}} | X, \mathcal{M}) \quad (28)$$

with $w_{\text{prior}} = 5e^{-3}$ 。碰撞损失是

$$\mathcal{L}_{\text{coll}} = w_{\text{agent}} \mathcal{L}_{\text{agent}} + w_{\text{env}} \mathcal{L}_{\text{env}}$$

其中 $\mathcal{L}_{\text{agent}}$ 与公式 (17) 中定义的相同，但仅用于阻止规划器与其他非自我智能体发生碰撞。 $\mathcal{L}_{\text{env}}$ 与公式 (19) 中定义的相同，仅应用于规划器。我们使用

$w_{\text{agent}} = w_{\text{env}} = 10$ 。在计算碰撞损失时，规划器被扩展到未来 $8s$ （而不是场景未来的 $6s$ 长度），以确保它在场景结束时不会进入无法恢复的状态。规划器轨迹在碰撞检测前被上采样 $\times 3$ 。

优化。解决方案优化使用 ADAM [26] 优化器，以 0.05 的学习率进行 200 次迭代。

A.5. 预过滤潜在场景

如主论文第 5.1 节所述，在进行对抗性优化之前，从 nuScenes 中过滤初始 $8s$ 场景，以去除那些难以或不可能导致碰撞的场景。对于每个潜在的初始设置，从基于过去轨迹的条件交通模型中采样 20 个未来。如果采样的任何未来满足以下启发式条件之一，则场景被认为是可行的，这些条件旨在找到一个可以被使与规划器发生碰撞的智能体：

- 存在一个非自我智能体，在某个时间步 $10m$ 内经过规划器 t 附近。
- 该智能体在 t 时不在规划器后方（“后方”的定义与附录 A.3 中相同）。
- 该智能体在 t 时没有被非可行驶地图区域与规划器隔开。
- 自我车辆必须在 $> 1 m/s$ 某个时刻移动，避免规划器处于“坐以待毙”且无避免碰撞希望的情况。

如果没有样本满足这些条件，初始场景将不用于场景生成。完成这一可行性检查后，我们会得到一个可能在时间 t 与规划器发生合理碰撞的非自我智能体候选。请注意，STRIVE 不会以任何方式使用这些信息——对抗性优化可以且确实会与初始候选不同的智能体发生碰撞。然而，这些信息对自行车基线有用，该基线需要在优化前选择对抗性智能体。

A.6. 自行车基准场景生成

自行车基线在主论文的第 5.1 节中引入。这种方法不使用学习到的交通模型来参数化场景，而是明确优化

对手的加速度曲线。由于它不对整体交通运动施加强先验假设，因此仅优化单个预先选择的“攻击者”（类似于先前的工作 [55]）。为此，我们使用附录 A.5 中由可行性检查确定的候选对手（在实践中，使用此可行性检查对自行车不可行，因为它利用了交通模型的样本，但我们在此使用它以确保与 STRIVE 的公平比较）。

优化是在对手 $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_T]$ 的未来加速度曲线 $\mathbf{t} = [\dot{v}_t, \theta_t]$ 上进行的。令 $\mathbf{b}$ 为对手车辆的长度和宽度，然后当需要获取对手轨迹 $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T]$ 时，会递归地应用运动学自行车模型 $\mathbf{y}_t = \mathcal{K}(\mathbf{y}_{t-1}, \mathbf{a}_t, \mathbf{b})$ ，其中 $\mathbf{y}_0$ 是固定过去最后一个时间步的状态。

初始化优化。在优化以造成碰撞之前，对手的加速度曲线会拟合到初始 nuScenes 场景 $\mathbf{Y}_{\text{init}}$ 中的对应轨迹，

$$\min_{\mathbf{A}} \|\mathbf{Y} - \mathbf{Y}_{\text{init}}\|^2. \quad (29)$$

该损失仅应用于轨迹的位置和航向部分（即不应用于速度或加速度）。

对手优化。接下来，执行主要对手优化，该优化鼓励对手使用 $\{\mathbf{v}_1\}$ 与规划器发生碰撞。

$$\min_{\mathbf{A}} w_{\text{adv}} \mathcal{L}_{\text{adv}} + w_{\text{accel}} \mathcal{L}_{\text{accel}} + \mathcal{L}_{\text{coll}}. \quad (30)$$

对抗性术语通过最小化位置距离来鼓励与 STRIVE 类似的碰撞：

$$\mathcal{L}_{\text{adv}} = \sum_{t=1}^T \|\mathbf{y}_t - \mathbf{y}_t^{\text{plan}}\| \cdot \delta_t \quad (31)$$

$$\delta_t = \frac{\exp(-\|\mathbf{y}_t - \mathbf{y}_t^{\text{plan}}\|)}{\sum_t \exp(-\|\mathbf{y}_t - \mathbf{y}_t^{\text{plan}}\|)}. \quad (32)$$

方程式 Eq. (32) 中的 softmin 只是在选择一个候选时间步来引发碰撞（与 STRIVE 中同时选择候选智能体和时间步不同），因为引发碰撞的智能体是预先固定的。此外请注意， $\mathbf{y}_t^{\text{plan}}$ 是实际的规划器轨迹，而不是像 STRIVE 中那样从交通模型中使用的可微分的近似值。这意味着在优化过程中，如果设置是闭环（例如基于规则的规划器），则需要通过真实规划器计算梯度。正如主论文第 5.1 节所述，我们实现了一种使用有限差分进行显式梯度估计的方法，以便能够反向传播通过规划器。然而，这需要向规划器发出大量查询，并且速度太慢，无法实际生成许多场景。有限差分虽然易于实现，但与先前工作中探索的黑盒方法相比效率低下 [55]——然而，探索这些选项也超出了我们当前的范围，因为 STRIVE

并不需要它们。

加速度项正则化优化后的轮廓，使其倾向于较小的加速度：

$$\mathcal{L}_{\text{accel}} = \frac{1}{T} \sum_{t=1}^T \|\mathbf{a}_t\|^2. \quad (33)$$

碰撞损失是

$$\mathcal{L}_{\text{coll}} = w_{\text{agent}} \mathcal{L}_{\text{agent}} + w_{\text{env}} \mathcal{L}_{\text{env}}$$

其中 $\mathcal{L}_{\text{agent}}$ 与 Eq. (17) 中定义的相同，但仅用于阻止对手与其他（固定的）非自我智能体发生碰撞。 $\mathcal{L}_{\text{env}}$ 与 Eq. (19) 中定义的相同，且仅应用于对手。

优化细节。我们使用 $w_{\text{adv}} = 1$ 、 $w_{\text{accel}} = 1$ 和 $w_{\text{agent}} = w_{\text{env}} = 20$ 。初始化优化使用 L-BFGS（对于简单目标函数优于 ADAM）进行 50 次迭代。对抗优化使用 ADAM 进行 300 次迭代。

为了公平地与 STRIVE 进行比较并评估某些指标，在自行车对抗优化后，我们使用附录 A.2 中描述的方法，将输出场景拟合到我们学习的交通模型中。然后我们可以计算对手 z 在学习先验下的似然性，并使用附录 A.4 中完全相同的解优化方法。

A.7. 基于规则的规划器

我们的基于规则的规划器在主论文的第4.2节中介绍，其具有以下结构：

1. 从车道图中提取一组有限样条线，每个车辆都可能沿着这些样条线行驶。
2. 沿着第1步中的每条样条线生成非本车车辆的预测未来运动。
3. 为本车车辆生成候选轨迹，并使用第2步的预测来估计每个候选轨迹的“碰撞概率” $p_{\text{col}}(\tau)$ 。
4. 在不太可能发生碰撞 $\{\tau \mid p_{\text{col}}(\tau) < p_{\text{max}}\}$ 的轨迹中，选择覆盖距离最长的轨迹。如果没有轨迹不太可能发生碰撞，则选择碰撞可能性最小的轨迹。
5. 每 Δt 秒重复一次。

请注意规划器的“意图”是确定的，即当从相同的初始化状态开始时，它总是会遵循相同的车道图路径（例如，选择是否向左或向右转）。正如在主论文中讨论的，nuScenes车道图不包含换道的信息，而基于规则的规划器严格遵循车道图，因此它不能换道。规划器的行为受超参数的影响，例如如何计算 $p_{\text{col}}(\tau)$ 、 p_{max} ，以及最大速度和前进加速度。

B. 实验细节

在本节中，我们提供了主论文第5节中执行实验的详细信息。

B.1. 数据和指标

数据集。所有实验均使用 nuScenes [5] 数据集；我们使用 nuScenes 预测挑战中的场景划分和设置。数据集中所有车辆的轨迹都经过预处理，以移除车辆边界框与不可驾驶区域或停车场区域有 $> 30\%$ 重叠的帧。这避免了存在许多未在标注地图上或未移动的辅助代理的场景。轨迹还使用有限差分法在提供的位置/航向上标注了速度和偏航率。最后，我们将“新加坡”数据的地图和轨迹绕 x 轴翻转，以便整个数据集中（包括波士顿和新加坡）的车辆都始终靠道路右侧行驶。

为训练学习到的交通模型，我们使用 nuScenes 预测挑战训练集的场景。请注意，我们使用训练场景中所有可用的小汽车和卡车轨迹数据，包括自车轨迹以及我们预处理中未移除的所有代理。

所有实验中的场景生成均从一组 1200 8s nuScenes 场景（在附录 A.5 中的预过滤之前）初始化，这些场景从训练集和验证集分割中提取。由于原始 nuScenes 数据序列是 20s 长的，其中一些提取的 8s 场景存在部分重叠。

指标。加速度和碰撞速度指标使用有限差分法计算。主论文的表 1 和表 3 中报告的加速度是前进方向的加速度（使用速度变化计算），而表 2 中的加速度是全加速度（包含前进方向和横向）。这是因为表 1 和 3 专注于基于规则的规划器生成的轨迹，该规划器遵循车道图，不能变道，并且具有确定性路线，如附录 A.7 中所述。因此，生成的场景无法使规划器突然转向（这需要离开车道图、变道或改变路线），它们只能导致更剧烈的减速或加速，这通过测量前进方向的加速度来捕捉。

所有实验中，加速度（Accel）、环境碰撞率（Env Coll）和最近邻距离（NN Dist）均仅报告至碰撞发生的时间，因为任何持续运动仅仅是未进行物理模拟碰撞的结果。表2中报告的环境碰撞率，如果车辆的边界框与非可行区域存在超过5%的重叠，则认为发生碰撞。

B.2. 规划器特定场景生成

该实验在主论文的第5.1节中介绍。在场景生成过程中，基于规则的规划器使用了默认的手动设置超参数（即事先未进行大规模调优，如主论文第5.3节所述）。这些默认超参数是通过观察nuScenes一小部分运行结果设置的。

在选项卡1中，报告了所有执行了对抗优化的场景的碰撞率（即约500个预过滤场景）。解决率是针对所有成功引发碰撞的场景，而规划器轨迹和匹配规划器指标是在所有有用场景（即同时找到碰撞和解决方案的场景）上计算的。

B.3. 基线对比

该实验在主论文的第5.1节中呈现，并将STRIVE与附录A.6中详细描述基线场景生成方法进行了比较。表2中报告的指标是两组场景的，这些场景在相同的nuScenes初始化条件下，两种方法都能够引发碰撞。请参阅附录A.6，了解如何测量Bicycle的解决率和NLL。

B.4. 场景分析

该实验在主论文的第5.2节中呈现。图6中显示的是第5.1节中生成的场景的碰撞标签。请注意， k -均值聚类并没有直接在第5.1节生成的场景上执行，而是在事先使用超过400个从nuScenes的不同子集生成的场景以及我们基于规则的规划器的多个版本进行聚类，从而提供了广泛的碰撞类型。通过视觉检查每个聚类中的碰撞来为聚类分配语义标签。然后，在生成第5.1节的新场景后，通过将每个新场景的碰撞特征与最近的聚类简单地关联，为每个新场景分配碰撞类型（即聚类不再重新执行，场景被分配到现有的聚类）。每个聚类中具有代表性的场景的视频显示在补充网页上。

我们使用 $k = 10$ 进行聚类。如有必要，可以使用更大的 k 或附加特征（如碰撞速度），但我们发现所描述的方法足以分析基于规则的规划器的性能，同时易于解释。

B.5. 改进基于规则的规划器

该实验在主论文的第5.3节中介绍。在进行任何调优之前，规划器使用附录B.2中描述的相同一组“默认”超参数启动。当调优规划器超参数时，

最优设置是通过最低碰撞率选择，若出现平局则通过最低加速度决定。规划器首先在800 8s nuScenes场景（来自train/val分割）上进行调优，这为“常规”驾驶场景提供了初始最优超参数。使用默认和常规调优的超参数对规划器进行对抗性优化，以创建一组具有挑战性的场景，以指导进一步的改进。在具有挑战性的场景上进行调优时，会移除“后方”碰撞，正如我们在主论文第5.2节中讨论的那样，我们发现这种碰撞不切实际。

基于规则的规划器的超参数在附录 A.7 中描述。在 $p_{\max}$ 的范围内、 $[0.05, 0.2]$ 范围内的最大速度、 $[12.5, 20.0]m/s$ 范围内的最大加速度、以及与计算 $p_{\text{col}}(\tau)$ 相关的参数进行搜索的调优。总共调优了 432 种超参数组合。

主论文表 3 中的结果来自保留的 nuScenes 测试集场景。对于某些超参数设置成功避免碰撞的场景（即所有超参数设置都发生碰撞的场景被视为不可能并丢弃），报告了碰撞场景（Coll）的指标。常规场景的最佳可能碰撞率为 3.2%（通过为每个场景选择不同的参数组合实现），这使得常规调优规划器版本的 4.6% 接近最优。这个碰撞率不能为 0 的原因是使用日志重放（即在预录制的场景中运行规划器），这导致了一些不可避免的碰撞：(i) 预录制的交通对规划器没有反应，(ii) 自行车有时初始化在车道图中无法稳健处理的区域。

学习模式分类器。规划器的多模式版本使用一个二元分类器，该分类器决定自行车当前是否处于“常规”或“易发生事故”的情况。在学习的版本中，此分类器是一个神经网络，其架构与附录A.1中描述的学习交通模型非常相似。具体来说，它接收场景中所有智能体的过去 2s 轨迹，以及每个智能体周围的局部地图裁剪，并以与交通模型相同的方式处理它们。这些特征随后被放置到场景图中，并像之前一样执行消息传递。在自行车节点处得到的输出特征（大小64）被输入到一个2层MLP，该MLP对场景进行二元分类。该网络在训练集中的常规nuScenes场景以及使用Replay和基于规则的规划器变体从train/val场景生成的1000多个碰撞场景上进行了训练。训练使用典型的二元交叉熵损失，该损失经过加权以考虑常规场景和碰撞场景之间的数据不平衡。

模型	ADE (m) ↓	FDE (m) ↓
LDS-AF [35]	1.66	3.58
DLow-AF [57]	1.78	3.77
Trajectron++ [47]	1.51	-
AgentFormer [58]	1.45	2.86
我们, 完整	1.75	3.57
我们, 无自行车	1.60	3.17

表4. 与当前最先进技术相比, 在所有nuScenes预测类别上学习的交通模型未来预测精度。ADE/FDE使用10个样本报告。

模型	ADE (m)	FDE (m)	环境碰撞(%)	车辆碰撞(%)
Full	1.74	3.54	10.6	5.6
无自行车	1.72	3.45	7.2	3.7
No $\mathcal{L}_{env}$	1.91	3.92	13.2	5.0
无自回归	3.68	8.00	16.2	5.4

表 5. 仅针对汽车和卡车 nuScenes 类别的交通模型消融研究（与场景生成所用相同）。尽管不使用自行车模型能获得更好的性能, 但它产生的单智能体车辆动力学不够真实, 这对场景生成来说是非常不理想的。

C. 补充实验

在本节中, 我们提供了由于篇幅限制而省略在正文中的附加结果和实验。

C.1. 交通运动模型

我们首先评估了学习到的交通模型预测场景未来运动的能力。我们在nuScenes [5]预测挑战的测试集上评估, 使用 2s (4 步) 的过去运动来预测 6s (12 步) 的未来。这些数据包含来自公共汽车、汽车、卡车、建筑和紧急救援类别的车辆。

指标。评估使用标准的未来预测指标, 包括最小平均位移误差 (ADE) 和最小最终位移误差 (FDE), 这些指标在 K 交通模型样本上测量。对于单个被评估的智能体, 这些指标是

$$\text{ADE} = \min_k \frac{1}{T} \sum_{t=1}^T \|\hat{\mathbf{y}}_t^{(k)} - \mathbf{y}_t\|_2 \quad (34)$$

$$\text{FDE} = \min_k \|\hat{\mathbf{y}}_T^{(k)} - \mathbf{y}_T\|_2 \quad (35)$$

其中 $\hat{\mathbf{y}}_t^{(k)}$ 是智能体在 k 个样本在时间 t 的预测位置, $\mathbf{y}_t$ 是真实值。在我们的实验中, 我们使用 $K = 10$ 个样本。

对于消融研究, 我们还测量了环境和车辆碰撞率。环境碰撞率是指预测的未来轨迹中超过

这是在所有 K 样本上测量的。车辆碰撞率是在每个场景中的所有智能体（而不是预测挑战测试拆分中每个数据点指定的单个智能体）和所有 K 样本上测量的。它与TrafficSim [49], 中使用的相同, 后者统计发生碰撞的智能体数量（即边界框与其他智能体重叠超过 IoU 0.02）。

C.1.1 基线比较

预测性能与最近最先进模型 AgentFormer [58], Trajec- tron++ [47], DLow-AF [57], 和 LDS-AF [35] 报告的结果进行比较。结果显示在表 4 中。我们的完整模型仅在 *car* 和 *truck* 车辆上训练, 用于场景生成, 因此要在预测挑战的测试集上评估, 我们将输入车辆的类别修改为这些之一（例如公共汽车 $\rightarrow$ 卡车）。我们的学习交通模型做出准确预测, 并与当前 SOTA 方法具有竞争力, 如表 4 所示。我们还训练了我们模型的消融版本, 该版本不使用运动学自行车模型, 而是解码器直接预测输出位置和航向。这个版本在挑战数据集的所有类别上训练, 并根据 ADE/FDE 做出更准确的预测。请注意, 然而, 使用自行车模型对于对抗性和解决方案优化非常重要, 以确保输出轨迹在优化 Z 离开流形时具有合理的动力学。

C.1.2 消融实验

为了评估我们的模型基于 TrafficSim [49] 和 ILVM [6], 的关键设计差异, 我们对交通模型设计的各个组件进行了消融。结果展示在表 5 中, 其中所有模型仅在 *car* 和 *truck* 类别上进行训练和评估, 因为这是我们用于场景生成的在主论文中使用的部分。与表 4 相同, No Bicycle 直接从解码器中预测位置和航向, 而不是通过运动学自行车模型进行加速度曲线; 同样, 这略微提高了性能, 但每个智能体的动态更不真实。No $\mathcal{L}_{env}$ 仅在训练时使用车辆碰撞惩罚, 与先前工作 [49] 类似。移除环境碰撞惩罚会导致更高的碰撞率和更低的预测精度。No Autoregress 使用一个 GNN 解码器, 一次性预测整个未来轨迹, 而不是作为自回归展开。这使得未来预测任务更加困难, 显著降低了准确率。

C.2. 对抗优化消融研究

接下来, 我们研究敌对优化目标函数的各个组成部分（该函数在第3.2节介绍, 是主论文中的内容, 并在附录A.3中详细说明）如何影响生成的场景。我们考虑以下变化:

场景	目标	百分比 (%)		对手轨迹的合理性 ↓		神经网络距离 (m)	NLL	其他轨迹的合理性 ↓		NLL
		成功率 (%)	成功率 (%)	加速度 (m/s^2)	环境碰撞 (%)			加速度 (m/s^2)	神经网络距离 (m)	
所有方法 碰撞	Full	-	87.9	1.11	9.4	0.90	517.0	0.45	0.39	341.4
	No $\mathcal{L}_{\text{prior}}$	-	78.8	1.26	9.4	1.05	502.9	0.47	0.39	474.2
	No $\mathcal{L}_{\text{coll}}$	-	81.8	1.43	15.6	1.11	487.0	0.45	0.39	351.5
	No $\mathcal{L}_{\text{init}}$	-	78.8	1.19	9.4	0.83	579.2	0.51	0.36	21.8
	无 $\mathcal{L}_{\text{init}}, \gamma$	-	84.8	1.13	9.4	0.76	89.2	0.49	0.40	-2.9
	无 $\mathcal{L}_{\text{init}}, \gamma, \delta$	-	57.6	1.38	15.6	0.99	154.6	1.04	0.65	104.3
所有碰撞 场景的 每种方法	Full	27.4	86.8	1.30	13.3	0.95	555.9	0.43	0.35	365.2
	No $\mathcal{L}_{\text{prior}}$	27.2	83.9	1.29	19.1	0.95	571.8	0.39	0.31	486.0
	No $\mathcal{L}_{\text{coll}}$	38.0	82.1	1.42	19.6	0.91	540.8	0.38	0.27	357.0
	No $\mathcal{L}_{\text{init}}$	34.6	80.1	1.40	18.3	1.02	611.6	0.41	0.29	6.8
	无 $\mathcal{L}_{\text{init}}, \gamma$	30.5	76.1	1.34	14.2	0.97	110.4	0.40	0.30	3.0
	无 $\mathcal{L}_{\text{init}}, \gamma, \delta$	45.9	58.1	2.01	26.4	1.38	230.8	1.07	0.71	127.9

表 6。基于规则的规划器场景生成的对抗优化目标消融研究。在顶部部分，仅报告了所有方法均能导致碰撞的场景的指标。在底部部分，每个方法的指标是在该方法生成的所有碰撞场景上计算的，即不直接可比。因此，也报告了碰撞率作为参考，数值不加粗。

在主论文中详细说明，并在附录A.3)中介绍的内容会影响生成的场景。我们考虑以下变化：

- 无 $\mathcal{L}_{\text{prior}}$ — 移除保持智能体遵循先验的先验损失，很可能在已学习的先验下。
- 没有 $\mathcal{L}_{\text{coll}}$ — 移除环境和车辆碰撞惩罚。
- 没有 $\mathcal{L}_{\text{init}}$ — 移除初始化损失，这会使智能体保持在初始（真实）场景附近。
- 没有 $\mathcal{L}_{\text{init}}, \gamma$ — 移除 γ 权重来自 $\mathcal{L}_{\text{prior}}$ ，这意味着可能的对手需要和场景中所有其他智能体一样可能地停留。
- 没有 $\mathcal{L}_{\text{init}}, \gamma, \delta$ — 此外移除了 δ 权重方案来自 $\mathcal{L}_{\text{adv}}$ ，这意味着所有智能体将在所有时间步同时尝试与规划器碰撞，而完全由 $\mathcal{L}_{\text{prior}}$ 来避免不切实际的车辆堆积。

注意，当移除 δ 和 γ 权重时，我们也移除了 $\mathcal{L}_{\text{init}}$ ，因为对手在需要碰撞时不应预期会非常靠近初始化。

结果展示在表6中。我们使用了与主论文第5.1节基线比较相同的指标。除了计算对手（碰撞代理）的指标外，还报告了所有其他非规划代理的结果（除了环境碰撞，因为nuScenes包含许多在标注的可驾驶区域外行驶的代理）。这些指标并不完美，很难评估哪个优化目标产生了“更好”的场景（甚至可能不可能，因为期望特征取决于下游用途），但它们确实能提供关于生成场景类型的见解。

Tab. 6 的顶部部分计算了所有方法都导致冲突（与主论文中 Tab 2 的协议相同）的场景中的指标。然而，由于有很多

由于存在许多变化，这总共只有33个场景。为了更全面地展示每种变化的情况，表格的底部部分计算了每种方法生成的所有冲突场景的指标。它还报告了冲突率，以便将解决方案率和其他指标进行上下文关联。由于底部部分每种方法计算的指标场景不同，数值不能直接比较，但趋势通常与顶部部分相似。

在表6的顶部，我们看到完整目标提供了最高的解决方案率，即它以最高频率生成有用场景。由于它们不再受学习先验的约束，因此没有 $\mathcal{L}_{\text{prior}}$ 倾向于导致场景中其他智能体出现不太可能的轨迹，并且如底部部分所示，环境碰撞对对手来说更加常见。没有 $\mathcal{L}_{\text{coll}}$ 同样导致碰撞次数大幅增加，再加上加速度更高的对手。尽管如此，轨迹仍然保持合理的可能性，因为 $\mathcal{L}_{\text{prior}}$ 仍然被使用，并且交通模型确实允许某些碰撞，如附录C.1.2所示。没有 $\mathcal{L}_{\text{init}}$ 允许轨迹远离 nuScenes初始化，这导致可解决场景的生成率降低，并且表格底部部分对手运动的合理性降低。请注意，“others”的NLL非常低，因为唯一剩余的正则化是 $\mathcal{L}_{\text{prior}}$ 。没有 $\mathcal{L}_{\text{init}}, \gamma$ 迫使对手在先验下更可能保持，导致NLL较低，但解决方案率降低。这种变化产生的合理结果表明了我们公式的灵活性，能够生成不同类型的场景。通过移除 γ ，我们鼓励场景中碰撞发生在更“典型”的设置中，而不是作为分布外、对抗性行为的结果。这在图8中定性地显示出来。没有 $\mathcal{L}_{\text{init}}, \gamma, \delta$ 使许多对手能够同时攻击，从而产生许多具有不现实轨迹的不可解决场景。




图8。基于规则规划器使用完整目标函数和修改后无初始化损失或每智能体权重的目标函数生成的对抗场景对比（适用于 $\mathcal{L}_{\text{prior}}$ ）。移除每智能体权重要求对抗样本更符合先验分布，这可能导致更符合“常规”交通的碰撞。STRIVE提供了修改此目标的灵活性，以生成最适合下游应用的场景。




图9。对抗优化导致的每智能体潜在向量变化，以与规划器的距离为函数。底部轴表示与规划器的距离区间（例如，10表示0-10m，20表示10-20m等）。每个区间内，报告了在对抗优化前后潜在距离为 > 0.5 的智能体数量（详见文本）。我们观察到，对抗优化倾向于对靠近规划器的智能体产生较大影响。

C.3. 多智能体场景下的性能表现

为了评估STRIVE有效优化大型场景的能力，我们特别关注包含许多智能体的场景。nuScenes中智能体的平均数量为11.4，因此它不包含许多大规模场景：在主论文的表1中，基于规则的规划器仅包含2/496 优化场景，其中包含 > 50 智能体。对于包含 ≥ 20 智能体的场景，碰撞率为21.2%，这与表1中的27.4%一致，表明性能在

大规模场景的表现与小规模场景相似。这是因为即使场景中有许多智能体，只有靠近规划器的少数智能体才会对结果产生重大影响（由于主论文中 Eq 9 的优化目标）。如图 9 所示，对抗性优化会频繁地对规划器 10m 范围内智能体的潜在向量进行大幅修改，而远离智能体的潜在向量则变化较少。每个智能体的潜在 z^i 的变化被测量为初始潜在值与对抗性优化后的最终潜在值之间的欧几里得距离，并除以场景中观察到的最大差异。

C.4. 建模二阶效应

对抗性优化的一项有趣能力是生成会导致与规划器发生碰撞的场景，即所谓的“二阶效应”。在这些场景中，对手可能不会以明显恶意的直接方式与规划器发生碰撞——相反，它会执行某些行为，导致规划器或其他车辆做出反应，从而引发规划器与另一个智能体的碰撞。例如，我们观察到几次对手在规划器前方突然刹车的情况，导致规划器刹车并被后方另一个智能体撞击，而不是前方最初对手。这促使我们在附录 A.3 中引入了正则化器 $\mathcal{L}_{\text{plan}}$ 。二阶行为之所以可能，是因为 STRIVE 优化场景中的所有智能体，而不是提前选择特定的对手。这些二阶场景的示例视频显示在补充网页上。

C.5. 解决方案优化评估

为确认解决方案优化是否能够过滤掉过于困难的场景，我们使用超参数调整流程并生成主论文第5.3节中引入的具有挑战性的场景进行评估。具体而言，我们采用基础的基于规则的规划器，执行两次超参数调整扫描：一次在解决方案优化找到解决方案的生成碰撞场景中，另一次在无法找到解决方案的碰撞场景中。对于每次扫描，我们测量调整集中每个场景成功（即不发生碰撞）的超参数设置的平均比例。在针对解决方案失败的场景进行调优时，平均每个场景只有11.8%的超参数组合能够避免碰撞。然而，在针对解决方案找到的场景进行调优时，每个场景有29.8%的超参数能够成功。这表明，为那些我们的解决方案优化失败的场景找到足够的超参数设置，比那些可以找到解决方案的场景更为困难。

C.6. 其他定性结果

基于规则的规划器中 STRIVE 的额外定性结果如图 11 所示。视频示例也包含在补充网页中。




图10. 使用在所有类别上训练的交通模型生成的Replay规划器场景。顶部行显示初始场景，底部是对抗优化的输出。在提前选择对手时，STRIVE会导致与行人（左）和骑行者（右）发生碰撞。

也包含在补充网页中。

C.7. 行人与骑行者对抗者

尽管我们这项工作的主要重点是生成涉及车辆的场景，但作为概念验证，我们将学习到的交通模型在nuScenes数据集的所有类别上进行训练，并为Replay规划器生成对手是行人或骑行者的场景。对于此实验，在附录A.5中使用的程序在优化之前特别选择了一个行人/骑行者对抗者。结果如图10和网页所示。

C.8. 失败案例和局限性

除了主论文第6节中讨论的局限性外，图12展示了其他STRIVE局限性示例。首先，我们提出的解决方案优化是迭代的，并在完整的时间规划器轨迹上运行，因此它可以访问未来的信息，有时甚至在“攻击”明显之前就能执行规避动作。图12(a)中的示例就是这样，优化的解决方案简单地没有驶入发生碰撞的环岛。图12(b)显示，对手有时会穿过不可驾驶区域以与规划器发生碰撞。虽然这种情况在技术上可能，但它是一种极端行为，可能并不理想。然而，这些情况可以很容易地检测并丢弃，并且通常只在规划器附近没有其他可行的对手时才会发生。最后，对抗优化可能难以表现出在先验分布下非常不可能但在现实中很真实的行为，例如图12(c)中停放汽车驶出，因为这些运动在交通模型训练数据中很少见。




图11. STRIVE闭环基于规则的规划器的额外定性结果。对抗优化对nuScenes的初始场景进行大幅修改，例如改变对手的意图或移动静止的车辆，以产生有用的碰撞场景。




图12. STRIVE的示例失效案例。(a) 求解优化有时能获取特权信息，导致产生不切实际的“解”。(b) 攻击者有时会驶入不可行驶区域以引发碰撞。(c) 需要在学习到的先验知识下进行不太可能运动的攻击（例如，停放汽车驶出）可能难以生成。